# KLASIFIKASI CITRA KANKER KULIT MENGGUNAKAN CONVOLUTIONAL NEURAL NETWORK MODEL GOOGLENET

# **SKRIPSI**



Disusun Oleh
DINA ZATUSIVA HAQ
H72217050

PROGRAM STUDI MATEMATIKA
FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS ISLAM NEGERI SUNAN AMPEL
SURABAYA

2021

## PERNYATAAN KEASLIAN

Saya yang bertanda tangan di bawah ini,

Nama

: Dina Zatusiva Haq

NIM

: H72217050

Program Studi : Matematika

Angkatan

: 2017

Menyatakan bahwa saya tidak melakukan plagiat dalam penulisan skripsi saya yang berjudul "KLASIFIKASI CITRA KANKER KULIT MENGGUNAKAN CONVOLUTIONAL NEURAL NETWORK MODEL GOOGLENET". Apabila suatu saat nanti terbukti saya melakukan tindakan plagiat, maka saya bersedia menerima sanksi yang telah ditetapkan.

Demikian pernyataan keaslian ini saya buat dengan sebenar-benarnya.

Surabaya, 1 September 2020

Yang menyatakan,

Dina Zatusiva Haq NIM. H72217050

# PERNYATAAN KEASLIAN

Saya yang bertanda tangan di bawah ini,

Nama

: Dina Zatusiva Haq

NIM

: H72217050

Program Studi : Matematika

Angkatan

: 2017

Menyatakan bahwa saya tidak melakukan plagiat dalam penulisan skripsi saya yang berjudul "KLASIFIKASI CITRA KANKER KULIT MENGGUNAKAN CONVOLUTIONAL NEURAL NETWORK MODEL GOOGLENET". Apabila suatu saat nanti terbukti saya melakukan tindakan plagiat, maka saya bersedia menerima sanksi yang telah ditetapkan.

Demikian pernyataan keaslian ini saya buat dengan sebenar-benarnya.

Surabaya, 1 September 2020

Yang menyatakan,

Dina Zatusiva Haq

AFAJX061083160

NIM. H72217050

# LEMBAR PERSETUJUAN PEMBIMBING

# Skripsi oleh

Nama : Dina Zatusiva Haq

NIM : H72217050

Judul Skripsi : KLASIFIKASI CITRA KANKER KULIT

MENGGUNAKAN CONVOLUTIONAL NEURAL

NETWORK MODEL GOOGLENET

telah diperiksa dan disetujui untuk diujikan.

Pembimbing I

Dian C. Rim Novitasari, M. Kom

NIP. 198511242014032001

Pembimbing II

Lutfi Hakim, M.Ag

NIP. 197312252006041001

Mengetahui,

Ketua Program Studi Matematika

UIN Sunan Ampel Surabaya

Aris Fanani, M.Kom

NIP. 198701272014031002

# PENGESAHAN TIM PENGUJI SKRIPSI

# Skripsi oleh

Hama Dina Zatuslva Haq

NIM H7??17050

Judul Skripsi KLASIG KAS1 CITRA KANKER KUL1T

MENGGUNAKAN COYVOLUTIONAL NEURAL

NETWO RK MODEL GOOGLENET

Telah dipenahankan dl depan Tim Penguji pada tanggal 27 Januari 202!

> Mengesahkan, Tim Penguji

Penguji I

Aris Fanani, V,Kom NIP. 198701272014031002 Penguji II

Nurissaidin 64nn hu, M.Kom NIP. 199011022014032004

Penguji III

Dian Candra Kiri Novitasari, V. Kom

NIP. 19851 12470I4032001

Penguji N

Lutti Hakin, M. Ag

NIP. 19731225206041001

Mengetahui,

Dekan Fak 1d\* S3ins dan Teknologi TERHASUPAN Anipel Surnbaya

usydlJah, U.Ag

?272005012003



# KEMENTERIAN AGAMA UNIVERSITAS ISLAM NEGERI SUNAN AMPEL SURABAYA PERPUSTAKAAN

Jl. Jend. A. Yani 117 Surabaya 60237 Telp. 031-8431972 Fax.031-8413300 E-Mail: perpus@uinsby.ac.id

# LEMBAR PERNYATAAN PERSETUJUAN PUBLIKASI KARYA ILMIAH UNTUK KEPENTINGAN AKADEMIS

Sebagai sivitas aka	demika UIN Sunan Ampel Surabaya, yang bertanda tangan di bawah ini, saya:
Nama	: DINA ZATUSIVA HAQ
NIM	: H72217050
Fakultas/Jurusan	: SAINTEK / MATEMATIKA
E-mail address	· zatusivad @ gmail.com
Sekripsi  yang berjudul:	
With the second of the second	ITRA KANKER KULIT MENGGUNAKAN CONVOLUTIONAL
NEURAL NET	work model awalenet
Perpustakaan UIN mengelolanya da menampilkan/mer akademis tanpa penulis/pencipta da Saya bersedia unt Sunan Ampel Sura dalam karya ilmiah	
Demikian pemyata	an ini yang saya buat dengan sebenarnya.
	Surabaya, 22 Februari 2021
	Penulis.

(DINA ZATUSIVA HAQ )

#### **ABSTRAK**

# KLASIFIKASI CITRA KANKER KULIT MENGGUNAKAN CONVOLUTIONAL NEURAL NETWORK MODEL GOOGLENET

Kanker kulit memiliki sepertiga bagian dari keselurahan kasus kanker dan diperkirakan akan terus bertambah. Keganasan kanker kulit, dapat diatasi dengan deteksi dini pada area kulit yang mencurigakan dengan pemeriksaan visual. Deteksi dini yang dilakukan secara manual sangat mengandalkan ketrampilan pengamat dan memungkinkan untuk terjadi kesalahan, sehingga diperlukan perhitungan komputasi untuk mempermudah dan menimalisir kesalahan oleh pengamat. Deteksi dini kanker kulit menggunakan perhitungan komputasi dilakukan dengan mengklasifikasi data citra area kulit yang mencurigakan. Pada penelitian ini, proses pembelajaran fitur dan klasifikasi data citra dilakukan dengan mengaplikasikan salah satu bagian deep learning yaitu GoogleNet yang merupakan arsitektur dari algoritma Convolutional Neural Network (CNN) yang diperkenalkan oleh Google pada tahun 2014 dan menempati peringkat pertama dalam kompetisi ILSVRC 2014 sebagai arsitektur dengan kinerja terbaik. Sistem klasifikasi yang dibuat menghasilkan nilai akurasi, sensitivitas, dan spesifitas masing-masing, 100%, 100%, dan 100% dengan pembagian data 90%, 0.4 dropout layer, 8 batchsize. Hasil evaluasi sistem menunjukkan bahwa pengaplikasian arsitektur GoogleNet pada algoritma CNN merupakan cara yang efektif untuk mendeteksi kanker kulit berdasarkan hasil klasifikasi data citra pada area kulit yang mencurigakan.

Kata kunci: CNN, GoogleNet, Kanker, Kanker Kulit, Deep Learning

#### **ABSTRACT**

# CLASSIFICATION OF SKIN CANCER IMAGE USING CONVOLUTIONAL NEURAL NETWORK MODEL GOOGLENET

Skin cancer accounts for one-third of all cancer cases and is expected to continue to grow. Skin cancer malignancy, can be resolved by early detection of suspicious skin areas with visual examination. Manual early detection relies heavily on the skills of observers and allows errors to occur, so computational calculations are required to simplify and minimize errors by observers. Early detection of skin cancer using computational calculations is performed by classifying suspicious skin area image data. In this study, the process of learning features and classification of image data was carried out by applying one part of deep learning, namely GoogleNet, which is the architecture of the Convolutional Neural Network (CNN) algorithm introduced by Google in 2014 and was ranked first in the ILSVRC competition with the best performance. The classification system created produces the accuracy, sensitivity, and specificity values of 100%, 100% and 100%, respectively, with 90% data sharing, 0.4 dropout layer, 8 batch The results of the system evaluation show that the application of the GoogleNet architecture to the CNN algorithm is an effective way to detect skin cancer based on 014 as an architecture resulting from the classification of image data on suspicious skin areas.

Keywords: CNN, GoogleNet, Cancer, Skin Cancer, Deep Learning

# **DAFTAR ISI**

HALAMAN PERNYATAAN KEASLIAN		j
LEMBAR PERSETUJUAN PEMBIMBING		ii
PENGESAHAN TIM PENGUJI SKRIPSI		iii
LEMBAR PERSETUJUAN PUBLIKASI		iv
ABSTRAK		vi
ABSTRACT		vii
DAFTAR ISI		viii
DAFTAR TABEL		xi
DAFTAR GAMBAR		xii
I PENDAHULUAN	<b>.</b>	1
1.1. Latar Belakang Ma <mark>sa</mark> lah	. ,)	1
1.2. Rumusan Masalah		5
1.3. Tujuan Penelitian		6
1.4. Manfaat Penelitian		6
1.5. Batasan Masalah		7
1.6. Sistematika Penulisan		
II TINJAUAN PUSTAKA		9
2.1. Kanker		9
2.2. Kanker Kulit		10
2.3. Citra Digital		14
2.3.1. Citra RGB		15
2.3.2. Citra Grayscale		15
2.3.3. Citra Biner		16
2.4. Dull Razor Filtering		17
2.5. Augmentasi Data		19
2.6. Convolutional Neural Network (CNN)		21
2.6.1. <i>Convolution layer</i>		23

		2.6.2.	Rectified Linear Unit (ReLU)	25
		2.6.3.	Local response normalization layer	25
		2.6.4.	Pooling layer	27
		2.6.5.	Dropout layer	27
		2.6.6.	Fully connected layer	28
	2.7.	Google	eNet	29
	2.8.	Confus	sion Matrix	30
	2.9.	Penyal	kit dalam Islam	32
		2.9.1.	Allah Menciptakan Penyakit untuk Manusia	32
		2.9.2.	Kewajiban Orang Sakit	33
		2.9.3.	Balasan Bagi Orang yang Sabar	35
Ш	МЕТ	ODE I	PENELITIAN	37
	3.1.	Jenis F	Penelitian	37
	3.2.	Pengui	mpulan Data <mark></mark>	37
	3.3.	Kerang	gka Penelitia <mark>n</mark>	38
IV	HAS		N PEMBAH <mark>ASAN</mark> <mark>.</mark>	
	4.1.	Deskri	psi Data	42
	4.2.	Dull R	azor Filtering	45
	4.3.	Augmo	entasi Data	50
		4.3.1.	Rotasi	50
		4.3.2.	Refleksi	52
	4.4.	Featur	re Learning dan Klasifikasi	54
		4.4.1.	Convolution layer	54
		4.4.2.	Rectified Linear Unit (ReLU)	58
		4.4.3.	Pooling Layer	60
		4.4.4.	Local Response Normalization	61
		4.4.5.	Inception Nodule	65
		4.4.6.	Dropout Layer	67
		1 1 7		67
		4.4.7.	Fully Connected Layer	67
	4.5.		jian Model dan Evaluasi Sistem	

		4.5.1.	Pembagian Data 60%	 -	71
		4.5.2.	Pembagian Data 70%	 -	77
		4.5.3.	Pembagian Data 80%	 8	34
		4.5.4.	Pembagian Data 90%	 Ģ	91
	4.6.	Diskus	si Hasil Penelitian	 Ģ	98
	4.7.	Integra	asi Keislaman	 1(	)1
V	PEN	UTUP		 10	<b>)</b> 4
	5.1.	Kesim	pulan	 10	)4
	5.2.	Saran		 10	)5
D	A FTA	R PHST	ΤΑΚΑ	1(	) <b>-</b>

# **DAFTAR TABEL**

2.1	Confusion matrix	31
4.1	Hasil evaluasi percobaan perbandingan data 60%	71
4.2	Hasil evaluasi percobaan perbandingan data 60% pada data tanpa	
	augmentasi	74
4.3	Hasil evaluasi percobaan perbandingan data 60% menggunakan	
	HOG-SVM	76
4.4	Hasil evaluasi percobaan perbandingan data 70%	78
4.5	Hasil evaluasi percobaan perbandingan data 70% pada data tanpa	
	augmentasi	81
4.6	Hasil evaluasi percobaan perbandingan data 70% menggunakan	
	HOG-SVM	83
4.7	Hasil evaluasi percobaan perbandingan data 80%	85
4.8	Hasil evaluasi percobaan perbandingan data 80% pada data tanpa	
	augmentasi	88
4.9	Hasil evaluasi percobaan perbandingan data 80% menggunakan	
	HOG-SVM	90
4.10	Hasil evaluasi percobaan perbandingan data 90%	92
4.11	Hasil evaluasi percobaan perbandingan data 90% pada data tanpa	
	augmentasi	95
4.12	Hasil evaluasi percobaan perbandingan data 80% menggunakan	
	HOG-SVM	97
4.13	Perbandingan hasil evaluasi sistem dengan peneliti terdahulu	99

# DAFTAR GAMBAR

2.1	Ilustrasi perbandingan benign dan malignant	9
2.2	Struktur lapisan kulit	11
2.3	Squaomous Cell Carcinoma (SCC)	12
2.4	Bassal Cell Carcinoma (BCC)	13
2.5	Melanoma	14
2.6	Contoh citra RGB dan nilai-nilai pikselnya	16
2.7	Contoh citra grayscale dan nilai-nilai pikselnya	16
2.8	Contoh citra biner dan nilai-nilai pikselnya	17
2.9	Gambar asli dan hasil akhir dari proses dull razor filtering	18
2.10	(a) Ilustrasi transformasi geometri rotasi, (b) Citra asli, (c) Citra	
	setelah di rotasi 90°	20
2.11	Ilustrasi transform <mark>asi geometri refle</mark> ksi	21
2.12	Layers pada algoritma CNN	22
2.13	Operasi konvolusi	24
2.14	Operasi konvolusi citra RGB	24
2.15	Ilustrasi perhitungan local response normalization layer	26
2.16	Jenis-jenis pooling layer	27
2.17	(a) Contoh neural network tanpa dropout dan (b) Contoh neural	
	network menggunakan dropout	28
2.18	Inception modules	30
3.1	Sampel data citra <i>malignant</i> dan <i>benign</i>	38
3.2	Diagram alir penelitian	38
3.3	Diagram alir <i>pre-processing</i> data citra	39
3.4	Arsitektur GoogleNet	41
J		
4.1	(a) dan (b) Sampel data citra benign (non-kanker)	42
4.2	(a) dan (b) Sampel data citra benign (non-kanker)	43

4.3	Lapisan citra RGB	43
4.4	Nilai piksel pada lapisan Red	43
4.5	Nilai piksel pada lapisan Green	44
4.6	Nilai piksel pada lapisan Blue	44
4.7	Proses <i>croping</i> dan <i>resize</i> data citra	44
4.8	Sample data citra dermoscopic	45
4.9	Lapisan R pada data sampel	46
4.10	Lapisan G pada data sampel	46
4.11	Lapisan B pada data sampel	46
4.12	Identifikasi piksel rambut lapisan R	47
4.13	Identifikasi piksel rambut lapisan G	47
4.14	Identifikasi piksel rambut lapisan B	48
4.15	Matriks hasil akhir lapisan R	48
4.16	Matriks hasil akhir <mark>lap</mark> isan G	49
4.17	Matriks hasil akhir lapisan B	49
4.18	Hasil akhir dari proses dull razor filtering	50
4.19	Ilustrasi rotasi 90°	52
4.20	Ilustrasi refleksi terhadap sumbu y	53
4.21	Contoh hasil augmentasi data	53
4.22	Sampel perhitungan convolution layer	54
4.23	Sampel perhitungan convolution layer lapisan R	55
4.24	Sampel perhitungan convolution layer lapisan G	55
4.25	Sampel perhitungan convolution layer lapisan B	56
4.26	Visualisasi feature map pada convolution layer	58
4.27	Visualisasi feature map pada ReLU	59
4.28	Ilustrasi perhitungan max pooling	60
4.29	Visualisasi feature map pada max pooling	61
4.30	Visualisasi feature map pada local response normalization	65
4.31	Feature map pada max pooling layer sebelum inception nodule	66
4.32	Feature map pada inception nodule	66

4.33	Ilustrasi perhitungan dropout layer	67
4.34	<i>Training progress</i> hasil terbaik pembagian data 60%	72
4.35	Confusion matrix hasil terbaik pembagian data 60%	73
4.36	Confusion matrix hasil terbaik pembagian data 60% tanpa augmentasi	75
4.37	Confusion matrix hasil terbaik pembagian data 60% menggunakan	
	HOG-SVM	76
4.38	Training progress hasil terbaik pembagian data 70%	79
4.39	Confusion matrix hasil terbaik pembagian data 70%	80
4.40	Confusion matrix hasil terbaik pembagian data 70% tanpa augmentasi	82
4.41	Confusion matrix hasil terbaik pembagian data 70% menggunakan	
	HOG-SVM	83
4.42	Training progress hasil terbaik pembagian data 80%	86
4.43	Confusion matrix hasil terbaik pembagian data 80%	87
4.44	Confusion matrix hasil terbaik pembagian data 80% tanpa augmentasi	89
4.45	Confusion matrix hasil terbaik pembagian data 80% menggunakan	
	HOG-SVM	90
4.46	Training progress hasil terbaik pembagian data 90%	93
4.47	Confusion matrix hasil terbaik pembagian data 90%	94
4.48	Confusion matrix hasil terbaik pembagian data 90% tanpa augmentasi	96
4.49	Confusion matrix hasil terbaik pembagian data 90% menggunakan	
	HOG-SVM	97

#### **BABI**

#### **PENDAHULUAN**

#### 1.1. Latar Belakang Masalah

Allah SWT menciptakan makhluk di bumi ini terutama umat manusia akan diuji dengan berbagai macam ujian. Allah SWT memberikan ujian agar melatih kesabaran umat manusai akan ujian tersebut, sebagaimana tertulis dalam ayat Al-Quran Surat Al-Baqarah ayat 155 yang berbunyi:

Artinya: Dan sungguh akan Kami berikan cobaan kepadamu, dengan sedikit ketakutan, kelaparan, kekurangan harta, jiwa dan buah-buahan. Dan berikanlah berita gembira kepada orang-orang yang sabar.

Maksud dari ayat tersebut adalah Allah SWT akan menguji umat manusia dengan rasa takut, kekurangan makanan, kemiskinan, dan kematian akibat peperangan ataupun penyakit. Salah satu jenis ujian dari Allah SWT berupa penyakit yang mematikan adalah kanker. Kanker dikenal sebagai penyakit dengan tingkat kematian tertinggi di negara maju dan tertinggi kedua di negara berkembang (Asyhar et al., 2020). Pada tahun 2018, terdapat sekitar 18.1 juta kasus kanker baru dengan kematian akibat kanker mencapai 9.6 juta jiwa. Persentase jumlah kematian akibat kanker telah mengungguli jumlah kematian

yang disebabkan oleh stroke dan jantung koroner. Kanker dapat menyerang organ-organ tubuh manusia, seperti paru-paru, payudara, otak, kulit, dan lain-lain (Bray et al., 2018). Salah satu jenis kanker yang umum adalah kanker kulit. Kanker kulit diderita sekitar 108.420 pasien dan menjadi penyebab kematian 11.480 jiwa di tahun 2020 (Siegel et al., 2020).

Penderita kanker kulit mengalami pertumbuhan sel yang tidak normal pada kulit (Dorj et al., 2018). Pertumbuhan sel yang tidak normal umumnya terjadi pada bagian kulit yang sering terpapar sinar matahari, namun juga dapat terjadi pada kulit bagian tubuh manapun. Kanker kulit menyerang bagian kulit lapisan terluar *Squamous Cells Carcinoma* (SCC), lapisan kedua *Basal Cell Carcinoma* (BCC), dan *melanocytes cells* pada lapisan ketiga atau lapisan terdalam. *Squamous cells* disebut dengan *non-melanoma*, sedangkan *melanocytes cells* disebut dengan kanker melanoma (Ansari and Sarode, 2017). Melanoma berawal dari transformasi keganasan *melanocytes cells*. *Melanocytes cells* yang terletak di bagian terdalam epidermis bertanggung jawab dalam pembentukan pigmen melamin kulit, sehingga kanker kulit jenis melanoma menyerang sel-sel pigmen pada kulit (Naves et al., 2017). Kerusakan jaringan kulit akibat sel kanker dapat dicegah dengan melakukan deteksi kanker kulit pada tahap awal agar mendapat perawatan yang tepat (Dorj et al., 2018).

Deteksi dini pada area kulit yang mencurigakan dengan membedakan lesi pada area kulit menjadi dua kelas yaitu *benign* dan *malignant*. *Benign* merupakan tumor jinak yang tidak dapat menyebar ke jaringan lain dan dapat diangkat atau dihilangkan dengan kemungkinan muncul kembali yang sangat minim. Sedangkan *malignant* merupakan kanker yang terdiri dari SCC, BCC, dan melanoma.

Identifikasi lesi pada area kulit sebagai *benign* atau *malignant* dilakukan oleh dokter kulit secara manual (Esteva et al., 2017). Deteksi dini yang dilakukan secara manual sangat mengandalkan ketrampilan pengamat, sehingga memungkinkan untuk terjadi *human error* (Farooq et al., 2016).

Human error dalam mengidentifikasi kanker kulit dapat diminimalisir dengan memanfaatkan sistem Computer Aided Diagnosis (CAD) (Layode et al., 2019). Sistem CAD diawali dengan pre-processing data citra (Thohir et al., 2020). Pre-processing data merupakan bagian penting pada setiap proses machine learning. Pre-processing dilakukan dengan tujuan mengoptimalkan data untuk model pembelajaran (Tabik et al., 2017). Tahap awal dalam pre-processing data citra dermoscopic yaitu dengan mengimplementasikan dull razor algorithm untuk menghilangkan piksel-piksel rambut pada area kulit yang diamati (Shafiq et al., 2018). Hal ini dilakukan dengan tujuan meningkatkan hasil akurasi pada proses klasifikasi. Proses klasifikasi data citra untuk mendeteksi adanya kanker telah dilakukan beberapa peneliti sebelumnya.

Penelitian yang dilakukan oleh Varun Sharma, penentuan benign atau malignant lesi kulit menggunakan metode klasifikasi *Support Vector Machine* (SVM) berdasarkan fitur-fitur warna, aturan ABCD (*axis length, border irregulerity, color,* dan *depth*), dan fitur geometris. Hasil evaluasi yang diperoleh dari penelitian tersebut menghasilkan nilai akurasi berkisar antara 90% hingga 97% (Sharma et al., 2020). Metode klasifikasi yang dilakukan oleh Varun Sharma dalam mendeteksi kanker kulit merupakan bentuk pengaplikasian dari metode *artificial intelligence*. Salah satu bagian dari *artificial intelligence* yaitu *deep learning*. *Deep learning* memungkinkan proses ekstraksi fitur dan proses klasifikasi data

citra terjadi pada satu arsitektur yang sama (Lecun et al., 2015). Penggunaan metode deep learning dalam proses klasifikasi data citra kanker kulit dilakukan oleh Adria Romer Lopez dengan menggunakan metode VGGNet yang mengklasifikasi citra lesi kulit menjadi dua kelas yaitu benign dan malignant. Hasil akurasi terbaik yang didapat pada model evaluasi training dataset mencapai 95.95% sedangkan pada model evaluasi testing dataset mencapai 81.33% (Lopez et al., 2017). Metode-metode pada deep learning yang umum digunakan antara lain Deep Belief Network (DBN), Reccurent Neural Network (RNN), dan Convolutional Neural Network (CNN) (Elleuch et al., 2017).

CNN merupakan salah satu metode deep learning yang mempelajari fitur dari suatu data dengan menggun<mark>aka</mark>n feature learning. CNN telah diterapkan dalam berbagai aplikasi komputasi seperti pengenalan pola, deteksi objek, klasifikasi data citra, dan lain sebagainya. CNN umumnya digunakan dalam identifikasi dan klasifikasi data citra (Garg and Verma, 2020). CNN memiliki beberapa arsitektur yang berbeda, seperti LeNet, AlexNet, ResNet, GoogleNet, dan lain-lain (Shanthi and Sabeenian, 2019). GoogleNet merupakan arsitektur dari metode CNN yang dikenalkan pada tahun 2014 dan memenangkan kompetisi ImageNet Large-Scale Visual Recognition Challenge 2014 (ILSVRC14) untuk klasifikasi data citra (Nagpal and Dubey, 2019). Arsitektur GoogleNet telah digunakan dalam penelitian sebelumnya. Penelitian yang dilakukan oleh R Anand menggunakan arsitektur GoogleNet pada algoritma CNN untuk mendeteksi wajah. akurasi yang dihasilkan dari sistem pengenalan wajah lebih baik dari teknik Machine Learning (ML) konvensional yaitu sebesar 91,43% (Anand et al., 2020). Penelitian lain dilakukan oleh Yanfen Li dalam klasifikasi hama yang membandingkan arsitektur GoogleNet dengan arsitektur CNN yang lain, seperti

VGG-19, ResNet50, VGG-16, ResNet152. Dari penelitian tersebut, sistem klasifikasi terbaik dihasilkan oleh arsitektur GoogleNet dengan tingkat akurasi mencapai 94.26% (Li et al., 2020).

Metode *deep learning* telah terbukti memiliki kinerja yang baik dalam perhitungan komputasi, namun metode ini sangat bergantung pada ketersediaan data dalam jumlah besar (*big data*) untuk mengurangi *overfitting* (Alqumboz and Abu-naser, 2019). Beberapa domain aplikasi tidak memiliki akses data besar, seperti analisis citra medis. Solusi untuk mengatasi masalah tersebut dapat dilakukan dengan melakukan augmentasi data. Augmentasi data menambahkan data baru yang mewakili satu set poin data yang lebih komprehensif dan dapat menimalisisr *overfitting* pada model (Shorten and Khoshgoftaar, 2019). Augmentasi data citra kanker kulit dapat dilakukan dengan melakukan transformasi geometri seperti rotasi, *horizontal flip*, dan *vertical flip* (Pham et al., 2018).

Berdasarkan penelitian-penelitian sebelumnya, arsitektur GoogleNet pada algoritma CNN memiliki kinerja yang baik dalam proses klasifikasi, sehingga penelitian ini memanfaatkan arsitektur CNN GoogleNet untuk mendeteksi kanker kulit berdasarkan data citra pada area kulit yang mencurigakan. Deteksi kanker kulit dengan arsitektur GoogleNet juga memanfaatkan algoritma *dull razor fillterring* dan augmentasi pada *pre-processing* data. Penelitian ini diharapkan dapat membangun sistem klasifikasi citra kanker kulit menggunakan metode CNN jenis GoogleNet.

#### 1.2. Rumusan Masalah

Berdasarkan permasalahan yang telah diuraikan pada latar belakang, perumusan masalah penelitian ini sebagai berikut:

- Bagaimana proses klasifikasi kanker kulit menggunakan dull razor filterring dan Convolutional Neural Network (CNN) GoogleNet berdasarkan klasifikasi data citra?
- 2. Bagaimana model optimal klasifikasi kanker kulit menggunakan *Convolutional Neural Network* (CNN) GoogleNet berdasarkan uji coba pembagian data, *dropout*, dan *minibatchsize*?

## 1.3. Tujuan Penelitian

Berdasarakan perumusan masalah diatas, penelitian ini dibuat dengan tujuan sebagai berikut:

- Dapat menklasifikasi kanker kulit menggunakan dull razor filterring dan Convolutional Neural Network (CNN) GoogleNet berdasarkan klasifikasi data citra dengan tingkat akurasi yang tinggi.
- Dapat mengetahui model optimal klasifikasi kanker kulit menggunakan Convolutional Neural Network (CNN) GoogleNet berdasarkan uji coba pembagian data, dropout, dan batchsize.

#### 1.4. Manfaat Penelitian

Penelitian ini diharapkan bermanfaat bagi berbagai lapisan masyarakat, seperti yang tertulis sebagai berikut:

#### 1. Manfaat Teoritis

Penelitian ini diharapkan menjadi referensi bagi penulis-penulis berikutnya dalam klasifikasi menggunakan salah satu arsitektur dari algoritma *Convolutional Neural Network* (CNN) yaitu GoogleNet atau deteksi dini adanya kanker kulit.

#### 2. Manfaat Praktis

#### a. Bagi Penulis

Menambah wawasan baru bagi penulis dalam menerapakan algoritma GoogleNet untuk klasifikasi kanker kulit.

#### **b.** Bagi Ahli Medis

Membantu ahli medis dalam mendiagnosis kanker kulit dengan lebih mudah dan hasil akurasi yang maksimal.

#### c. Bagi Masyarakat Umum

Mengedukasi masyarakat umum tentang bahaya kanker kulit serta membantu ahli medis mendiagnosis kanker kulit, sehingga pasien yang terdiagnosis dapat ditangani secara cepat dan tepat.

### 1.5. Batasan Masalah

Luasnya ruang lingkup permasalahan, maka pada penelitian ini diberikan batasan-batasan masalah sebagai berikut:

- Metode pembelajaran yang digunakan untuk mendeteksi adanya kanker kulit dengan proses klasifikasi data citra menggunakan arsitektur GoogleNet pada algoritma CNN.
- 2. Data citra yang digunakan pada penelitian ini merupakan data citra kanker

kulit dan data citra tumor jinak.

3. Kategori yang ditentukan pada proses klasifikasi ini yaitu indikasi kanker kulit dan tumor jinak.

#### 1.6. Sistematika Penulisan

#### BAB I PENDAHULUAN

Berisi latar belakang masalah, perumusan masalah, tujuan penelitian, manfaat penelitian, metodologi penelitian, dan sistematika penulisan.

#### BAB II TINJAUAN PUSTAKA

Berisi tentang kajian terhadap teori-teori yang digunakan untuk memahami permasalahan yang ada pada penelitian ini. Teori-teori tersebut meliputi kanker, kanker kulit, *dull razor filtering, Convolutional Neural Network* (CNN), GoogleNet, *confussion matrix*, dan integrasi kanker kulit dalam islam.

#### BAB III METODE PENELITIAN

Berisi jenis penelitian, pengumpulan data, dan kerangka penelitian.

#### BAB IV HASIL DAN PEMBAHASAN

Berisi tentang penjabaran hasil yang didapat dalam penelitian ini dan analisis data untuk menarik kesimpulan sesusai dengan tujuan penelitian.

#### BAB V PENUTUP

Berisi tentang kesimpulan dari hasil penelitian dan saran.

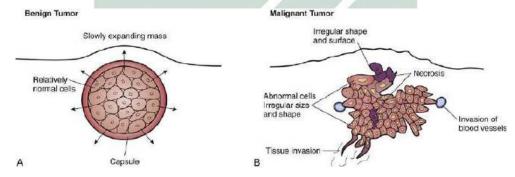
#### **BAB II**

## TINJAUAN PUSTAKA

#### 2.1. Kanker

Kanker merupakan penyakit yang akibat oleh pertumbuhan sel-sel tidak normal yang berkembang secara konstan dan menyebar ke jaringan-jaringan terdekat bahkan keseluruh tubuh. Sel kanker membentuk jaringan massa kanker yang disebut tumor. Tumor tersebut menyerang dan menghancurkan jaringan-jaringan normal disekitarnya (Geetha and Selvi, 2015). Tumor terbagi menjadi dua jenis, yaitu *benign* (jinak) dan *malignant* (ganas). *Benign* tidak bersifat kanker dan tidak dapat menyebar ke bagian tubuh lainnya. Berbeda dengan *benign*, *malignant* bersifat kanker dan dapat bermetastasis atau menyebar ke jaringan tubuh yang lain (Rashid, 2017). Ilustrasi perbandingan *benign* dan *malignant* ditunjukkan pada

Gambar 2.1.



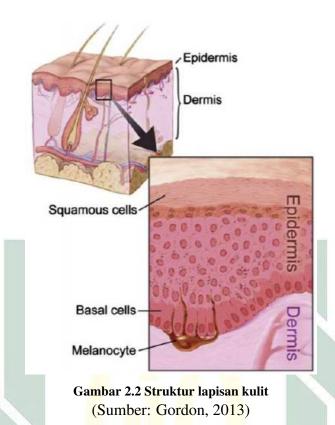
Gambar 2.1 Ilustrasi perbandingan benign dan malignant (Sumber: Pathology and Laboratory Medical, 2016)

Sel kanker memiliki lebih dari 100 jenis, dimana penamaan jenis kanker biasanya sesuai dengan organ tubuh tempat sel kanker tersebut berkembang, seperti kanker paru-paru, kanker otak, dan kanker kulit. Jenis kanker juga dapat dinamai sesuai dengan jenis sel yang membentuknya, sebagai contoh sel epitel atau sel skuamosa (Geetha and Selvi, 2015). Pertumbuhan sel kanker dapat terjadi karena berbagai faktor, seperti gaya hidup, konsumsi rokok maupun alkohol, diet, aktivitas fisik, perubahan lingkungan, dan paparan radiasi sinar matahari (Irigaray et al., 2007). Pertumbuhan sel kanker dapat dideteksi dengan berbagai cara, seperti tes darah (Hamouda et al., 2020), *biopsy, endoscopy* (Veitch et al., 2015), *Magnetic Resonance Image* (MRI), dan *Computed Tomography* (CT) (Chen et al., 2020).

#### 2.2. Kanker Kulit

Kulit merupakan organ terbesar dalam tubuh manusia yang mencapai 15% dari keseluruhan total berat badan pada orang dewasa. Kulit memiliki peran penting dalam tubuh antara lain berfungsi sebagai pelindung tubuh dari radiasi sinar ultraviolet (UV), melindungi dari serangan fisik maupun kimia dari luar tubuh, mencegah tubuh mengalami kekurangan air, dan sebagai tempat untuk menyimpan cadangan lemak (Kolarsick et al., 2011).

Kulit terdiri dari beberapa lapisan seperti pada Gambar 2.2. Lapisan terluar kulit disebut dengan lapisan epidermis. Lapisan epidermis merupakan lapisan yang menjadi pelindung tubuh dari benda asing. Setelah itu terdapat lapisan dermis yang terletak diantara lapisan epidermis dan lapisan hipodermis. Lapisan dermis merupakan tempat melekatnya pembuluh darah, kelenjar keringat, lemak, dan folikel rambut (Al-Amin et al., 2015). Lapisan pada kulit terdiri dari tiga sel utama, yaitu sel squamous, sel basal, dan sel melanosit (Ansari and Sarode, 2017).



Salah satu penyakit kulit yang mematikan adalah kanker kulit. Kanker kulit terjadi karena adanya pertumbuhan sel yang tidak normal pada kulit (Al-Amin et al., 2015). Sekitar 50% hingga 90% dari keseluruhan kanker kulit disebabkan oleh paparan radiasi ultraviolet (Kumar et al., 2015) Berdasarkan asal selnya kanker kulit dikelompokkan menjadi dua kategori, yaitu *Non Melanoma Skin Cancer* (NMSC) dan *Melanoma Skin Cancer* (MSC).

Kanker kulit *non-melanoma* terdiri dari dua jenis yaitu *Bassal Cell Carcinoma* (BCC) dan *Squaomous Cell Carcinoma* (SCC) (D'Orazio et al., 2013). Masingmasing tipe kanker kulit dijelaskan sebagai berikut:

Squaomous Cell Carcinoma (SCC)
 Squaomous Cell Carcinoma (SCC) merupakan neoplasma ganas keratinosit

yang menyerang lapisan dermis. SCC mencakup sekitar 16% kasus dari keseluruhan kasus kanker kulit (Gordon, 2013). Paparan sinar radiasi ultraviolet menjadi peran utama penyebab SCC. Faktor-faktor tambahan yang dapat mempengaruhi timbulnya SCC pada manusia antara lain terdapat infeksi *Human Papillomavirus* (HPV) tipe 16, 18, 31 dan kelainan kulit genetik seperti albino, *xeroderma pigmentosum*, dan lain-lain. SCC ditandai dengan adanya poliferasi sel skuamosa invasif yang dapat bermetastatis. Tingkat keganasan SCC dipengaruhi ukuran tumor, kedalaman lesi, dan sistem kekebalan tubuh pasien (Didona et al., 2018). Sampel SCC ditunjukkan pada Gambar 2.3.



Gambar 2.3 Squaomous Cell Carcinoma (SCC) (Sumber: Marks, 2020)

#### 2. Bassal Cell Carcinoma (BCC)

Bassal Cell Carcinoma (BCC) merupakan neoplasma ganas yang berasal dari sel basal. Sekitar 80% dari keseluruhan kasus NMSC. BCC umumnya muncul tanpa tanda-tanda lesi sebelumnya dan biasanya terdapat pada daerah yang sering terpapar sinar matahari, seperti kepala dan leher (Gordon, 2013). BCC dicirikan dengan sel yang menyerupai sel basal epidermis dan merupakan NMSC yang paling jinak. Meskipun dikatakan jenis NMSC

yang paling jinak BCC dapat menyebar ke jaringan disekitarnya dan dapat merusak jaringan (Didona et al., 2018). BCC ditunjukkan pada Gambar 2.4.



Gambar 2.4 Bassal Cell Carcinoma (BCC) (Sumber: Marks, 2020)

### 3. Melanoma

Melanoma ganas berasal dari sel melanosit epidermal dan dapat berkembang di jaringan manapun yang memiliki sel melanosit. Melanoma dapat diinduksi melalui berbagai mekanisme, seperti tekanan pada sistem kekebalan kulit, induksi sel melanosit, produksi radikal bebas, dan kerusakan DNA melanosit. Dari keseluruhan kasus kanker kulit, diperkirakan melanoma hanya terjadi pada 4% kasus. Namun kanker kulit tipe melanoma menyumbang sekitar 65% kematian dari keseluruhan kasus kanker kulit (Gordon, 2013). Melanoma merupakan jenis kanker kulit paling berbahaya dari jenis kanker kulit lainnya seperti BCC dan SCC. Melanoma merusak sel-sel pigmen pada kulit (Saba et al., 2019). Melanoma diakibatkan oleh beberapa faktor seperti warna kulit, kecenderungan kulit berbintik-bintik, riwayat keluarga, dan paparan sinar UV di lingkungan sekitar (Jensen et al., 2010). Melanoma ditunjukkan pada Gambar 2.5



Gambar 2.5 Melanoma (Sumber: Marks, 2020)

# 2.3. Citra Digital

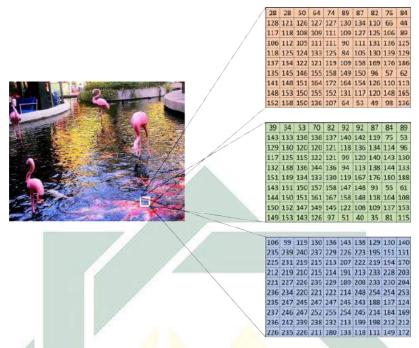
Citra digital merupakan representasi visual dari suatu objek atau benda. Proses menangkap atau capture suatu objek yang merepresentasikan citra digital disebut dengan akuisisi citra (Tarigan et al., 2016). Secara matematis citra didefinisikan sebagai fungsi dua dimensi f(x,y) dimaana x dan y adalah koordinat spasial (bidang) dan amplitudo f pada titik x,y merupakan nilai intensitas atau nilai derajat keabuan dari suatu citra. Citra dikatakan sebuah citra digital apabila nilai x,y dan nilai intensitas f terbatas dalam besaran diskrit. Citra digital terdiri dari sejumlah elemen yang terbatas dan pada masing-masing titik x,y memiliki nilai tertentu. Istilah paling umum untuk menyatakan elemen-elemen dalam citra yaitu piksel (Gonzales and Woods, 2018). Citra digital  $M \times N$  piksel dapat direpresentasikan dengan matriks baris M dan kolom N (Ma, 2020). Matriks yang merepresentasikan citra digital ditunjukkan pada Persamaan 2.1

$$f(x,y) = \begin{bmatrix} f(1,1) & f(1,2) & f(1,3) & \cdots & f(1,N) \\ f(2,1) & f(2,2) & f(2,3) & \cdots & f(2,N) \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ f(M,1) & f(M,2) & f(M,3) & \cdots & f(M,N) \end{bmatrix}$$
(2.1)

Citra menjadi data utama yang digunakan dalam implementasi pengelolahan citra digital (Padmavathi and Thangadurai, 2016). Pengelolahan citra digital merupakan teknologi yang digunakan untuk penggalian informasi dalam suatu citra dan pemprosesan citra melalui berbagai algoritma matematika. Pengelolahan citra digital telah banyak digunakan dalam berbagai bidang seperti teknik, ilmu komputer, *biology science*, *medical science*, dan lain-lain (Meng et al., 2018). Terdapat beberapa jenis citra yang umum digunakan dalam pengelolahan citra digital. Berikut jenis-jenis citra digital yang dibedakan berdasarkan tingkat warnanya:

#### 2.3.1. Citra RGB

Citra RGB direpresesntasikan oleh tiga lapisan komponen warna yaitu red (R), green (G), dan blue (B) (Padmavathi and Thangadurai, 2016). Secara matematis citra RGB didefinisikan dengan persamaan  $f_{m,n} = (r_{m,n}, g_{m,n}, b_{m,n})$ , dimana masing-masing lapisan warna memilki nilai piksel dengan rentang antara 0 hingga 255 (Kumar and Verma, 2010;Grigoryan and Agaian, 2018). Contoh citra RGB dan nilai-nilai piksel pada lapisannya ditunjukkan pada Gambar 2.6.



Gambar 2.6 Contoh citra RGB dan nilai-nilai pikselnya

## 2.3.2. Citra Grayscale

Citra *grayscale* adalah citra monokrom atau citra yang hanya memiliki satu warna. Citra *grayscale* hanya memiliki nilai yang menunjukkan informasi kecerahan dan tidak memiliki informasi warna. Nilai piksel yang dimiliki citra *grayscale* berada pada rentang 0 hingga 255, masing-masing nilai memiliki tingkat kecerahan atau level keabuan yang berbeda (Padmavathi and Thangadurai, 2016). Contoh citra *grayscale* ditunjukkan pada Gambar 2.7.

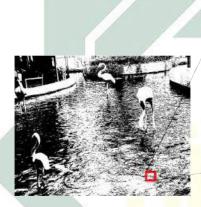
#### 2.3.3. Citra Biner

Citra biner merupakan jenis citra paling sederhana, karena hanya terdiri dari dua piksel yaitu 0 dan 1. Nilai piksel 0 pada citra biner merepresentasikan warna hitam sedangkan nilai piksel putih merepresentasikan warna putih (Padmavathi and Thangadurai, 2016). Contoh citra biner ditunjukkan pada Gambar 2.8.



43	40	60	75	86	97	96	90	87	93
149	141	146	146	145	147	149	125	81	59
136	138	128	128	129	125	143	141	121	102
125	132	123	129	129	107	128	148	151	137
138	144	143	151	143	102	121	146	152	140
157	154	140	139	137	127	174	183	187	195
151	160	160	167	168	159	159	105	65	68
154	160	162	172	179	171	161	131	115	116
159	163	158	161	157	135	121	122	149	163
159	164	155	139	109	64	53	48	94	128

Gambar 2.7 Contoh citra grayscale dan nilai-nilai pikselnya



0	0	0	O	0	0	0	0	0	0
1	1	1	1	1	1	1	0	0	0
1	1	1	1	1	0	1	1	0	0
0	1	0	1	1	0	1	1	1	1
1	1	1	1	1	0	0	1	1	1
1	1	1	1	1	1	1	1	1	1
1	1	1	1	1	1	1	0	0	0
1	1	1	1	1	1	1	1	0	O
1	1	1	1	1	1	0	0	1	1
1	1	1	1	0	0	0	0	0	1

Gambar 2.8 Contoh citra biner dan nilai-nilai pikselnya

#### 2.4. Dull Razor Filtering

Beberapa citra *dermoscopic* memiliki piksel rambut yang dapat memengaruhi kinerja klasifikasi data citra, sehingga perlu dilakukan proses untuk menghilangkan piksel rambut. *Dull razor filtering* merupakan algoritma yang digunakan untuk menghilangkan piksel rambut pada data citra *dermoscopic* (Attia et al., 2019). Algoritma dull razor filtering mengidentifikasi lokasi rambut gelap dengan menggunakan *generalizes graysacle morphological closing operation*. *Graysacle morphological closing operation* menghaluskan piksel rambut hitam yang memiliki nilai intensitas rendah (Lee et al., 1997).

Algoritma dull razor filtering dalam menghilangkan piksel rambut pada data citra terdiri dari tiga langkah yaitu, mendeteksi piksel rambut, mengganti piksel rambut dengan piksel yang bukan rambut disekitarnya, dan menghaluskan hasil akhir. Dalam skema tersebut, deteksi piksel rambut dilakukan berdasarkan tingkat keabuan data citra dan melihat ukuran piksel rambut. Piksel yang terdeteksi sebagai rambut selanjutnya akan diganti dengan piksel yang bukan rambut disekitarnya. Langkah terakhir menghilangkan piksel rambut yaitu dengan menghaluskan data citra untuk meningkatkan keserasian pada piksel rambut yang diganti (Kiani and Sharafat, 2011). Hasil dari proses dull razor filtering ditunjukkan pada Gambar 2.9





Gambar 2.9 Gambar asli dan hasil akhir dari proses dull razor filtering (Sumber: Maglogiannis and Delibasis, 2015)

Berikut merupakan langkah-langkah algoritma *dull razor filtering* dalam menghilangkan piksel rambut pada citra RGB (Srividya and Arulmozhi, 2019):

- 1. Membaca data citra,
- 2. Memisahkan lapisan R, G, dan B pada data citra,
- 3. Mendeteksi piksel rambut dilakukan berdasarkan tingkat keabu-abuan data citra dan melihat ukuran piksel rambut pada masing-masing lapisan warna.

Deteksi piksel rambut dilakukan dengan *bottom-hat filtering* yang merupakan selisih antara citra hasil operasi mofologi *closing* dan citra asli,

- 4. Mengganti piksel yang terdeteksi sebagai rambut dengan menggunakan algoritma *Region of Interest* (ROI),
- 5. Menggabungkan ketiga lapisan sehingga menghasilkan data citra berwarna dengan piksel rambut yang telah dihilangkan.

#### 2.5. Augmentasi Data

Augmentasi data merupakan salah satu cara yang digunakan untuk mengurangi overfitting pada sistem klasifikasi dengan memperbanyak variansi data citra. Metode augmentasi data memperbanyak variansi data citra dengan cara memodifikasi data citra asli. Modifikasi dapat dilakukan dengan berbagai cara seperti transformasi geometrik, modifikasi warna, filter kernel dan lain sebagainya. Sehingga untuk setiap input-an data citra menghasilkan citra duplikat yang digeser, diputar, diperbesar, dan lain-lain (Perez and Wang, 2017). Metode modifikasi augmentasi dengan modifikasi warna merubah nilai-nilai piksel dalam data citra untuk meningkatkan kecerahan, kontras, dan lain sebagainya. Metode modifikasi warna yang paling umum digunakan yaitu metode histogram equalization, enhancing contrast or brightness, white balancing, sharpening, dan blurring. Sedangkan metode augmentasi dengan transformasi geometrik merubah posisi piksel pada citra. Metode yang umum digunakan dalam augmentasi data dengan transformasi geometrik yaitu rotasi dan refleksi (Mikołajczyk and Grochowski, 2018). Penerapan rotasi dan refleksi data citra dijelaskan sebagai berikut:

#### 1. Rotasi

Rotasi dalam augmentasi data citra yaitu dengan melakukan perputaran posisi

nilai-nilai piksel pada data citra awal sebesar  $\theta^\circ$  terhadap sudut dan titik pusat rotasi. Perubahan posisi piksel awal data citra ke posisi yang baru dengan rotasi didefinisikan pada Persamaan 2.2

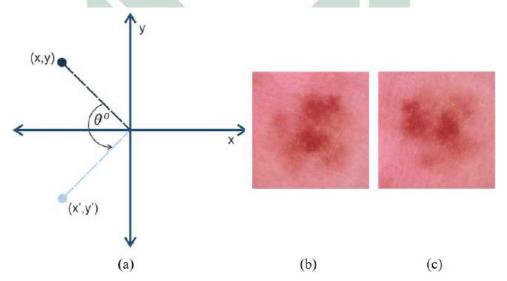
$$\begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} \cos\theta^{\circ} & -\sin\theta^{\circ} \\ \sin\theta^{\circ} & \cos\theta^{\circ} \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix}$$
 (2.2)

Berdasarkan aturan perkalian matriks, dari Persamaan 2.2 didapat Persamaan 2.3 sebagai berikut:

$$x' = x\cos\theta^{\circ} - y\sin\theta^{\circ}$$

$$y' = x\sin\theta^{\circ} + y\cos\theta^{\circ}$$
(2.3)

Dimana x' dan y' merupakan koordinat posisi piksel yang telah diperbarui. Sedangkan x dan y merupakan koordinat posisi piksel awal. Ilustrasi rotasi ditunjukkan pada Gambar 2.10



Gambar 2.10 (a) Ilustrasi transformasi geometri rotasi, (b) Citra asli, (c) Citra setelah di rotasi  $90^\circ$ 

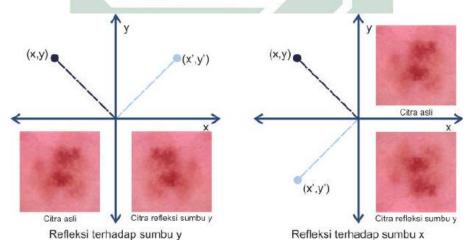
#### 2. Refleksi

Refleksi atau pencerminan dalam augmentasi data citra yaitu dengan melakukan pencerminan posisi nilai-nilai piksel pada data citra awal terhadap sumbu x atau sumbu y. Perubahan posisi piksel awal data citra ke posisi yang baru dengan refleksi terhadap sumbu x dan sumbu y didefinisikan pada Persamaan 2.4 dan Persamaan 2.5.

$$\begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix}$$
 (2.4)

$$\begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix}$$
 (2.5)

Dimana x' dan y' merupakan koordinat posisi piksel yang telah diperbarui. Sedangkan x dan y merupakan koordinat posisi piksel awal. Ilustrasi refleksi ditunjukkan pada Gambar 2.11



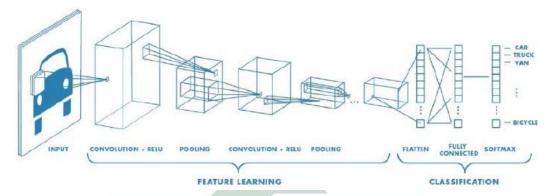
Gambar 2.11 Ilustrasi transformasi geometri refleksi

#### **2.6.** Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN) termasuk algoritma deep learning karena kedalaman jaringannya yang tinggi. Algoritma CNN merupakan hasil dari pengembangan Multilayer Perceptron (MLP) yang memungkinkan untuk melakukan pengolahan data dua dimensi sehingga algoritma CNN dapat digunakan dalam pengelolahan data citra atau suara (Susilo et al., 2017). Algoritma CNN telah digunakan dalam berbagai macam perhitungan komputasi seperti segmentasi, deteksi, pengenalan pola, dan klasifikasi data citra (Ker et al., 2017).

Beberapa dekade terakhir, algoritma CNN banyak diaplikasikan dalam analisis citra medis. Arsitektur yang dirancang pada algoritma CNN mampu mempelajari pola-pola rumit dalam citra medis yang terlihat mirip satu sama lain (Anwar et al., 2018). CNN terdiri dari input layer, output layer, dan beberapa hidden layer. Hidden layer dalam CNN umumnya terdiri dari convolution layer, fungsi aktivasi, Rectified Linear Unit (ReLU), local response normalization layer, pooling layer, dropout layer dan fully connected layer (Alqumboz and Abu-Naser, 2020). Layer tersebut digunakan untuk mempelajari fitur dari data citra dengan membaca dan mengolah nilai-nilai pikselnya. Fully connected layers merupakan layer terakhir yang memberi nilai probabilitas pada masing-masing kelas (Ker et al., 2017). Data akan diklasifikasikan kedalam kelas dengan probabilitas tertinggi. Klasifikasi menggunakan algoritma CNN GoogleNet dipengaruhi oleh beberapa faktor, salah satunya yaitu batchsize. Batchsize merupakan hyperparameter yang menentukan jumlah sampel data yang akan di training dengan perulangan sebanyak epoch pada masing-masing sampel. Ilustrasi layer pada algoritma CNN ditunjukkan pada

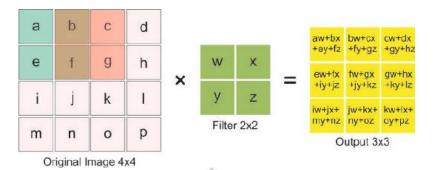
Gambar 2.12.



Gambar 2.12 Layers pada algoritma CNN (Sumber: Matworks)

#### 2.6.1. Convolution layer

Convolution layer merupakan layer paling penting dari CNN (Wang et al., 2018b). Konvolusi merupakan sebuah matriks yang diterapkan pada citra dengan operasi matematika (Ludwig, 2013). Convolution layer ini diterapakan beberapa operasi konvolusi pada data citra secara berurutan guna mempelajari fitur tepi, warna, dan bentuk dari citra input (Kalash et al., 2018). Operasi konvolusi diterapkan pada dua matriks, yaitu matriks yang berisi piksel citra input dan matriks kernel atau filter (Ker et al., 2017). Dalam CNN filter merupakan matriks berisi nilai random antara -1 sampai 1 yang digunakan untuk mempelajari fitur-fitur pada citra pada area-area kecil sesuai ukuran filternya. Ukuran filter bergantung pada jenis-jenis arsitekturnya. Filter bergeser sebanyak stride pada nilai-nilai piksel citra input. Output dari convolution layer merupakan hasil operasi dot product antara citra input. Output yang didapat pada proses di convolution layer berupa tumpukan feature map dari semua lapisan filter (Elsharif et al., 2019). Operasi konvolusi dengan stride 1 di ilustrasikan pada Gambar 2.13



Gambar 2.13 Operasi konvolusi

Berdasarkan operasi *dot product* pada Gambar 2.13, maka perhitungan pada *convolution layer* dengan *input*an data citra RGB diilustrasikan pada Gambar 2.14



Hasil dari *convolution layer* akan membentuk *feature map* dengan ukuran dimensi seperti pada Persamaan 2.6

$$h = \frac{i - k + 2p}{s} + 1\tag{2.6}$$

Dimana h adalah ukuran dimensi  $feature\ map$ , k adalah ukuran dimensi filter, p ukuran dimensi padding, dan s adalah banyaknya stride. Padding merupakan parameter bernilai 0 yang ditambahkan di setiap sisi pada citra input. Hal ini bertujuan untuk meningkatkan kinerja layer dalam mempelajari fitur pada

citra.

### 2.6.2. Rectified Linear Unit (ReLU)

Rectified Linear Unit (ReLU) merupakan fungsi aktivasi yang paling umum digunakan dalam algoritma CNN (Munir et al., 2019). ReLU merubah nilai input neuron feature map yang dihasilkan dari convolution layer berada pada range 0 hingga infinity (Wang et al., 2018a). Misalkan x merupakan nilai input neuron, operasi fungsi aktivasi ReLU didefinisikan pada Persamaan 2.7.

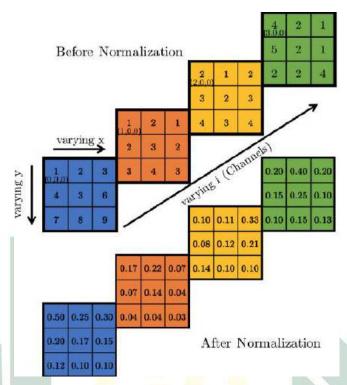
$$F(x) = max(0, x) \tag{2.7}$$

Sederhananya fungsi aktivasi menetapkan nilai 0 sebagai pengganti nilai negatif pada *feature map* dan nilai *input neuron feature map* tetap jika bernilai lebih dari atau sama dengan 0 (Cokun et al., 2017).

#### 2.6.3. Local response normalization layer

Normalisasi berperan penting dalam algoritma CNN untuk mengatasi nilai yang tidak dibatasi pada fungsi aktivasi ReLU (Krizhevsky et al., 2012). Normalisasi dilakukan dengan menggunakan *local response normalization layer* untuk memproses *feature map* guna meningkatkan kemampuan generalisasi (Chu et al., 2018). Ilustrasi perhitungan *local response normalization layer* dengan parameter  $(k, \alpha, \beta, n)$  sama dengan (0, 1, 1, 2) ditunjukkan pada Gambar 2.15

Local response normalization layer juga dikenal dengan nama cross channel normalization. Layer ini mengubah setiap elemen dengan nilai normalisasi berdasarkan elemen dari fitur-fitur terdekat dari feature map yang sama maupun feature map yang berbeda (Feng et al., 2017). Local response



Gambar 2.15 Ilustrasi perhitungan *local response normalization layer* (Sumber: Anwar, 2019)

normalization layer didefinisikan pada Persamaan 2.8.

$$x_{i,j}^{p} = \frac{a_{i,j}^{p}}{\left(k + \frac{\alpha \sum_{q=\max(1, p-n/2)}^{\min(N-1, p+n/2)} \left(a_{i,j}^{q}\right)^{2}}{n}\right)^{\beta}}$$
(2.8)

Dimana p menunjukkan output dari filter ke-p, a(i,j) dan x(i,j) merupakan nilai piksel sebelum dan sesudah dinormalisasi pada posisi (i,j), N merupakan jumlah total layer.  $k, \alpha, \beta, n$  merupakan hyperparameters dengan k adalah konstanta yang digunakan untuk menghindari pembagian nol,  $\alpha$  sebagai konstanta normalisasi,  $\beta$  sebagi konstanta kontras, dan n digunakan untuk menentukan panjang piksel berdekatan yang perlu dipertimbangkan saat normalisasi.

# 2.6.4. Pooling layer

Pooling layer memodifikasi feature map berdasarkan nilai piksel terdekat menggunakan operasi statistik (Wang et al., 2018a). Pooling layer mempercepat proses perhitungan komputasi dengan cara mengurangi volume pada setiap tumpukan feature map tanpa menghilangkan informasi-informasi penting (Cokun et al., 2017). Pooling layer memiliki beberapa jenis seperti max pooling layer dan average pooling layer. Max pooling layer merupakan jenis pooling layer yang paling umum digunakan (Kudva et al., 2018). Ilustrasi jenis-jenis pooling layer ditunjukkan pada Gambar 2.16.

Berdasarkan Gambar 2.16 dengan *stride* sama dengan dua, *max pooling* layer mengambil nilai piksel tertinggi pada bagian terpilih *feature map*, average pooling layer menghitung rata-rata dari semua nilai piksel pada bagian terpilih *feature map*.

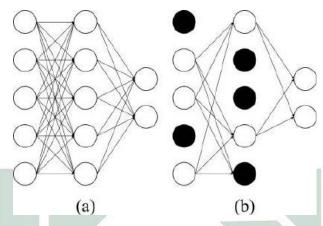
F	eatur	e Ma	р					
1	5	6	2		ax oling	Average Pooling		
5	5	4	4	5	6	4	4	
2	2	4	4	4	8	3	5	
2	4	8	4					

Gambar 2.16 Jenis-jenis pooling layer

#### 2.6.5. Dropout layer

Algoritma CNN memiliki *hidden layer* yang sangat kompleks dan sering kali menyebabkan *overfitting*. Salah satu teknik mengatasi *overfitting* yaitu dengan menggunakan *dropout layer*. *Dropout layer* merupakan teknik sederhana yang

dapat mempengaruhi kinerja algoritma CNN dalam proses *testing* model (Srivastava et al., 2014).



Gambar 2.17 (a) Contoh *neural network* tanpa *dropout* dan (b) Contoh *neural network* menggunakan *dropout* 

Ide utama dari *dropout layer* adalah menghilangkan beberapa *neuron* secara acak dengan probabilitas sebesar *p* pada setiap iterasi proses *training* model dan *p* dapat ditentukan dengan uji coba. Setelah diterapkan *dropout layer* jaringan akan lebih tipis dari sebelumnya yang mengurangi *overfitting* pada model dan menpercepat proses *training* (Wang et al., 2020). Sebagai contoh *dropout layer* ditunjukkan pada Gambar 2.17.

#### 2.6.6. Fully connected layer

Fully connected layer melakukan klasifikasi pada output yang dihasilkan dari convolution layer dan pooling layer. Setiap jaringan pada fully connected layer saling terhubung dengan jaringan pada lapisan sebelumnya (Kalash et al., 2018). Fully connected layer dianggap sebagai layer penyatuan akhir yang mengklasifikasi fitur kedalam kelas-kelas berdasarkan set data pelatihan. Penentuan kelas data citra dilihat dari kombinasi fitur yang paling kuat (Cokun et al., 2017). Fully connected layers didefinisikan pada Persamaan 2.9

$$y_j = b_j + \sum_i w_{ij} x_i \tag{2.9}$$

Dimana x merupakan input pada fully connected layer yang merupakan hasil dari pembelajaran fitur, w merupakan bobot jaringan berukuran ixj dengan i menunjukkan jumlah fitur dan j menunjukkan jumlah target kelas, b merupakan bias, dan y merupakan output dari fully connected layer (Liu et al., 2018). Fully connected layer biasanya diikuti oleh softmax layer yang digunakan sebagai fungsi aktivasi. Fungsi aktivasi softmax mengubah vektor skor nilai ril kedalam bentuk yang sama namun dalam rentang nilai 0 hingga 1 yang berjumlah 1 (Cokun et al., 2017). Fungsi aktivasi softmax merubah nilai menjadi probabilitas dengan menggunakan Persamaan 2.10

$$SoftMax(y_i) = \frac{e^{y_i}}{\sum_{i=1}^{m} e^{y_i}}, i = 1, 2, m$$
 (2.10)

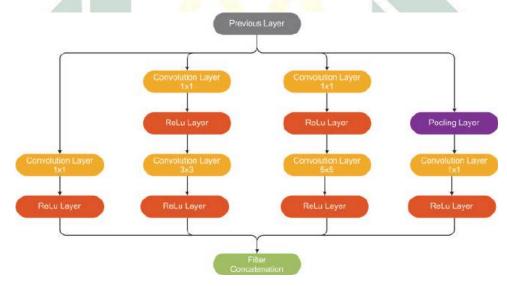
Dimana  $SoftMax(a_i)$  merupakan nilai probabilitas  $a_i$  dan m merupakan jumlah kelas. Nilai softmax berada pada range 0 sampai 1. Data akan diklasifikasikan kedalam kelas dengan nilai softmax yang mendekati satu atau paling tinggi (Bora et al., 2016; Tabik et al., 2017).

#### 2.7. GoogleNet

GoogleNet merupakan arsitektur yang diperkenalkan oleh Google pada tahun 2014 dan menempati peringkat pertama dalam kompetisi *ImageNet Large Scale Visual Recognition Challenge* (ILSVRC) 2014 sebagai arsitektur dengan kinerja terbaik. Nilai *error* yang didapatkan GoogleNet dalam klasifikasi data citra mencapai 6.7% (Seo and Shin, 2019). Model pembelajaran arsitektur GoogleNet

dapat mencapai akurasi tinggi dengan memperdalam layer untuk meningkatkan kinerja jaringan saraf (Kim et al., 2019). GoogleNet memiliki 144 layer dengan ukuran citra pada layer input  $224 \times 224 \times 3$  (Zhang et al., 2020b).

Keunggulan GoogleNet terletak pada *inception modules* yang tidak dimiliki CNN pada umumnya. *Inception modules* terdiri dari beberapa *convolution* kecil yang bertujuan untuk mereduksi jumlah parameter tanpa mengurangi kinerja jaringan (Jasitha et al., 2019). *Output* pada *layer* sebelumnya diolah pada *convolution layer* 11 sebanyak 4 *layer*, *convolution layer* 3 × 3 sebanyak 1 *layer*, *convolution layer* 5 × 5 sebanyak 1 *layer*, dan *pooling* 3 × 3 yang ditambahkan bersamaan dengan susunan seperti pada Gambar 2.18 (Zmudzinski, 2018).



Gambar 2.18 Inception modules

#### 2.8. Confusion Matrix

Confusion matrix adalah alat evaluasi visual yang digunakan dalam sistem klasifikasi (Xu et al., 2020). Confusion matrix ini berguna untuk mengukur seberapa baik model klasifikasi yang telah dibuat (Deng et al., 2016). Confusion

matrix berukuran  $n \times n$ , dimana n merupakan jumlah kelas yang berbeda (Visa et al., 2011). Confusion matrix menentukan akurasi yang didapat dari nilai beberapa parameter, seperti  $True\ Positif\ (TP)$ ,  $False\ Positif\ (FP)$ ,  $True\ Negatif\ (TN)$ , dan  $False\ Negatif\ (FN)$  (Foeady et al., 2019). Tabel  $confusion\ matrix$  ditunjukkan pada Tabel 2.1.

Tabel 2.1 Confusion matrix

K I GI	Kelas Hasil Klasifikasi					
Kelas Sebenarnya	Malignant	Benign				
Malignant	True Positif(TP)	False Negatif(FN)				
Benign	False Positif(FP)	True Negatif(TN)				

- 1. True Positif (TP) merupakan jumlah pasien malignant yang terklasifikasi benar sebagai malignant oleh sistem klasifikasi.
- 2. *False Positif* (FP) merupakan jumlah pasien *benign* yang terklasifikasi salah sebagai *malignant* oleh sistem klasifikasi.
- 3. *False Negative* (FN) merupakan jumlah pasien *malignant* yang terklasifikasi salah sebagai *benign* oleh sistem klasifikasi.
- 4. *True Negatif* (TP) merupakan jumlah pasien *malignant* yang terklasifikasi benar sebagai *malignant* oleh sistem klasifikasi.

Berdasarkan nilai-nilai *True Positif* (TP), *False Positif* (FP), *True Negatif* (TN), dan *False Negatif* (FN), evaluasi klasifikasi dianalisis dari beberapa indikator seperti akurasi, sensitivitas, dan spesifisitas (Ruuska et al., 2018). Akurasi merupakan rasio antara jumlah terprediksi benar dari semua data (Chicco and Jurman, 2020). Sensitivitas merupakan nilai yang menunjukkan banyak data yang

terklasifikasi benar sebagai kelas *malignant*, sedangkan spesifisitas merupakan nilai yang menunjukkan banyak data yang terklasifikasi benar sebagai kelas *benign* (Kavitha et al., 2017). Masing-masing indikator dihitung dengan Persamaan 2.11, 2.12, 2.13.

$$Akurasi = \frac{TP + TN}{TP + TN + FP + FN}$$
 (2.11)

$$Sensitivitas = \frac{TP}{TP + FN} \tag{2.12}$$

$$Spesifisitas = \frac{TN}{TN + FP} \tag{2.13}$$

# 2.9. Penyakit dalam Islam

#### 2.9.1. Allah Menciptakan Penyakit untuk Manusia

Manusia hidup di dunia selalu dihadapkan dengan dua kondisi yang berlawanan seperti, hidup dan mati, suka dan duka. Allah SWT menciptakan kondisi-kondisi tersebut berdasarkan berbagai kejadian yang menimpa umat manusia sebagai bentuk ujian. Ujian yang diturunkan menjadi tolak ukur tingkat keimanan manusia kepada Allah SWT (Mu'allim, 2016). Hal ini tertulis pada Al-Qur'an surat Al-Mulk ayat 2 yang berbunyi:

Artinya: "Yang menjadikan mati dan hidup, supaya Dia menguji kamu, siapa di antara kamu yang lebih baik amalnya. Dan Dia Maha Perkasa lagi Maha

Pengampun,"

Allah menurunkan ujian kepada hamba-Nya dengan dua bentuk yaitu ujian berupa kesenangan atau ni'mat dan ujian berupa kesengsaraan atau niqmat. Penyakit merupakan salah satu bentuk ujian berupa kesengsaraan dari Allah SWT yang tidak dapat dihindari oleh siapapun (Kaltsum, 2018). Penyakit memiliki jenis yang bermacam-macam seperti penyakit menular, penyakit tidak menular, penyakit keturunan, penyakit musiman, dan lain-lain. Dalam islam, penyakit yang diturunkan Allah SWT kepada hamba-Nya dapat menjadi pengampunan atau pengguguran dosa, seperti yang tertulis pada sabda Rasulullah SAW "Tidaklah seorang muslim tertimpa suatu penyakit dan sejenisnya, melainkan Allah akan mengugurkan bersamanya dosa-dosanya seperti pohon yang mengugurkan daun-daunnya". (HR. Bukhari no. 5660 dan Muslim no. 2571) (Estria and Trihadi, 2019). Allah SWT telah menjamin bahwa setiap penyakit yang diturunkan-Nya memiliki penawar (Rahman et al., 2019). Sebagaimana yang tertulis pada hadist shahih riwayat Imam Bukhari, Rasulullah Shallallahu'Allahi wa Sallam bersabda:

Artinya: "Tidaklah Allah menurunkan penyakit kecuali Dia juga menurunkan penawarnya." (HR Bukhari).

Hal ini diperkuat dengan surat Asy-Syu'ara' ayat 80 yang berbunyi:

Artinya: "Dan apabila aku sakit, Dialah yang menyembuhkan aku."

#### 2.9.2. Kewajiban Orang Sakit

Allah SWT telah menjajikan kesembuhan dari penyakit yang diturunkan-Nya, namun Allah SWT tidak akan merubah nasib seseorang jika seseorang itu tidak berusaha atau berikhtiar merubah nasibnya sendiri. Hal tersebut telah tertulis pada Al-Qur'an surat Ar-Ra'd ayat 11 yang berbunyi:

Artinya: "Bagi manusia ada malaikat-malaikat yang selalu mengikutinya bergiliran, di muka dan di belakangnya, mereka menjaganya atas perintah Allah. Sesungguhnya Allah tidak merubah keadaan sesuatu kaum sehingga mereka merubah keadaan yang ada pada diri mereka sendiri. Dan apabila Allah menghendaki keburukan terhadap sesuatu kaum, maka tak ada yang dapat menolaknya; dan sekali-kali tak ada pelindung bagi mereka selain Dia."

Berdasarkan surat Ar-Ra'd ayat 11, kesembuhan yang dijanjikan oleh Allah SWT dapat terjadi apabila seseorang terebut berikhtiar untuk kesembuhannya sendiri. Salah satu bentuk ikhtiar yang dapat dilakukan untuk kesembuhan penyakit kanker kulit adalah deteksi dini kemunculan kanker kulit. Dengan mengetahui sejak dini kemunculan kanker kulit, penanganan pasien dapat dilakukan dengan lebih cepat dan tepat sehingga dapat meningkatkan peluang kesembuhan penderita kanker kulit. Selain berikhtiar demi sembuh akan penyakit,

salah satu anjuran Al-Qur'an dalam menghadapi penyakit yaitu bersabar. Anjuran bersabar dalam menghadapi penyakit sesuai dengan hadits riwayat Imam Muslim berbunyi:

Artinya: "Sungguh mengagumkan perkara seorang mukmin, sesungguhnya seluruhnya seluruh urusannya adalah baik dan hal itu tidak dimiliki kecuali seorang yang beriman: jika ia mendapatkan kebaikan ia bersyukur, maka itu baik baginya. Dan jika ia mendapatkan musibah ia bersabar dan itu pun baik baginya." (HR. Muslim).

# 2.9.3. Balasan Bagi Orang yang Sabar

Allah SWT memberikan ujian kepada hamba-Nya dalam berbagai bentuk seperti bencana alam, kematian, kesengsaraan, dan sakit yang dapat. Kemampuan kesabaran manusia dalam menghadapi ujian yang diberikan Allah SWT dapat meningkatkan keimanan manusia. Sebagai umat muslim yang beriman sehendaknya selalu bersabar dan berkhusnudzon kepada Allah SWT dalam menghadapi ujian, karena sesungguhnya Allah SWT selalu bersama orang-orang yang sabar sebagaimana tertulis pada surat Al-Qur'an ayat 153.

Artinya: "Hai orang-orang yang beriman, jadikanlah sabar dan shalat

sebagai penolongmu, sesungguhnya Allah beserta orang-orang yang sabar."

Bersabar dan berkhusnudzon dapat dilakukan dengan mengikhlaskan apapun yang terjadi dan memahami bahwa yang diciptakan oleh Allah SWT akan kembali kepada-Nya. Allah SWT menganjurkan untuk mengucapkan *inalillahi wa inna ilaihi raji'un* sebagaimana yang tertulis pada Surat Al-Baqarah ayat 156 yang berbunyi:

Artinya: "(yaitu) orang-orang yang apabila ditimpa musibah, mereka mengucapkan: 'Inna lillaahi wa innaa ilaihi raaji'uun'."

# **BAB III**

#### METODE PENELITIAN

### 3.1. Jenis Penelitian

Penelitian deteksi dini kanker kulit menggunakan *Convolutional Neural Network* (CNN) jenis GoogleNet berdasarkan klasifikasi data citra. Penelitian ini termasuk jenis penelitian kuantitatif karena didasarkan pada data yang digunakan. Pada penelitian ini menggunakan data numerik yang berisi nilai-nilai piksel dari data citra. Hasil dari penelitian ini adalah sistem klasifikasi citra kanker kulit menggunakan alggoritma CNN jenis GoogleNet yang diharapkan dapat membantu ahli medis dalam mendiagnosis kanker kulit secara cepat dan tepat.

# 3.2. Pengumpulan Data

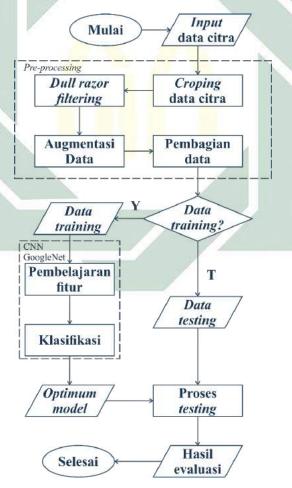
Penelitian ini menggunakan data citra kanker kulit sebagai data *input*. Data tersebut diperoleh dari *International Skin Imaging Collaboration Archive* sebanyak 204 data yang terbagi menjadi dua kelas yaitu *benign* (non-kanker) dan *malignant* (kanker) dengan jumlah masing-masing 102 data pada setiap kelas. Data tersebut diaugmentasi menjadi 1020 data pada masing-masing kelas yang selanjutnya diklasifikasi untuk mendeteksi adanya kanker kulit secara otomatis dengan cepat dan tepat. Sampel data citra *benign* (non-kanker) dan *malignant* (kanker) ditunjukkan pada Gambar 3.1.



Gambar 3.1 Sampel data citra malignant dan benign

# 3.3. Kerangka Penelitian

Secara umum diagram alir pada Gambar 3.2, merupakan proses yang dilakukan untuk deteksi dini kanker kulit otomatis menggunakan CNN GoogleNet berdasarkan klasifikasi data citra dijelaskan sebagai berikut:



Gambar 3.2 Diagram alir penelitian

Input data merupakan data citra kanker kulit diperoleh dari International Skin
 Imaging Collaboration Archive. Data berisi data citra benign (non-kanker)
 dan malignant (kanker).

# 2. Pre-processing

Pre-processing merupakan langkah awal pengelolahan data yang dilakukan dengan tujuan mendapatkan data yang optimal. Langkah-langkah pre-processing data citra dilakukan sesuai dengan diagram alir pada Gambar

3.3 Input Mulai data citra Dull razor filtering Identifikasi Croping data citra piksel rambut Mengganti piksel rambut dengan piksel terdekat Augmentasi data citra Rotasi Refleksi Data citra/ baru Selesai

Gambar 3.3 Diagram alir pre-processing data citra

Langkah-langkah *pre-processing* data dijelaskan sebagai berikut:

a. Melakukan croping area lesi kulit pada data citra dari ukuran citra  $400 \times$ 

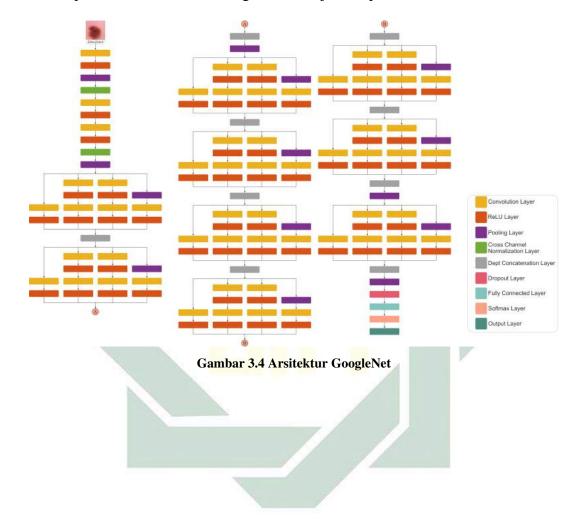
600 menjadi citra dengan ukuran  $400 \times 400$ . Proses *croping* dilakukan secara manual. Selanjutnya citra di *resize* berukuran  $224 \times 224 \times 3$  sesuai ketentuan pada arsitektur GoogleNet secara otomatis.

- **b.** Mengidentifikasi piksel rambut yang menutupi area kulit pada data citra.
- c. Mengganti piksel rambut dengan piksel terdekat untuk menghilangkan rambut pada data citra.
- **d.** Augmentasi data dilakukan dengan rotasi dan refleksi data citra. Data citra dirotasi sebesar  $15^{\circ}$ ,  $30^{\circ}$ ,  $45^{\circ}$ ,  $60^{\circ}$ ,  $75^{\circ}$ ,  $90^{\circ}$  dan  $105^{\circ}$ . Data citra direfleksikan terhadap sumbu x dan y.

#### 3. Pembelajaran fitur dan klasifikasi CNN GoogleNet

Proses pembelajaran fitur dan klasifikasi dilakukan dalam satu arsitektur. Arsitektur yang digunakan pada penelitian ini adalah CNN GoogleNet, dimana dalam arsitektur GoogleNet terdiri dari beberapa layer. Layer-layer tersebut antara lain convolution layer, ReLU layer, pooling layer, dan fully connected layer. Fitur-fitur data citra dipelajari dengan convolution layer, ReLU layer, dan pooling layer. Hasil dari proses pembelajaran fitur data citra diklasifikasi pada fully connected layer dengan penentuan kelas berdasarkan probabilitas kelas tertinggi pada softmax layer. Proses pembelajaran sistem klasifikasi menghasilkan model optimum yang selanjutnya diuji pada proses testing. Pada penelitian ini dilakukan uji coba pembagian data, inisialisasi probabilitas dropout layer, dan batchsize untuk mendapatkan nilai optimal. Uji coba dilakukan dengan menggunakan data training 60%, 70%, 80%, dan 90%. Percobaan inisialisasi probabilitas dropout yaitu 0.4, 0.5, 0.6, dan 0.7 dengan nilai batchsize 8, 16, 32, dan 64. Masing-masing percobaan dilakukan menggunakan data yang telah di

augmentasi dan data tanpa di augmentasi. Model optimum yang dihasilkan di evaluasi menggunakan beberapa indikator seperti akurasi, sensitivitas, dan spesifisitas. Arsitektur GoogleNet ditunjukkan pada Gambar 3.4.

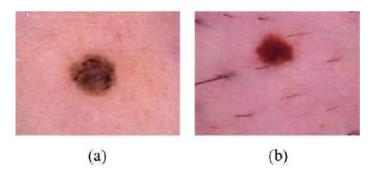


# **BAB IV**

# HASIL DAN PEMBAHASAN

# 4.1. Deskripsi Data

Sebagaimana yang telah dipaparkan pada bab 3, deteksi kanker kulit secara automatis berdasarkan klasifikasi data citra dilakukan dengan mengimplementasikan arsitektur GoogleNet pada algoritma CNN. Data yang digunakan pada penelitian ini merupakan data citra kanker kulit diperoleh dari International Skin Imaging Collaboration Archive. Data citra kanker kulit sebanyak 204 data yang terbagi menjadi dua kelas yaitu benign (non-kanker) dan malignant (kanker) dengan jumlah masing-masing 102 data pada setiap kelas. Sampel data citra benign (non-kanker) dan malignant (kanker) ditunjukkan pada Gambar 4.1 dan Gambar 4.1

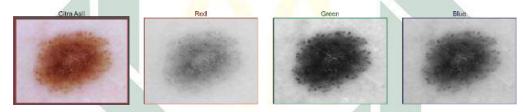


Gambar 4.1 (a) dan (b) Sampel data citra benign (non-kanker)



Gambar 4.2 (a) dan (b) Sampel data citra benign (non-kanker)

Inputan data citra kanker kulit yang pada penelitian ini merupakan tipe data citra RGB dengan ukuran 400x600 dimana satu data citra memiliki tiga lapisan warna yaitu merah (R), hijau (G), dan biru (B). Data citra masing-masing lapisan ditunjukkan pada Gambar 4.3



Gambar 4.3 Lapisan citra RGB

Masing-masing lapisan memiliki nilai piksel dengan derajat keabuan pada range 0 sampai 225. Nilai piksel lapisan R, G, dan B ditunjukkan pada Gambar 4.4, Gambar 4.5, Gambar 4.6

	1	2	3	4	5		597	598	599	600
1	214	213	215	213	213		215	215	214	216
2	212	212	215	217	215		210	210	211	211
3	211	213	214	215	215		210	210	213	211
4	213	215	215	215	213		213	211	215	214
5	214	215	215	214	215		215	210	213	214
:	:	:	1	:	:	٠.	:	:	:	:
397	211	211	208	210	213		217	218	215	216
398	210	211	211	211	209	***	214	218	217	220
399	213	212	210	210	209		214	214	215	215
400	214	210	212	211	209	•••	217	216	214	215

Gambar 4.4 Nilai piksel pada lapisan Red

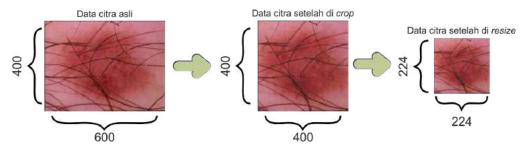
	1	2	3	4	5	•••	597	598	599	600
1	202	201	203	203	203		202	203	203	204
2	200	200	203	205	206		198	198	199	199
3	199	201	202	203	206	•••	196	198	200	198
4	202	204	203	203	204	•••	202	200	204	203
5	203	204	203	202	203	•••	202	197	200	203
:	:	:		:	1	100	1		:	
397	193	192	194	198	196	•••	217	218	215	216
398	192	192	194	197	195	•••	214	218	217	220
399	195	193	195	197	194		214	214	215	215
400	193	193	195	197	195	•••	217	216	214	215

Gambar 4.5 Nilai piksel pada lapisan Green

		7.1		1						
	1	2	3	4	5	•••	597	598	599	600
1	222	223	227	228	228	•••	219	217	217	218
2	222	220	223	227	227	•••	210	210	211	209
3	219	221	224	227	227	•••	209	208	210	208
4	218	221	223	225	225		210	208	210	211
5	220	221	223	224	227	•••	211	207	209	211
:	:	÷	:	i	:	٠.	:	i	:	i
397	209	211	209	212	212	•••	212	213	212	213
398	208	211	212	214	212		208	213	214	215
399	211	212	214	215	213		209	211	212	213
400	210	211	213	214	212		211	211	211	212

Gambar 4.6 Nilai piksel pada lapisan Blue

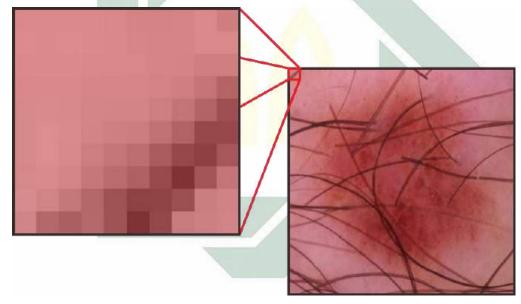
Data citra kanker kulit berukuran  $400 \times 600 \times 3$  di crop dengan ukuran ordo yang sama yaitu  $400 \times 400 \times 3$ . Ukuran data citra yang diperlukan dalam arsitektur GoogleNet ditentukan dengan  $224 \times 224 \times 3$ . Sehingga data citra kanker kulit pada dataset yang berukuran  $400 \times 400 \times 3$  di resize menjadi data citra dengan ukuran  $224 \times 224 \times 3$ . Perubahan data citra awal hingga data citra baru yang telah di resize ditunjukkan pada Gambar 4.7.



Gambar 4.7 Proses croping dan resize data citra

# 4.2. Dull Razor Filtering

Data citra kanker kulit tidak hanya menampilkan area kulit yang dicurigai sebagai kanker, namun terkadang juga memiliki citra rambut yang dapat mempengaruhi kinerja sistem klasifikasi. Hal tersebut dapat diatasi dengan menghilangkan piksel rambut pada data citra kanker kulit. Piksel rambut pada data citra kanker kulit dapat dihilangkan dengan mengaplikasikan algoritma  $dull\ razor$  filtering. Sebagai contoh pengaplikasian algoritma  $dull\ razor\ filtering$  pada sampel ukuran  $10\times 10$  yang diambil dari bagian citra kanker kulit yang ditunjukkan pada Gambar 4.8



Gambar 4.8 Sample data citra dermoscopic

Sampel tersebut menghasilkan 3 matriks berukuran  $10 \times 10$  yang terdiri dari lapisan R, G, dan B dan berisi nilai piksel dengan derajat keabuan pada range 0 sampai 225. Nilai piksel dari masing-masing lapisan data sampel ditunjukkan pada Gambar 4.9, Gambar 4.10, dan Gambar 4.10

218	218	218	219	216	212	211	213	219	207
220	219	220	219	217	214	213	213	218	218
219	219	219	217	216	215	213	212	207	207
216	217	217	214	214	214	211	207	197	181
214	217	216	212	211	211	205	196	179	158
216	220	218	211	207	204	192	178	150	150
216	220	216	205	197	189	171	151	143	166
214	217	212	198	187	175	153	129	164	196
216	208	196	180	158	142	144	156	202	207
209	180	172	181	159	127	148	200	204	208

# Gambar 4.9 Lapisan R pada data sampel

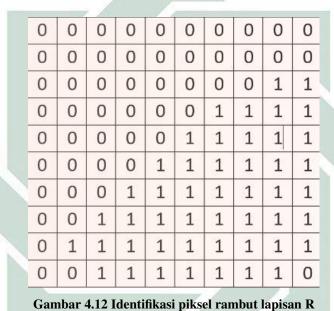
			60						
138	138	138	139	136	132	131	133	139	127
140	139	140	139	137	134	133	133	138	138
139	139	139	137	136	135	133	132	127	127
136	137	137	134	134	134	131	127	117	101
136	139	138	134	133	133	127	118	101	80
138	142	140	133	129	126	114	100	72	72
138	142	138	127	119	111	93	73	65	88
136	139	134	120	109	97	75	51	86	118
140	132	120	104	82	66	68	80	126	131
133	104	96	105	83	51	72	124	128	132

Gambar 4.10 Lapisan G pada data sampel

137	137	137	138	135	131	130	132	138	126
139	138	139	138	136	133	132	132	137	137
138	138	138	136	135	134	132	131	126	126
135	136	136	133	133	133	130	126	116	100
136	139	138	134	133	133	127	118	101	80
138	142	140	133	129	126	114	100	72	72
138	142	138	127	119	111	93	73	65	88
136	139	134	120	109	97	75	51	86	118
142	134	122	106	84	68	70	82	128	133
135	106	98	107	85	53	74	126	130	134

Gambar 4.11 Lapisan B pada data sampel

Berdasarkan langkah-langkah yang telah dipaparkan di bab 2, langkah pertama adalah mengidentifikasi piksel rambut pada masing-masing lapisan. Untuk mendeteksi piksel rambut pada masing-masing lapisan warna menggunakan bottom hat filtering. Berdasarkan hasil bottom hat filtering dibentuk matriks biner dengan nilai piksel hasil yang berbeda dengan nilai sekitarnya diisi dengan angka 1, sedangkan yang lain berisi angka 0, seperti pada Gambar 4.12, Gambar 4.13, dan Gambar 4.14



Gambar 4.13 Identifikasi piksel rambut lapisan G

0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	1	1
0	0	0	0	0	0	0	1	1	1
0	0	0	0	0	0	1	1	1	1
0	0	0	0	0	1	1	1	1	1
0	0	0	0	1	1	1	1	1	1
0	0	0	1	1	1	1	1	1	1
0	0	1	1	1	1	1	1	1	1
0	1	1	1	1	1	1	1	1	1
0	0	1	1	1	1	1	1	1	0

Gambar 4.14 Identifikasi piksel rambut lapisan B

Nilai 1 pada matriks biner menunjukkan posisi piksel yang teridentifikasi sebagai piksel rambut. Setelah diketahui posisi piksel yang teridentifikasi piksel rambut, selanjutnya mengganti piksel rambut dengan algoritma ROI dimana matriks biner pada proses sebelumnya digunakan sebagai *mask*. Nilai piksel hasil akhir masing-masing lapisan warna dari pengaplikasian algoritma *dull razor filtering* ditunjukan pada Gambar 4.15, Gambar 4.16, dan Gambar 4.17

218	218	218	219	216	212	211	213	219	207
220	219	220	219	217	214	213	213	218	218
219	219	219	217	216	215	213	212	207	207
216	217	217	214	214	214	211	207	194	181
214	217	216	212	211	211	203	194	180	158
216	220	218	211	207	201	195	187	174	150
216	220	216	205	198	192	188	185	179	166
214	217	212	198	188	181	181	186	189	196
216	208	195	187	174	163	170	188	197	207
209	180	172	181	159	127	148	200	204	208

Gambar 4.15 Matriks hasil akhir lapisan R

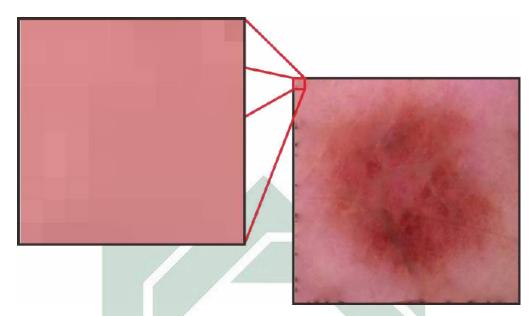
138	138	138	139	136	132	131	133	139	127
140	139	140	139	137	134	133	133	138	138
139	139	139	137	136	135	133	132	127	127
136	137	137	134	134	134	131	127	114	101
136	139	138	134	133	133	124	115	101	80
138	142	140	133	129	123	117	109	96	72
138	142	138	127	120	115	111	107	101	88
136	139	134	120	111	104	104	109	112	118
140	132	118	110	98	87	94	112	121	131
133	104	96	105	83	51	72	124	128	132

Gambar 4.16 Matriks hasil akhir lapisan G

	137	137	137	138	135	131	130	132	138	126
	139	138	139	138	136	133	132	132	137	137
į	138	138	138	136	135	134	132	131	127	126
9	135	136	136	133	133	133	130	122	112	100
	136	139	138	134	133	133	123	113	100	80
	138	142	140	133	129	123	116	108	95	72
	138	142	138	127	121	115	111	107	101	88
	136	139	134	121	111	105	105	110	113	118
	142	134	119	112	99	88	95	113	122	133
	135	106	98	107	85	53	74	126	130	134

Gambar 4.17 Matriks hasil akhir lapisan B

Ketiga lapisan hasil akhir tersebut selanjutnya digabungkan sehingga menjadi citra seperti pada Gambar 4.18



Gambar 4.18 Hasil akhir dari proses dull razor filtering

# 4.3. Augmentasi Data

Metode augmentasi data memperbanyak variansi data citra dengan memodifikasi data citra asli. Pada penelitian ini metode augmentasi yang digunakan yaitu rotasi dan refleksi. Rotasi dan refleksi data citra memodifikasi data citra asli dengan merubah posisi nilai piksel menggunakan Persamaan 2.3 sampai Persamaan 2.5. Data citra asli dirotasi sebesar 15°, 30°, 45°, 60°, 75°, 90° dan 105°, dan direfleksi terhadap sumbu x dan sumbu y. Sebagai contoh rotasi dan refleksi data citra dilakukan pada lapisan Blue (B) Gambar 4.18 dengan nilai piksel seperti pada Gambar 4.17.

#### 4.3.1. Rotasi

Perputaran posisi nilai-nilai piksel pada data citra awal sebesar 90° terhadap sudut dan titik pusat rotasi. Rotasi dilakukan dengan menggunakan Persamaan 2.2 dengan contoh perhitungan sebagai berikut:

$$(x,y) \Rightarrow \begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} \cos 90^{\circ} & -\sin 90^{\circ} \\ \sin 90^{\circ} & \cos 90^{\circ} \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix}$$

$$(1,1) \Rightarrow \begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$

$$(1,2) \Rightarrow \begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \end{bmatrix} = \begin{bmatrix} -2 \\ 1 \end{bmatrix}$$

$$(1,3) \Rightarrow \begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ 3 \end{bmatrix} = \begin{bmatrix} -3 \\ 1 \end{bmatrix}$$

$$(1,8) \Rightarrow \begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ 8 \end{bmatrix} = \begin{bmatrix} -8 \\ 1 \end{bmatrix}$$

$$(1,9) \Rightarrow \begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ 9 \end{bmatrix} = \begin{bmatrix} -9 \\ 1 \end{bmatrix}$$

$$(1,10) \Rightarrow \begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} -10 \\ 1 \end{bmatrix}$$

Nilai negatif pada hasil perhitungan merepresentasikan posisi sebaliknya dari posisi awal. Apabila hasil perhitungan dengan (x,y)sama nilai (-1,1), (-2,1), (-3,1), maka posisi dari piksel baru adalah  $(n,1),(n-1,1),(n-2,1),\;$ dimana n merupakan ukuran matriks, sehingga posisi (-1,1), (-2,1), (-3,1), (-8,1), (-9,1), (-10,1)baru adalah (10,1), (9,1), (8,1), (3,1), (2,1), (1,1). Rotasi 90° pada lapisan Blue (B) Gambar 4.18 dengan nilai piksel seperti pada Gambar 4.17 diilustrasikan pada Gambar 4.19

|             |   |  |   |   |   |   
  |   |   |  
   | 137   
   
   | 13  | 37   1  | .37   | 138   | 135   | 131  | 130  
   | 13   | 2 1  
  | 38  | 126   |
|-------------|---|--|---|---|---
--
--|---|---
--
--
--
---|---|---|---|---|---
--
--|--
---|---|---|
| 126         | 137   | 133  | 132   | 132   | 132   | 133   
  | 133   | 134   | 134  
   | V   
   
   | 137   | 137   | 137   | 138   | 135   | 131  | 130  
   | 132  | 138  
  | 126   | V   |
| 138         | 137   | 133  | 132   | 132   | 132   | 133   
  | 133   | 133   | 133  
   |   
   
   | 139   | 138   | 139   | 138   | 136   | 133  | 132  
   | 132  | 137  
  | 137   |   |
| 132         | 132   | 131  | 131   | 132   | 132   | 133   
  | 133   | 133   | 133  
   |   
   
   | 138   | 138   | 138   | 136   | 135   | 134  | 132  
   | 131  | 133  
  | 133   |   |
| 130         | 132   | 132  | 130   | 132   | 132   | 133   
  | 133   | 133   | 132  
   |   
   
   | 135   | 136   | 136   | 133   | 133   | 133  | 130  
   | 131  | 132  
  | 132   |   |
| 131         | 133   | 134  | 133   | 133   | 133   | 133   
  | 133   | 132   | 132  
   |   
   
   | 136   | 139   | 138   | 134   | 133   | 133  | 132  
   | 132  | 132  
  | 132   |   |
| 135         | 136   | 135  | 133   | 133   | 133   | 133   
  | 133   | 132   | 131  
   |   
   
   | 138   | 142   | 140   | 133   | 133   | 133  | 132  
   | 132  | 132  
  | 132   |   |
| 138         | 138   | 136  | 133   | 134   | 133   | 135   
  | 134   | 133   | 130  
   |   
   
   | 138   | 142   | 138   | 135   | 133   | 133  | 133  
   | 133  | 133  
  | 133   |   |
| 137         | 139   | 138  | 136   | 138   | 140   | 138   
  | 136   | 134   | 129  
   |   
   
   | 136   | 139   | 136   | 134   | 133   | 133  | 133  
   | 133  | 133  
  | 133   |   |
| 137         | 138   | 138  | 136   | 139   | 142   | 142   
  | 139   | 136   | 130  
   |   
   
   | 142   | 136   | 134   | 133   | 132   | 132  | 133  
   | 133  | 133  
  | 134   |   |
| 137         | 139   | 138  | 135   | 135   | 138   | 138   
  | 136   | 142   | 135  
   |   
   
   | 135   | 130   | 129   | 130   | 131   | 132  | 132  
   | 133  | 133  
  | 134   |   |
| 1 1 1 1 1 1 | 138<br>132<br>130<br>131<br>135<br>138<br>137 | 138 137<br>132 132<br>130 132<br>131 133<br>135 136<br>138 138<br>137 139<br>137 138 | 138     137     133       132     132     131       130     132     132       131     133     134       135     136     135       138     138     136       137     139     138       137     138     138 | 138     137     133     132       132     132     131     131       130     132     132     130       131     133     134     133       135     136     135     133       138     138     136     133       137     139     138     136       137     138     138     136 | 138     137     133     132     132       132     132     131     131     132       130     132     132     130     132       131     132     130     132     130     132       131     133     134     133     133       135     136     135     133     133       138     136     135     133     134       137     139     138     136     138       137     138     136     139 | 138         137         133         132         132         132         132         132         132         132         132         132         132         132         132         132         132         132         132         132         132         132         133         133         133         133         133         133         133         133         133         133         133         133         133         133         133         133         133         133         133         134         133         134         133         134         133         134         133         134 <td>138         137         133         132         132         132         133           132         132         131         131         132         132         133           130         132         132         130         132         132         133           131         133         134         133         133         133         133           135         136         135         133         133         133         133           138         138         136         133         134         133         135           137         139         138         136         138         140         138           137         138         136         139         142         142</td> <td>138         137         133         132         132         132         133         133           132         132         131         131         132         132         133         133           130         132         132         130         132         132         133         133           131         133         134         133         133         133         133         133           135         136         135         133         133         133         133         133           138         136         135         134         133         135         134           137         139         138         136         138         140         138         136           137         138         138         136         139         142         142         139</td> <td>138         137         133         132         132         132         133         132         132         133         133         133         133         133         133         133         133         132         132         133         132         133         133         133         133         133         133         133         133         132         133<td>138         137         133         132         132         132         133         132         133         133         133         133         133         133         133         133         133         133         133         133         133         134         133<td>138     137     133     132     132     132     133     133     133     133       132     132     131     131     132     132     133     133     133       130     132     132     132     133     133     133     133       131     133     134     133     133     133     133     132     132       131     133     134     133     133     133     133     132     132       135     136     135     133     133     133     133     132     131       138     136     133     134     133     135     134     133     130       137     139     138     136     136     139     142     142     139     136     130</td><td>138     137     133     132     132     132     133     133     133     133     133       132     132     131     132     132     133     133     133     133       130     132     131     132     132     133     133     133     133       130     132     132     132     132     133     133     133     132     135       131     133     134     133     133     133     133     132     132     136       135     136     135     133     133     133     133     133     132     131     138       138     136     135     134     133     135     134     133     130     138       137     139     136     136     139     140     138     136     130     130       137     138     138     136     139     142     142     139     136     130</td><td>138     137     133     132     132     132     133     133     133     133     138     138     138       132     132     131     131     132     132     133     133     133     133     138     138       130     132     132     132     132     133     133     133     132     135     136       131     133     134     133     133     133     133     132     132     132     136     139       135     136     135     133     133     133     133     132     131     138     142       138     136     135     134     133     133     133     132     131     138     142       138     136     135     134     133     135     134     133     130     138     142       137     139     136     136     134     136     134     129     136     139       137     138     138     136     134     139     136     130     142     136</td><td>138     137     133     132     132     132     133     133     133     133     138     136     136     136     136     136     136     136     136     139     138     142     140       137     138     138     136     133     133     133     133     130     138     142     140       137     138     138     136     139     142     142     139     136     130     142     136     134</td><td>138     137     133     132     132     132     133     133     133     133     133     139     138     139     138     139     138     139     138     136     136     133     133     133     133     132     132     132     136     139     138     134     133     133     133     133     132     131     138     142     140     133       138     136     133     133     133     133     133     132     131     138     142     140     133       138     136     133     133     133     133     133     133     132     131     138     142     140     133       138     136     133     133     133     133     133     133     133     133     133     134     133     134     133     133     133     133</td><td>138     137     133     132     132     132     132     133     133     133     133     134     139     138    
138     138<td>138     137     133     132     132     132     133     133     133     133     133     138     138     138     138     138     136     133     136     132     132     131     132     132     132     133     133     133     133     133     138     138     138     136     135     136     135     136     135     136     135     136     135     136     133     133     133     133     133     133     133     132     136     136     136     133     133     133     133     132     132     136     136     133     133     133     133     132     132     136     136     133     133     133     133     132     136     136     133     133     133     133     132     131     136     136     133     133     133     133     132     131     138     142     140     133<td>138     137     133     132     132     132     132     133<td>138     137     133     132     132     132     133<td>138       137       133       132       132       132       133       1</td><td>138       137       133       132       132       132       133       1</td></td></td></td></td></td></td> | 138         137         133         132         132         132         133           132         132         131         131         132         132         133           130         132         132         130         132         132         133           131         133         134         133         133         133         133           135         136         135         133         133         133         133           138         138         136         133         134         133         135           137         139         138         136         138         140         138           137         138         136         139         142         142 | 138         137         133         132         132         132         133         133           132         132         131         131         132         132         133         133           130         132         132         130         132         132         133         133           131         133         134         133         133         133         133         133           135         136         135         133         133         133         133         133           138         136         135         134         133         135         134           137         139         138         136         138         140         138         136           137         138         138         136         139         142         142         139 | 138         137         133         132         132         132         133         132         132         133         133         133         133         133         133         133         133         132         132         133         132         133         133         133         133         133         133         133         133         132         133 <td>138         137         133         132         132         132         133         132         133         133         133         133         133         133         133         133         133         133         133         133         133         134         133<td>138     137     133     132     132     132     133     133     133     133       132     132     131     131     132     132     133     133     133       130     132     132     132     133     133     133     133       131     133     134     133     133     133     133     132     132       131     133     134     133     133     133     133     132     132       135     136     135     133     133     133     133     132     131       138     136     133     134     133     135     134     133     130       137     139     138     136  
  136     139     142     142     139     136     130</td><td>138     137     133     132     132     132     133     133     133     133     133       132     132     131     132     132     133     133     133     133       130     132     131     132     132     133     133     133     133       130     132     132     132     132     133     133     133     132     135       131     133     134     133     133     133     133     132     132     136       135     136     135     133     133     133     133     133     132     131     138       138     136     135     134     133     135     134     133     130     138       137     139     136     136     139     140     138     136     130     130       137     138     138     136     139     142     142     139     136     130</td><td>138     137     133     132     132     132     133     133     133     133     138     138     138       132     132     131     131     132     132     133     133     133     133     138     138       130     132     132     132     132     133     133     133     132     135     136       131     133     134     133     133     133     133     132     132     132     136     139       135     136     135     133     133     133     133     132     131     138     142       138     136     135     134     133     133     133     132     131     138     142       138     136     135     134     133     135     134     133     130     138     142       137     139     136     136     134     136     134     129     136     139       137     138     138     136     134     139     136     130     142     136</td><td>138     137     133     132     132     132     133     133     133     133     138     136     136     136     136     136     136     136     136     139     138     142     140       137     138     138     136     133     133     133     133     130     138     142     140       137     138     138     136     139     142     142     139     136     130     142     136     134</td><td>138     137     133     132     132     132     133     133     133     133     133     139     138     139     138     139     138     139     138     136     136     133     133     133     133     132     132     132     136     139     138     134     133     133     133     133     132     131     138     142     140     133       138     136     133     133     133     133     133     132     131     138     142     140     133       138     136     133     133     133     133     133     133     132     131     138     142     140     133       138     136     133     133     133     133     133     133     133     133     133     134     133     134     133     133     133     133</td><td>138     137     133     132     132     132     132     133     133     133     133     134     139     138<td>138     137     133     132     132     132     133     133     133     133     133     138     138     138     138     138     136     133     136     132     132     131     132     132     132     133     133     133     133     133     138     138     138     136     135     136     135     136     135     136     135     136     135     136     133     133     133     133     133     133     133     132     136     136     136     133     133     133     133     132     132     136     136     133     133     133     133     132     132     136     136     133     133     133     133     132     136     136     133     133     133     133     132     131     136     136     133     133     133     133     132     131     138     142     140     133<td>138     137     133     132     132     132     132     133<td>138     137     133     132     132     132     133<td>138       137       133       132       132       132       133       1</td><td>138       137       133       132       132       132       133       1</td></td></td></td></td></td> | 138         137         133         132         132         132         133         132    
    132         132         132         132         132         132         132         132         132         132         132         132         132         132         132         132         132         133         133         133         133         133         133         133         133         133         133         133         133         133         134         133 <td>138     137     133     132     132     132     133     133     133     133       132     132     131     131     132     132     133     133     133       130     132     132     132     133     133     133     133       131     133     134     133     133     133     133     132     132       131     133     134     133     133     133     133     132     132       135     136     135     133     133     133     133     132     131       138     136     133     134     133     135     134     133     130       137     139     138     136     136     139     142     142     139     136     130</td> <td>138     137     133     132     132     132     133     133     133     133     133       132     132     131     132     132     133     133     133     133       130     132     131     132     132     133     133     133     133       130     132     132     132     132     133     133     133     132     135       131     133     134     133     133     133     133     132     132     136       135     136     135     133     133     133     133     133     132     131     138       138     136     135     134     133     135     134     133     130     138       137     139     136     136     139     140     138     136     130     130       137     138     138     136     139     142     142     139     136     130</td> <td>138     137     133     132     132     132     133     133     133     133     138     138     138       132     132     131     131     132     132     133     133     133     133     138     138       130     132     132     132     132     133     133     133     132     135     136       131     133     134     133     133     133     133     132     132     132     136     139       135     136     135     133     133     133     133     132     131     138     142       138     136     135     134     133     133     133     132     131     138     142       138     136     135     134     133     135     134     133     130     138     142       137     139     136     136     134     136     134     129     136     139       137     138     138     136     134     139     136     130     142     136</td> <td>138     137     133     132     132     132     133     133     133     133     138     136     136     136     136     136     136     136     136     139     138     142     140       137     138     138     136     133     133     133     133     130     138     142     140       137     138     138     136     139     142     142     139     136     130     142     136     134</td> <td>138     137     133     132     132     132     133     133     133     133     133     139     138     139     138     139     138     139     138     136     136     133     133     133     133     132     132     132     136     139     138     134     133     133     133     133     132     131     138     142     140     133       138     136     133     133     133     133     133     132     131     138     142     140     133       138     136     133     133     133     133     133     133     132     131     138     142     140     133       138     136     133     133     133     133     133     133     133     133     133     134     133     134     133     133     133     133</td> <td>138     137     133     132     132     132     132     133     133     133     133     134     139     138<td>138     137     133     132     132     132     133     133     133     133     133     138     138     138     138     138     136     133     136     132     132     131     132     132     132     133     133     133     133     133     138     138     138     136     135     136     135     136     135     136     135     136     135     136     133     133     133     133     133     133     133     132     136     136     136     133     133     133     133     132     132     136     136     133     133     133     133     132     132     136     136     133     133     133     133     132     136     136     133     133     133     133     132     131     136     136     133     133     133     133     132     131     138     142     140     133<td>138     137     133     132     132     132     132     133<td>138     137     133     132     132     132     133<td>138       137       133       132       132       132       133       1</td><td>138       137       133       132       132       132       133      
133       133       133       133       133       133       133       133       133       133       133       133       133       1</td></td></td></td></td> | 138     137     133     132     132     132     133     133     133     133       132     132     131     131     132     132     133     133     133       130     132     132     132     133     133     133     133       131     133     134     133     133     133     133     132     132       131     133     134     133     133     133     133     132     132       135     136     135     133     133     133     133     132     131       138     136     133     134     133     135     134     133     130       137     139     138     136     136     139     142     142     139     136     130 | 138     137     133     132     132     132     133     133     133     133     133       132     132     131     132     132     133     133     133     133       130     132     131     132     132     133     133     133     133       130     132     132     132     132     133     133     133     132     135       131     133     134     133     133     133     133     132     132     136       135     136     135     133     133     133     133     133     132     131     138       138     136     135     134     133     135     134     133     130     138       137     139     136     136     139     140     138     136     130     130       137     138     138     136     139     142     142     139     136     130 | 138     137     133     132     132     132     133     133     133     133     138     138     138       132     132     131     131     132     132     133     133     133     133     138     138       130     132     132     132     132     133     133     133     132     135     136       131     133     134     133     133     133     133     132     132     132     136     139       135     136     135     133     133     133     133     132     131     138     142       138     136     135     134     133     133     133     132     131     138     142       138     136     135     134     133     135     134     133     130     138     142       137     139     136     136     134     136     134     129     136     139       137     138     138     136     134     139     136     130     142     136 | 138     137     133     132     132     132     133     133     133     133     138     136     136     136     136     136     136     136     136     139     138     142     140       137     138     138     136     133     133     133     133     130     138     142     140       137     138     138     136     139     142     142     139     136     130     142     136     134 | 138     137     133     132     132     132     133     133     133     133     133     139     138     139     138     139     138     139     138     136     136     133     133     133     133     132     132     132     136     139     138     134     133     133     133     133     132     131     138     142     140     133       138     136     133     133     133     133     133     132     131     138     142     140     133       138     136     133     133     133     133     133     133     132     131     138     142     140     133       138     136     133     133     133     133     133     133     133     133     133     134     133     134     133     133     133     133 | 138     137     133     132     132     132     132     133     133     133     133     134     139     138 <td>138     137     133     132     132     132     133     133     133     133     133     138     138     138     138     138     136     133     136     132     132     131     132     132     132     133     133     133     133     133     138     138     138     136     135     136     135     136     135     136     135     136     135     136     133     133     133     133     133     133     133     132     136     136     136     133     133     133     133     132     132     136     136     133     133     133     133     132     132     136     136     133     133     133     133     132     136     136     133     133     133     133     132     131     136     136     133     133     133     133     132     131     138     142     140     133<td>138     137     133     132     132     132     132     133<td>138     137     133     132     132     132     133<td>138       137       133       132       132       132       133       1</td><td>138       137       133       132       132       132       133       1</td></td></td></td> | 138     137     133     132     132     132     133     133     133     133     133     138     138     138
    138     138     136     133     136     132     132     131     132     132     132     133     133     133     133     133     138     138     138     136     135     136     135     136     135     136     135     136     135     136     133     133     133     133     133     133     133     132     136     136     136     133     133     133     133     132     132     136     136     133     133     133     133     132     132     136     136     133     133     133     133     132     136     136     133     133     133     133     132     131     136     136     133     133     133     133     132     131     138     142     140     133 <td>138     137     133     132     132     132     132     133<td>138     137     133     132     132     132     133<td>138       137       133       132       132       132       133       1</td><td>138       137       133       132       132       132       133       1</td></td></td> | 138     137     133     132     132     132     132     133 <td>138     137     133     132     132     132     133<td>138       137       133       132       132       132       133       1</td><td>138       137       133       132       132       132       133       1</td></td> | 138     137     133     132     132     132     133 <td>138       137       133       132       132       132    
  133       1</td> <td>138       137       133       132       132       132       133       1</td> | 138       137       133       132       132       132       133       1 | 138       137       133       132       132       132       133       1 |

Gambar 4.19 Ilustrasi rotasi 90°

#### 4.3.2. Refleksi

Refleksi atau pencerminan dalam augmentasi data citra yaitu dengan melakukan pencerminan posisi nilai-nilai piksel pada data citra awal terhadap sumbu x atau sumbu y. Berikut merupakan contoh perhitungan refleksi terhadapap sumbu y dengan menggunakan Persamaan 2.5

$$(x,y) \Rightarrow \begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix}$$

$$(1,1) \Rightarrow \begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$

$$(1,2) \Rightarrow \begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \end{bmatrix} = \begin{bmatrix} -1 \\ 2 \end{bmatrix}$$

$$(1,3) \Rightarrow \begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 3 \end{bmatrix} = \begin{bmatrix} -1 \\ 3 \end{bmatrix}$$

$$(1,8) \Rightarrow \begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} -1 & 0 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} 1 \\ 8 \end{bmatrix} = \begin{bmatrix} -1 \\ 8 \end{bmatrix}$$

$$(1,9) \Rightarrow \begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} -1 & 0 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} 1 \\ 9 \end{bmatrix} = \begin{bmatrix} -1 \\ 9 \end{bmatrix}$$

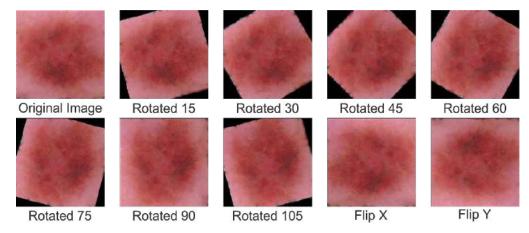
$$(1,10) \Rightarrow \begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 10 \end{bmatrix} = \begin{bmatrix} -1 \\ 10 \end{bmatrix}$$

Sama halnya dengan rotasi, nilai negatif pada hasil perhitungan merepresentasikan posisi sebaliknya dari posisi awal. Refleksi terhadap sumbu y pada lapisan Blue (B) Gambar 4.18 dengan nilai piksel seperti pada Gambar 4.17 diilustrasikan pada Gambar 4.20

	-					1	h		9 1									_	- 1
Ų.					3	T. A.			To Alle	21									
137	137	137	138	135	131	130	132	138	126	126	138	132	130	131	135	138	137	137	137
139	138	139	138	136	133	132	132	137	137	137	137	132	132	133	136	138	139	138	139
138	138	138	135	135	134	132	131	133	133	133	133	131	132	134	135	136	138	138	138
135	136	136	133	133	133	130	131	132	132	132	132	131	130	133	133	133	136	136	135
136	139	138	134	133	133	132	132	132	132	132	132	132	132	133	133	134	138	139	136
138	142	140	133	133	133	132	132	132	132	132	132	132	132	133	133	133	140	142	138
138	142	138	135	133	133	133	133	133	133	133	133	133	133	133	133	135	138	142	138
136	139	136	134	133	133	133	133	133	133	133	133	133	133	133	133	134	136	139	136
142	136	134	133	132	132	133	133	133	134	134	133	133	133	132	132	133	134	136	142
135	130	129	130	131	132	132	133	133	134	134	133	133	132	132	131	130	129	130	135

Gambar 4.20 Ilustrasi refleksi terhadap sumbu y

Proses augmentasi menghasilkan 1836 varian citra baru. Data citra yang awalnya hanya 204 data menjadi 2040 data citra. Contoh augmentasi data citra dengan memodifikasi data citra asli dengan data citra asli dirotasi sebesar  $15^{\circ}, 30^{\circ}, 45^{\circ}, 60^{\circ}, 75^{\circ}, 90^{\circ}$  dan  $105^{\circ}$ , dan direfleksi terhadap sumbu x dan sumbu y ditunjukkan pada Gambar 4.21



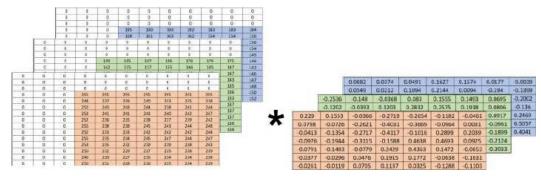
Gambar 4.21 Contoh hasil augmentasi data

# 4.4. Feature Learning dan Klasifikasi

Citra hasil *pre-processing* selanjutnya dipelajari fitur-fiturnya dengan menggunakan arsitektur GoogleNet. Pada pembelajaran fitur seluruh data citra akan melewati layer-layer yang terdapat dalam arsitektur GoogleNet dengan Data citra input berupa citra RGB dengan ukuran  $224 \times 224$ . Layer-layer dalam arsitektur GoogleNet antara lain

### 4.4.1. Convolution layer

Arsitektur GoogleNet memiliki *convolution layer* sebagaimana yang terletak seperti Gambar 3.4. *Convolution layer* mempelajari fitur suatu citra dengan operasi konvolusi dan filter. Filter yang digunakan berukuran  $7 \times 7$  dengan stride(s) sama dengan 2, dan zeropadding(p) sebanyak 3 pada tiap sisi citra. Stride, padding, ukuran dan banyaknya filter ditentukan secara default berdasarkan jenis arsitektur. Filter terdiri dari tiga lapisan untuk masing-masing lapisan citra RGB dengan nilai random antara -1 hingga 1 (Zhang et al., 2020a). Sebagai contoh perhitungan convolution layer menggunakan data input berupa citra kanker kulit dengan ukuran  $224 \times 224 \times 3$ . Ilustrasi sampel operasi konvolusi antara citra inputan dan filter ditunjukkan pada Gambar 4.22



Gambar 4.22 Sampel perhitungan convolution layer

Operasi konvolusi antara citra dan filter pada Gambar 4.22 akan

menghasilkan *feature map* dengan dimensi yang dihitung dengan perhitungan seperti pada Persamaan 2.6

$$h = \frac{i - k + 2p}{s} + 1 = \frac{224 - 7 + 2(3)}{2} + 1 = 112$$

Berdasarkan perhitungan diatas ukuran  $feature\ map$  yang dihasilkan dari  $convolution\ layer$  dengan ukuran citra  $224\times 224$ , filter berukuran  $7\times 7$  dengan stride(s) sama dengan 2, dan zeropadding(p) sebanyak 3 adalah 112. Contoh perhitungan operasi konvolusi pada masing-masing lapisan diilustrasikan pada Gambar 4.23, Gambar 4.24, dan Gambar 4.25

0	0	0	0	0	0	0	0	-	0								
0	0	0	0	0	-0	0	0	0	0		_						
0	0	0	0	0	0	0	0	0	0				_	_			
0	0	0	255	255	255	255	255	255	255								
0	0.	0	244	23.7	239	240	233	235	238		0.229	0.1553	-0.0366	-0.2719	-0.2654	-0.1182	-0.0461
0	0	0	252	242	243	244	238	241	244		0.0798	-0.0725	-0.2621	-0.4031	-0.3669	-0.6964	0.0031
0	0	0	233	241	243	243	240	242	Z47		-0.0413	-0.1354	-0.2717	-0.4117	-0.1010	0.2899	0.2039
0	-	0	252	236	235	238	237	239	242	*	-0.0976	-6.1944	-0.3115	-0.1588	0.4638	0.4693	0.0925
0	0	0	255	329	228	245	242	241	248		-0.0791	-0.1183	-0.0770	0.2439	0.4262	0.1472	-0.0853
0	0	0	252	233	233	242	747	242	244		-0.0377	-0.0296	0.0476	0.1915	0.1772	-0.0638	-0.1631
0	0	0	255	235	234	245	247	244	247		-0.0261	-0.0119	0.0705	0,1137	0.0325	-0.1288	-0.1303
0	0	0	253	235	232	239	239	238	243								
0	0	0	250	232	229	237	235	235	239								
0	0	0	249	230	227	235	234	234	238								
0	0	0	250	231	228	236	235	234	239								

Gambar 4.23 Sampel perhitungan convolution layer lapisan R

0	0	0	0	0	0	0	0.	-	0								
.0	0	.0	0	0	0	0	0	0	0								
0	-0	- 0	0	0	0	0	0	0	0				_	_			
0	0	- 6	100	185	187	186	176	176	175							_	
	-0	.0	107	153	357	155	146	145	147		-D.2536	-0.148	-0.0368	0.083	0.1555	0.1493	0.0095
0	0	0	163	154	154	153	145	145	147		-0.1202	-0.0393	0.1203	0.2832	0.2575	0.1918	0.0806
. 0	. 0	0	150	142	146	146	140	140	143	. USANT	-0.039	0.1019	0.2608	0.2753	0.2314	0.2532	0.0917
0	-	0	152	136	134	137	131	132	135	*	0.0741	0.1887	0.1857	0.2352	0.3369	0.1195	-0.0951
0	0	0	155	137	134	139	136	134	136		0.105	0.1308	0.1429	0.2174	0.0077	-0.195	-0.1899
0	0	0	151	132	129	137	135	132	133		0.073	0.0977	0.0535	-0.0056	-0.1647	-0.1989	-0.2124
0	0	0	156	136	133	144	142	139	937		0.0533	0.0258	-0.0184	-0.077	-0.1758	-0.25	-0.3033
0	0	0	158	140	135	142	138	137	137		-		ACKSON I	1,500,500			11-2
. 0	0	0	157	140	136	142	138	135	137								
0	0	0	158	139	136	142	138	137	138								
- 0	0	-0	100	1.00	120	943	120	100	9.90								

Gambar 4.24 Sampel perhitungan convolution layer lapisan G

0	0	0	0	0	0	0	0	0	0								
0	0	0	0	0	0	0	0	0	0		_						
0	0	0	0	0	0	.0	0	0	0				_				
0	0	0	195	190	193	192	183	183	184							_	
0	0	0	168	151	163	162	154	154	156		0.0882	0.0374	0.0491	0.1627	0.1574	0.0177	-0.0039
0	0	0	169	160	160	160	153	154	156		0.0549	0.0212	0.1094	0.2144	0.0094	-0.194	-0.1399
0	0	0	168	155	154	155	150	151	154	200	0.0199	0.0568	0.1533	0.0536	-0.3219	-0.3937	-0.2002
0	0	0	160	144	142	145	141	142	145	*	0.0739	0.0746	-0.0157	-0.2004	-0.4378	-0.4939	-0.136
0	0	0	103	145	143	149	146	145	148		0.0081	-0.034	-0.1171	-0.2557	-0.5004	-0.2506	0.2469
0	0	0	157	138	136	144	143	141	142		-0.0363	-0.044	-0.1302	-0.2255	-0.1249	0.2979	0.5057
0	0	0	161	141	139	150	149	146	146		-0.0065	-0.029	-0.0702	-0.0286	0.1561	0.411	0.4041
0	0	0	164	146	142	149	146	145	147								
0	0	0	165	145	144	148	147	144	148								
0	0	0	167	145	145	150	149	146	150								
0	0	0.	169	149	147	153	151	148	152								

Gambar 4.25 Sampel perhitungan convolution layer lapisan B

Hasil perhitungan pada masing-masing lapisan akan dijumlahkan untuk menghasilkan *feature map*. Hasil operasi konvolusi pertama pada lapisan R dijumlahkan dengan hasil operasi konvolusi pada lapisan G dan B, sehingga menghasilkan nilai *feature map* pada posisi (1,1). Contoh perhitungan *feature map* pada *convolution layer* sebagai berikut:

$$H_{1,1} = I_r(1,1) \times F_r(1,1) + I_r(1,2) \times F_r(1,2) + I_r(1,3) \times F_r(1,3) + \dots + I_r(7,7)$$

$$\times F_r(7,7) + (I_g(1,1) \times F_g(1,1) + I_g(1,2) \times F_g(1,2) + I_g(1,3) \times F_g(1,3) +$$

$$\dots + I_g(7,7) \times F_g(7,7) + (I_b(1,1) \times F_b(1,1) + I_b(1,2) \times F_b(1,2) + I_b(1,3)$$

$$\times F_b(1,3) + \dots + I_b(7,7) \times F_b(7,7)$$

$$= ((0 \times 0.229) + (0 \times 0.1553) + (0 \times (-0.0366)) + \dots + (243 \times (-0.1103)))$$

$$+ ((0 \times (-0.2536)) + (0 \times (-0.148)) + (0 \times (-0.0368)) + \dots + (146$$

$$\times (-0.3033))) + ((0 \times 0.0882) + (0 \times 0.0374) + (0 \times 0.0491) + \dots + (155$$

$$\times 0.4041))$$

$$= 48.7910$$

$$H_{1,2} = I_r(1,4) \times F_r(1,1) + I_r(1,5) \times F_r(1,2) + I_r(1,6) \times F_r(1,3) + \dots + I_r(7,10)$$

$$\times F_r(7,7) + (I_g(1,4) \times F_g(1,1) + I_g(1,5) \times F_g(1,2) + I_g(1,6) \times F_g(1,3)$$

$$+ \dots + I_g(7,10) \times F_g(7,7) + (I_b(1,4) \times F_b(1,1) + I_b(1,5) \times F_b(1,2) + I_b(1,6)$$

$$\times F_b(1,3) + \dots + I_b(7,10) \times F_b(7,7)$$

$$= ((0 \times 0.229) + (0 \times 0.1553) + (0 \times (-0.0366)) + \dots + (247 \times (-0.1103)))$$

$$+ ((0 \times (-0.2536)) + (0 \times (-0.148)) + (0 \times (-0.0368)) + \dots + (143)$$

$$\times (-0.3033)) + ((0 \times 0.0882) + (0 \times 0.0374) + (0 \times 0.0491) + \dots + (154)$$

$$\times 0.4041))$$

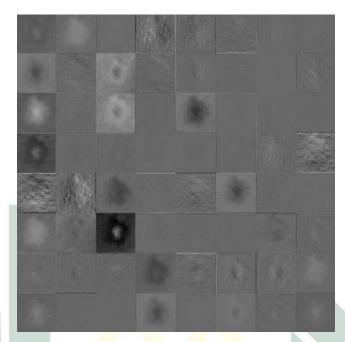
$$= 48.7910$$

Feature map yang dihasilkan dari perhitungan diatas ditunjukkan pada matriks berukuran  $112 \times 112$  berikut:

$$H_{(:,:,1)} = \begin{bmatrix} 48.8 & 38.7 & 39.2 & 41.4 & 32.4 & \cdots & 30.55 \\ 46.9 & -1.4 & -14.8 & -24.4 & -33.7 & \cdots & -29.26 \\ 20.3 & -38.2 & -46.0 & -54.2 & -57.1 & \cdots & -57.90 \\ 10.5 & -57.8 & -60.2 & -65.3 & -71.9 & \cdots & -71.45 \\ -2.1 & -66.7 & -65.7 & -70.6 & -79.6 & \cdots & -73.86 \\ -3.2 & -58.2 & -58.5 & -66.3 & -73.6 & \cdots & -66.15 \\ 6.1 & -48.2 & -52.5 & -59.7 & -65.5 & \cdots & -62.54 \\ -4.0 & -62.1 & -66.1 & -75.1 & -79.2 & \cdots & -70.21 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 12.02 & -36.00 & -39.04 & -48.02 & -48.21 & \cdots & -45.14 \end{bmatrix}$$

Perhitungan tersebut berulang sesuai dengan jumlah tumpukan *feature* map. Visualisasi tampilan *feature* map yang dihasilkan dari *convolution* layer

# ditunjukkan pada Gambar 4.26



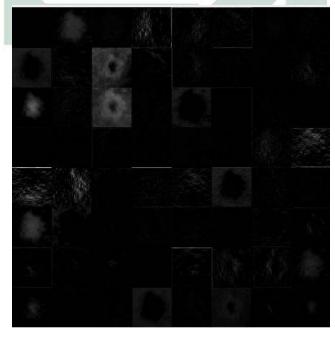
Gambar 4.26 Visualisasi feature map pada convolution layer

### 4.4.2. Rectified Linear Unit (ReLU)

Feature map yang dihasilkan dari proses convolution layer selanjutnya diaktivasi dengan menggunakan fungsi aktivasi ReLU untuk menghilangkan nilai negatif pada feature map. Nilai negatif dalam feature map digantikan oleh nilai 0 sebagaimana tertulis pada Persamaan 2.7. Nilai negatif pada feature map dapat menyebabkan kecenderungan nilai gradien neuron mendekati 0 untuk nilai input yang tinggi sehingga terjadi hilangnya kemiringan gradien dan model tidak dapat mempelajari polanya. Sebagai contoh, feature map yang dihasilkan olrh convolution layer diaktifasi ReLU dengan hasil seperti yang ditunjukkan pada matriks berukuran  $112 \times 112$  berikut:

$$H_{(:,:,1)} = \begin{bmatrix} 48.8 & 38.7 & 39.2 & 41.4 & 32.4 & \cdots & 30.55 \\ 46.9 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 20.26 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 10.54 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 0 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 0 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 6.1 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 0 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 0 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 0 & 0 & 0 & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 12.02 & 0 & 0 & 0 & 0 & \cdots & 0 \end{bmatrix}$$

Aktivasi ReLU berulang sesuai dengan jumlah tumpukan *feature map*. Visualisasi *feature map* Gambar 4.26 setelah melalui *ReLU layer* ditunjukkan pada Gambar 4.27



Gambar 4.27 Visualisasi feature map pada ReLU

## 4.4.3. Pooling Layer

Arsitektur GoogleNet memiliki *pooling layer* yang digunakan untuk mempercepat proses perhitungan komputasi dengan cara mengurangi volume pada setiap tumpukan *feature map* tanpa menghilangkan informasi-informasi penting. Jenis *pooling* yang digunakan setelah ReLU layer adalah *max pooling*. Penggunaan *max pooling* dilakukan untuk mendapatkan fitur-fitur paling dominan pada *feature map*. Ilustrasi perhitungan *max pooling* ditunjukkan pada Gambar 4.28

													1000	100		
48.8	38.7	39.2	41.4	32:4	26.8	29.1	27.9		30.55							
46.9	0	0	0	0	0	0	-0_		0							
20.26	0	0	0	0	0	0:	0		0							
10.54	.0	0	0	0	0	0	0	***	0							
Tes	100	- 33	1993	8837	100	255	189	=	-	48.79	41.44	32.40	29.10	24.36	***	30.55
0	0	0	0	0	0	0	0	***	0	20.26	0	0	0	0		0
0	0	0	0	0	0	0	0	1000	0	6.14	0	0	0	0		0
	90	52	0101	0.000	100	20		-	0000	6.14	0	0	0	0	444	0
6.1	0	0	0	0	0	0	0	355	0	0	0	0	0	0	100	0
0	0	0	0	0	0	0	0		0	1	1	1	15	1	%	
(X)	- 27	70	120	0.55/10	250		10000	20081	0.000	12.02	0	0	0	0		0
0	0	0	0	0	0	0	0		0	,		77	77			10
0	0	0	0	0	0	0	0	10.00	0							
18	4	Đ	4	4	:	10		140	:							
12.02	0	0.	0	0	.0.	0	0		0							

Gambar 4.28 Ilustrasi perhitungan max pooling

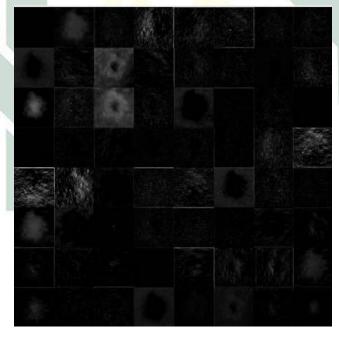
Contoh perhitungan max pooling feature map pada Tabel 4.27 dengan ukuran filter  $3 \times 3$  dan stride 2, dimana Y merupakan output dari pooling layer

$$Y_{1,1} = max(48.79, 38.66, 39.18, 46.88, 0, 0, 20.26, 0, 0)$$
 = 48.79  
 $Y_{1,2} = max(39.18, 41.44, 32.40, 0, 0, 0, 0, 0, 0)$  = 41.44  
 $Y_{1,3} = max(32.40, 26.80, 29.10, 0, 0, 0, 0, 0, 0)$  = 32.40

Dari contoh perhitungan diatas didapatkan hasil berukuran  $56 \times 56$  seperti pada matriks berikut:

$$Y_{(:,:,1)} = \begin{bmatrix} 48.79 & 41.44 & 32.40 & 29.10 & 24.36 & \cdots & 30.55 \\ 20.26 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 6.14 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 6.14 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 12.02 & 0 & 0 & 0 & 0 & \cdots & 0 \end{bmatrix}$$

Perhitungan *pooling layer* berulang sesuai dengan jumlah tumpukan feature map. Visualisasi feature map Gambar 4.27 setelah melalui max pooling layer ditunjukkan pada Gambar 4.29



Gambar 4.29 Visualisasi feature map pada max pooling

### 4.4.4. Local Response Normalization

Local response normalization digunakan untuk membatasi nilai pada feature map sehingga meningkatkan kemampuan generalisasi. Pada Local response normalization terdapat beberapa hyperparameter antara lain  $(k, \alpha, \beta, n)$ .

Inisialisasi hyperparameters  $(k, \alpha, \beta, n)$  sama dengan (1, 0.0001, 0.75, 5). Perhitungan Local response normalization pada hasil dari max pooling dengan sampel tumpukan feature map berukuran  $56 \times 56$  sebagai berikut:

$$Y_{(:,:,1)} = \begin{bmatrix} 48.79 & 41.44 & 32.40 & 29.10 & 24.36 & \cdots & 30.55 \\ 20.26 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 6.14 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 6.14 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 0 & 0 & 0 & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 12.02 & 0 & 0 & 0 & 0 & \cdots & 0 \end{bmatrix}$$

$$Y_{(:,:,2)} = \begin{bmatrix} 19.53 & 19.53 & 8.03 & 11.18 & 13.63 & \cdots & 39.46 \\ 24.55 & 24.55 & 26.87 & 25.93 & 35.92 & \cdots & 30.32 \\ 24.55 & 24.55 & 26.87 & 25.93 & 35.92 & \cdots & 22.94 \\ Y_{(:,:,2)} = \begin{bmatrix} 7.19 & 9.14 & 9.14 & 8.92 & 21.18 & \cdots & 32.56 \\ 10.95 & 18.14 & 18.14 & 19.32 & 14.73 & \cdots & 32.56 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 33.88 & 40.05 & 45.07 & 42.84 & 36.44 & \cdots & 9.63 \end{bmatrix}$$

$$\vdots$$

$$Y_{(:,:,64)} = \begin{bmatrix} 0 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 0 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 0 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 0 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 0 & 0 & 0 & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & 0 & \cdots & 0 \end{bmatrix}$$

Contoh perhitungan local response normalization pada filter 1 (p=1) menggunakan Persamaan 2.8

$$x_{1,1}^{1} = \frac{48.79}{\left(1 + \frac{0.0001\sum_{q=1}^{3} \left(a_{i,j}^{q}\right)^{2}}{5}\right)^{0.75}}$$

$$= \frac{48.79}{\left(1 + \frac{\left((48.79)^{2} + (19.53)^{2} + (75.78)^{2}\right)}{5}\right)^{0.75}}$$

$$= \frac{48.79}{\left(1 + \frac{8505.21}{5}\right)^{0.75}}$$

$$= \frac{48.79}{\left(1 + \frac{\left((48.79)^{2} + (19.53)^{2} + (75.78)^{2}\right)}{5}\right)^{0.75}}$$

$$= \frac{48.79}{\left(1 + 1701.04\right)^{0.75}}$$

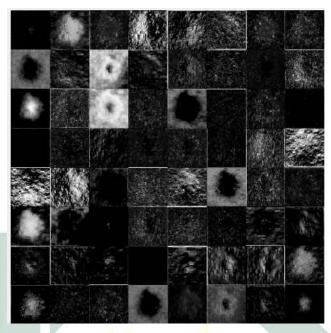
$$= 43.37$$

Perhitungan berlanjut hingga seluruh elemen dalam setiap  $feature\ map$  ternormalisasi. Hasil dari  $Local\ response\ normalization$  ditunjukkan pada matriks berukuran  $56\times 56$  berikut:

$$X_{(:,:,1)} = \begin{bmatrix} 43.37 & 39.34 & 31.87 & 28.67 & 24.03 & \cdots & 29.46 \\ 18.78 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 5.73 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 5.61 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 0 & 0 & 0 & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 10.36 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 22.73 & 23.17 & 26.03 & 20.84 & 28.67 & \cdots & 15.05 \\ 22.89 & 23.39 & 26.22 & 20.87 & 28.71 & \cdots & 11.90 \\ X_{(:,:,2)} = \begin{bmatrix} 6.50 & 8.91 & 8.88 & 8.33 & 19.68 & \cdots & 21.15 \\ 9.55 & 17.63 & 17.33 & 19.04 & 14.67 & \cdots & 25.48 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 26.10 & 38.54 & 43.16 & 41.05 & 34.25 & \cdots & 5.86 \end{bmatrix}$$

$$X_{(:,:,64)} = \begin{bmatrix} 0 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 0 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 0 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 0 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 0 & 0 & 0 & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & 0 & \cdots & 0 \end{bmatrix}$$

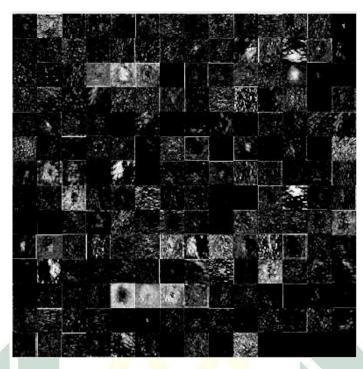
Visualisasi *feature map* Gambar 4.29 setelah melalui *local response* normalization ditunjukkan pada Gambar 4.30



Gambar 4.30 Visualisasi feature map pada local response normalization

### 4.4.5. Inception Nodule

Arsitektur GoogleNet memiliki 9 i<mark>nce</mark>ption nodule yang pada masing-masing inception nodule berisi convolution layer, ReLU, max pooling. Layer sebelum inception nodule adalah max pooling yang dibagi menjadi empat jalur dimana tiga jalur pertama merupakan convolution layer dengan masing-masing ukuran filter  $3 \times 3, 1 \times 1$ , dan  $5 \times 5$  untuk mempelajari fitur citra dengan ukuran spasial yang berbeda. Proses pembelajaran fitur pada dua jalur tengah dilakukan dengan convolution layer  $1 \times 1$  untuk mengurangi kompleksitas Jalur keempat menggunakan max pooling layer 3 × 3 yang diikuti model. convolution layer  $1 \times 1$ . Ukuran padding pada keempat jalur tersbut disesuaikan agar keluarannya memiliki ukuran yang sama. Hasil dari keempat jalur tersebut akan disusun menjadi beberapa tumpukan pada depth concatenation layer. Visualisasi *feature map* sebelum dan sesudah melalui *inception nodule* ditunjukkan pada Gambar 4.31 dan Gambar.



Gambar 4.31 Feature map pada max pooling layer sebelum inception nodule



Gambar 4.32 Feature map pada inception nodule

## 4.4.6. Dropout Layer

Drop out layer menentukan hasil yang akan diteruskan pada proses selanjutnya. Penentuan dilakukan berdasarkan nilai random antara 0 hingga 1, jika nilai random kurang dari nilai probabilitas yang ditentukan maka node tersebut tidak digunakan pada proses selanjutnya, sehingga terjadi pengurangan atau penipisan jaringan. Hal tersebut dapat mengurangi overfitting karena semakin tebal jaringannya maka akan semakin besar kemungkinan suatu model terlalu cocok pada dataset tertentu. Node yang tidak digunakan akan diganti dengan nilai 0 atau tidak diperhitungkan. Ilustrasi perhitungan dropout layer dengan nilai probabilitas yang ditentukan sama dengan 0.5 ditunjukkan pada Gambar 4.33

Input	Nilai Random	Output
2.33	0.76	2.33
0.72	0.74	0.72
0.18	0.66	0.18
0.17	0.39	0
0.39	0.87	0.39
1.26	0.71	1.26
1.38	0.64	1.38
0.11	0.92	0.11
0.13	0.05	0
:		:
0.29	0.10	0

Gambar 4.33 Ilustrasi perhitungan dropout layer

#### 4.4.7. Fully Connected Layer

Fully connected layer digunakan untuk menentukan fitur kelas yang paling dominan dari suatu citra. Input dari fully connected layer yaitu hasil dari layer sebelumnya yang berukuran  $1 \times 1024$ . Dalam perhitungan fully connected layer terdapat bobot (W) dan bias (b) dengan ukuran masing-masing  $2 \times 1024$  dan  $2 \times 1024$ 

1. Pada fully connected layer menggunakan metode multilayer perceptron yaitu backpropagation untuk pembaruan bobot dan bias. Bobot (W) dan bias (b) dalam fully connected layer ditunjukkan sebagai berikut:

$$x = \begin{bmatrix} 2.331 & 0.718 & 0.181 & 0 & \cdots & 0.093 & 0 & 0 \end{bmatrix}$$

$$\begin{bmatrix} 0.008 & -0.082 \\ 0.037 & -0.069 \\ 0.080 & -0.057 \\ 0.035 & 0.052 \\ \vdots & & \vdots \\ 0.056 & -0.035 \\ -0.122 & 0.019 \\ 0.025 & 0.028 \end{bmatrix}$$

$$b = \begin{bmatrix} 0.0013 \\ -0.0013 \end{bmatrix}$$

Perhitungan *fully connected layer* dilakukan dengan Persamaan 2.9 dengan contoh perhitungan sebegai berikut:

$$y_1 = b_1 + \sum_i w_{i1} x_i$$

$$= 0.0013 + ((0.008 * 2.331) + (0.037 * 0.718) + (0.080 * 0.181) + (0.035 * 0)$$

$$+ \dots + (0.025 * 0))$$

$$= 0.0013 + 5.7456$$

$$= 5.7469$$

$$y_2 = b_2 + \sum_i w_{i1} x_i$$

$$= -0.0013 + ((-0.082 * 2.331) + (-0.069 * 0.718) + (-0.057 * 0.181) + (0.052 * 0)$$

$$+ \dots + (0.028 * 0))$$

$$= -0.0013 + (-8.4906)$$

$$= -8.4919$$

$$y = \begin{bmatrix} 5.7469 \\ -8.4919 \end{bmatrix}$$

Fully connected layer biasanya diikuti oleh softmax layer yang digunakan sebagai fungsi aktivasi. Fungsi aktivasi softmax mengubah vektor skor nilai ril kedalam bentuk yang sama namun dalam rentang nilai 0 hingga 1 yang berjumlah 1. Perhitungan aktivasi softmax dilakukan dengan Persamaan 2.10 dengan contoh sebagai berikut:

$$SoftMax(y_1) = \frac{e^{y_1}}{\sum_{j=1}^{2} e^{y_j}}$$

$$= \frac{e^{5.7469}}{e^{5.7469} + e^{(-8.4919)}}$$

$$= 0.9999$$

$$SoftMax(y_2) = \frac{e^{y_2}}{\sum_{j=1}^{2} e^{y_j}}$$

$$= \frac{e^{-8.4919}}{e^{5.7469} + e^{(-8.4919)}}$$

$$= 0.0001$$

$$SoftMax = \begin{bmatrix} 0.9999 \\ 0.0001 \end{bmatrix}$$

Baris pertama pada *softmax* merepresentasikan probabilitas seseorang terdiagnosis kanker kulit berdasarkan citra kulit area yang mencurigakan. Baris kedua merepresentasikan probabilitas kulit area yang mencurigakan tidak terdeteksi sebagai kanker kulit.

## 4.5. Pengujian Model dan Evaluasi Sistem

Proses klasifikasi citra kanker kulit menggunakan algoritma CNN GoogleNet dipengaruhi oleh beberapa hal antara lain pembagian data *training* dan *testing*, *dropout*, dan *batchsize*. Pada penelitian ini dilakukan uji coba pembagian data, *dropout*, dan *batchsize* untuk mendapatkan model klasifikasi yang terbaik. Pembagian data yang di uji coba yaitu data training sebanyak 60%, 70%, 80%, dan 90%. Pada *dropout layer* dilakukan uji coba nilai probabilitas dengan inisialisasi probabilitas sama dengan 0.4, 0.5, 0.6, dan 0.7. *Batchsize* yang diujikan bernilai 8, 16, 32, dan 64. Model terbaik dipilih berdasarkan evaluasi sistem menggunakan *confusion matrix* dengan nilai akurasi, sensitifitas, dan spesifisitas.

Sistem klasifikasi menggunakan algoritma CNN GoogleNet dengan jumlah data yang sama dibandingkan dengan algoritma *machine learning* konvensional seperti *Support Vector Machine*. Klasifikasi menggunakan *Support Vector Machine* dalam data citra memerlukan algoritma untuk mengekstraksi fitur pada citra. Salah satu algoritma untuk mengekstraksi fitur pada citra adalah *Histogram of Oriented Gradients* (HOG), dimana citra diekstraksi berdasarkan nilai gradien piksel arah menurut orientasi arah.

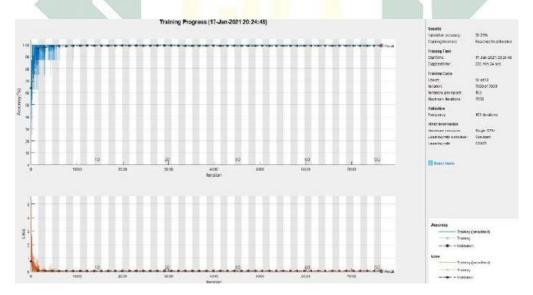
# 4.5.1. Pembagian Data 60%

Uji coba dengan pembagian data 60% ditunjukkan pada Tabel 4.1.

Tabel 4.1 Hasil evaluasi percobaan perbandingan data 60%

Pembagian data	Dropout	Batchsize	Akurasi (%)	Spesifisitas(	%)Sensitivitas(	%)waktu
		8	99.1	99	99.3	232 min 21 sec
		16	98.9	98.8	99	205 min
		7 /				54 sec
	0.4	32	98.53	98.5	98.5	198 min
						21 sec
		64	96.94	97.8	96.1	200 min
	3					44 sec
4	<i>X</i> *	8	98.65	98	99.3	232 min
		100	. 400			10 sec
		16	98.53	98.3	98.8	207 min
						11 sec
	0.5	32	98.28	98.3	98.3	197 min
					3//	12 sec
60		64	97.79	97.5	98	181 min
						13 sec
		8	99.02	99	99.3	232 min
						56 sec
		16	98.65	98.8	98.5	208 min
						49 sec
	0.6	32	97.92	98.5	97.3	196 min
						17 sec
		64	97.55	97.8	97.3	187 min
						3 sec
		8	99.26	99	99.5	235 min
						24 sec
		16	98.53	98.5	98.5	206 min
						9 sec
	0.7	32	98.41	98.5	98.3	192 min
						32 sec
		64	97.92	98.5	97.3	188 min
						45 sec

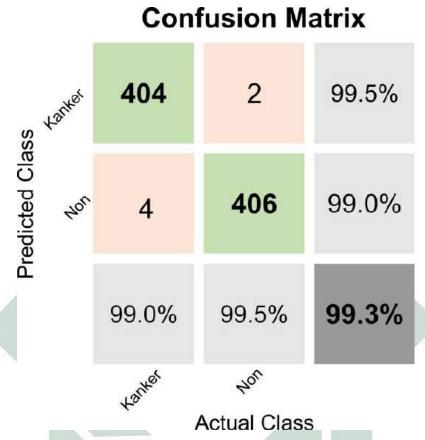
Berdasarkan Tabel 4.1 dapat diketahui akurasi terbaik dari pembagian data training 60% yaitu 99.26% dengan inisialisasi nilai probabilitas pada dropout layer sama dengan 0.7 dan nilai batchsize sama dengan 8. Setiap percobaan batchsize menunjukkan rata-rata nilai akurasi semakin turun ketika nilai batchsize semakin besar. Pada klasifikasi citra medis, kinerja sistem klasifikasi juga dievaluasi dengan sensitivitas dan spesifisitas. Sensitivitas dan spesifisitas pada percobaan dengan hasil akurasi terbaik masing-masing sebesar 99.5% dan 99%. Nilai sensitifitas yang tinggi menunjukkan bahwa model yang dihasilkan dapat mengenali citra malignant dengan baik. Sedangkan nilai spesifisitas yang tinggi menunjukkan bahwa model yang dihasilkan dapat mengenali citra benign dengan baik. Proses training membutuhkan waktu selama 235 min 24 sec dengan tampilan training progress seperti pada Gambar 4.34.



Gambar 4.34 Training progress hasil terbaik pembagian data 60%

Peningkatan nilai akurasi pada Gambar 4.34 ditunjukkan oleh grafik berwarna biru pada bagian atas yang berbanding terbalik dengan nilai eror ditunjukkan oleh grafik merah pada bagian bawah. Gambar 4.34 menunjukkan pada iterasi pertama nilai akurasi berada pada kisaran 60% yang terus meningkat

hingga pada iterasi terakhir mencapai nilai akurasi sebesar 99.26%. Dari proses *training* tersebut menghasilkan *confusion matrix* pada Gambar 4.35.



Gambar 4.35 Confusion matrix hasil terbaik pembagian data 60%

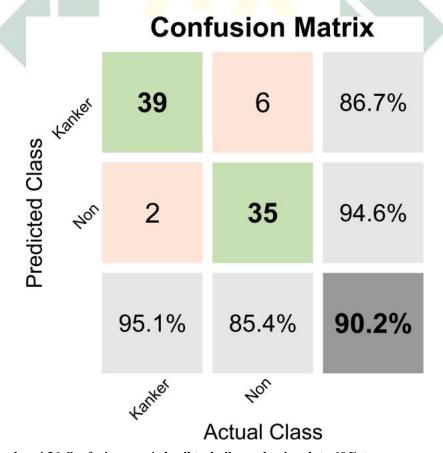
Berdasarkan Gambar 4.35 tiap baris pada tabel merepresentasikan kelas hasil prediksi (Output Class), sedangkan kolom mempresentasikan kelas sebenarnya (Target Class). Kotak pada diagonal matriks menunjukkan data yang terklasifikasi dengan benar, sebaliknya kotak selain pada diagonal menunujukkan data yeng terklasifikasi di kelas yang salah. Pada confusion matrix didapat True Positif (TP), False Positif (FP), True Negatif (TN), dan False Negatif (FN). TP merupakan jumlah citra malignant yang terprediksi benar, FP merupakan jumlah citra benign yang terprediksi benar, dan FN merupakan jumlah citra benign yang

terprediksi sebagai malignant. Sehingga TP, FP, TN, dan FN masing-masing bernilai 404, 4, 406, 2. Perhitungan akurasi, sensitivitas, dan spesifisitas dilakukan dengan menggunakan Persamaan 2.11, 2.12, dan 2.13. Hasil evaluasi sistem klasifikasi menggunakan data tanpa augmentasi ditunjukkan pada Tabel 4.2

Tabel 4.2 Hasil evaluasi percobaan perbandingan data 60% pada data tanpa augmentasi

Pembagian data	Dropout	Batchsize	Akurasi (%)	Spesifisitas (%)	Sensitivitas (%)	waktu
uata		8	89.02	90.02	87.8	24 min 6
	0.4					sec
	0.4	16	89.02	92.7	85.4	20 min 2
						sec
		32	89.02	90.02	87.8	17 min
	1					38 sec
	20	64	87.8	80.6	90.3	13 min
60		4 7				29 sec
60	Q.	8	90.24	95.1	85.4	23 min
	0.5					50 sec
	0.5	16	86.59	85.4	87.8	21 min 7
						sec
		32	89.02	90.2	87.8	18 min
						30 sec
		64	75	70	80	16 min
			7/			20 sec
		8	87.5	100	75	27 min
	0.6		-//	/ /		39 sec
	0.6	16	87.8	90.2	85.4	21 min
						33 sec
		32	85.48	90.3	80.6	20 min
						59 sec
		64	80.6	83.87	87.1	19 min
						12 sec
		8	89.02	97.6	80.5	24 min
	0.7					22 sec
	0.7	16	89.02	92.7	85.4	20 min
						58 sec
		32	87.8	90.2	85.4	18 min 3
						sec
		64	86.59	90.02	82.9	15 min 3
						sec
						SCC

Berdasarkan Tabel 4.2 dapat diketahui akurasi terbaik dari pembagian data training 60% yaitu 87.5% dengan inisialisasi nilai probabilitas pada dropout layer sama dengan 0.6 dan nilai batchsize sama dengan 8. Pada klasifikasi citra medis, kinerja sistem klasifikasi juga dievaluasi dengan sensitivitas dan spesifisitas. Sensitivitas dan spesifisitas pada percobaan dengan hasil akurasi terbaik masing-masing sebesar 100% dan 75%. Nilai sensitifitas yang tinggi menunjukkan bahwa model yang dihasilkan dapat mengenali citra malignant dengan baik. Sedangkan nilai spesifisitas yang tinggi menunjukkan bahwa model yang dihasilkan dapat mengenali citra benign dengan baik. Proses training membutuhkan waktu selama 235 min 24 sec dengan hasil confusion matrix seperti pada Gambar 4.36



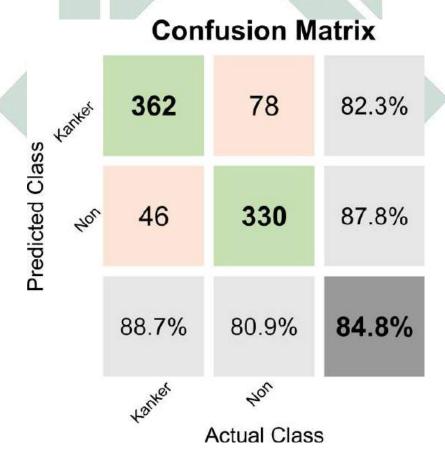
Gambar 4.36 Confusion matrix hasil terbaik pembagian data 60% tanpa augmentasi

Hasil pembagian data 60% dengan menggunakan algoritma HOG-SVM ditunjukkan pada Tabel 4.3.

Tabel 4.3 Hasil evaluasi percobaan perbandingan data 60% menggunakan HOG-SVM

Pembagian Data	Akurasi (%)	Spesifisitas (%)	Sensitivitas (%)	Waktu training
60%	84.8	88.7	80.9	3 min 16 sec

Berdasarkan Tabel 4.1 dan Tabel 4.3 menunjukkan bahwa kinerja algoritma CNN GoogleNet lebih baik dibandingkan algoritma HOG-SVM dari segi akurasi. *Confusion matrix* dari hasil percobaan ditunjukkan pada Gambar 4.37.



Gambar 4.37 Confusion matrix hasil terbaik pembagian data 60% menggunakan HOG-SVM

Berdasarkan hasil evaluasi kinerja sistem klasifikasi pada masing-masing percobaan diketahui bahwa klasifikasi dengan menggunakan augmentasi data dan

metode CNN GoogleNet memiliki rata-rata tingkat akurasi yang lebih tinggi. Tingkat akurasi sangat bekorelasi dengan durasi proses training. Pada percobaan dengan augmentasi data menggunakan metode CNN GoogleNet memiliki perbedaan akurasi dan durasi training yang signifikan dibandingkan menggunakan metpde HOG-SVM. Klasifikasi kanker kulit berdasarkan data yang telah di augmentasi menggunakan metode CNN GoogleNet membutuhkan waktu training lebih dari 2 jam, sedangkan pada metode HOG-SVM hanya membutuhkan waktu 3 Hasil akurasi pada sistem klasifikasi menggunakan metode CNN menit. GoogleNet berkisar antara 96 hingga 99%, sedangkan pada metode HOG-SVM hanya memperoleh tingkat akurasi sebesar 84.8%. Perbandingan akurasi klasifikasi data augmentasi dan tanpa augmentasi menggunakan metode CNN GoogleNet dengan metode HOG-SVM menunjukkan metode CNN GoogleNet lebih unggul dari segi akurasi. Percobaan pada Tabel 4.1 dan 4.2 menunjukkan augmentasi data berpengaruh dalam pembangunan sistem kalsifikasi. klasifikasi pada data yang telah di augmentasi memiliki kinerja yang lebih baik dibandingkan data tanpa augmentasi. Hal ini dikarenakan pada percoban dengan augmentasi data sistem akan mempelajari varians data yang lebih banyak sehingga dapat mengenali lesi kanker kulit pada berbagai posisi.

#### **4.5.2.** Pembagian Data **70%**

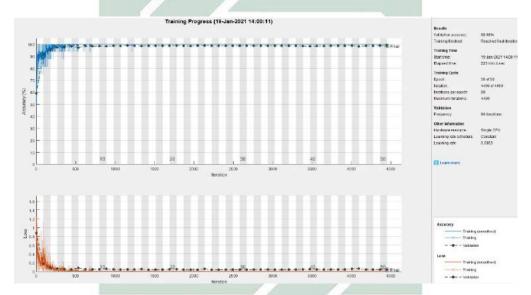
Uji coba dengan pembagian data 70% ditunjukkan pada Tabel 4.4.

Tabel 4.4 Hasil evaluasi percobaan perbandingan data 70%

Pembagian	Dropout	Batchsize	Akurasi	Spesifisitas	Sensitivitas	waktu
data			(%)	(%)	(%)	
		8	98.20	98	96.4	251 min
						11 sec
		16	98.69	99	98.4	223 min
						4 sec
	0.4	32	97.9	98	97.7	200 min
						34 sec
		64	97.39	97.7	97.1	214 min
		V /	//			15 sec
	/	8	97.71	98	97.4	250 min
	46					49 sec
		16	98.04	98	98	220 min
		1				52 sec
	0.5	32	97.71	98.7	96.7	213 min
		. 20 9				30 sec
70		64	98.04	100	96.1	232 min
						28 sec
		8	97.71	98	97.4	254 min
						39 sec
		16	98.20	98.7	97.7	221 min
						50 sec
	0.6	32	96.9	97.7	96.1	203 min
						31 sec
		64	97.55	97.1	98	210 min
						7 sec
		8	98.20	98.4	98	251 min
						10 sec
		16	98.20	96.7	97.7	221 min
						50 sec
	0.7	32	98.69	99	96.4	236 min
						6 sec
		64	97.88	97.7	98	234 min
						17 sec

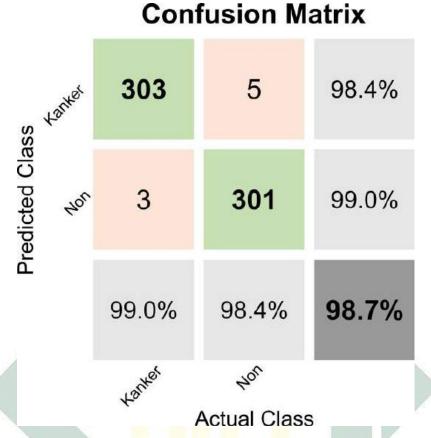
Berdasarkan Tabel 4.4 dapat diketahui akurasi terbaik dari pembagian data *training* 70% yaitu 98.69% dengan inisialisasi nilai probabilitas pada *dropout layer* sama dengan 0.4 dan nilai *batchsize* sama dengan 16. Setiap percobaan *batchsize* menunjukkan rata-rata nilai akurasi semakin turun ketika nilai *batchsize* semakin

besar. Pada klasifikasi citra medis, kinerja sistem klasifikasi juga dievaluasi dengan sensitivitas dan spesifisitas. Sensitivitas dan spesifisitas pada percobaan dengan hasil akurasi terbaik masing-masing sebesar 98.4% dan 99%. Nilai sensitifitas yang tinggi menunjukkan bahwa model yang dihasilkan dapat mengenali citra *malignant* dengan baik. Sedangkan nilai spesifisitas yang tinggi menunjukkan bahwa model yang dihasilkan dapat mengenali citra *benign* dengan baik. Proses *training* membutuhkan waktu selama 223 min 4 sec dengan tampilan *training progress* seperti pada Gambar 4.38.



Gambar 4.38 Training progress hasil terbaik pembagian data 70%

Peningkatan nilai akurasi pada Gambar 4.38 ditunjukkan oleh grafik berwarna biru pada bagian atas yang berbanding terbalik dengan nilai eror ditunjukkan oleh grafik merah pada bagian bawah. Gambar 4.38 menunjukkan pada iterasi pertama nilai akurasi 60% yang terus meningkat hingga pada iterasi terakhir mencapai nilai akurasi sebesar 98.69%. Dari proses *training* tersebut menghasilkan *confusion matrix* pada Gambar 4.39.



Gambar 4.39 Confusion matrix hasil terbaik pembagian data 70%

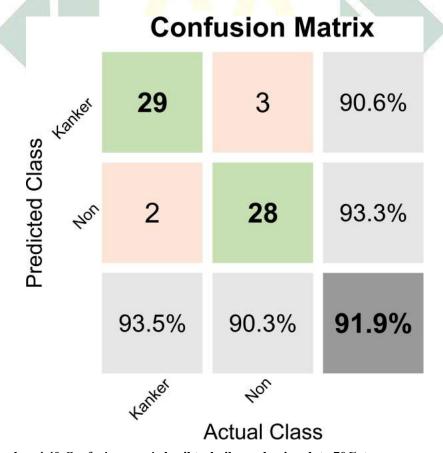
Berdasarkan Gambar 4.39 tiap baris pada tabel merepresentasikan kelas hasil prediksi (Output Class), sedangkan kolom mempresentasikan kelas sebenarnya (Target Class). Kotak pada diagonal matriks menunjukkan data yang terklasifikasi dengan benar, sebaliknya kotak selain pada diagonal menunujukkan data yeng terklasifikasi di kelas yang salah. Pada confusion matrix didapat True Positif (TP), False Positif (FP), True Negatif (TN), dan False Negatif (FN). TP merupakan jumlah citra malignant yang terprediksi benar, FP merupakan jumlah citra benign yang terprediksi sebagai benign, TN merupakan jumlah citra benign yang terprediksi sebagai malignant. Sehingga TP, FP, TN, dan FN masing-masing bernilai 303, 3, 301, 5. Perhitungan akurasi, sensitivitas, dan spesifisitas dilakukan

dengan menggunakan Persamaan 2.11, 2.12, dan 2.13. Hasil evaluasi sistem klasifikasi menggunakan data tanpa augmentasi ditunjukkan pada Tabel 4.5

Tabel 4.5 Hasil evaluasi percobaan perbandingan data 70% pada data tanpa augmentasi

Pembagian	Dropout	Batchsize	Akurasi	Spesifisitas	Sensitivitas	waktu
data			(%)	(%)	(%)	
		8	90.32	90.3	90.3	24 min
	0.4					20 sec
	0.4	16	88.17	87.1	90.3	21 min 2
		100		6		sec
		32	85.48	83.9	87.1	20 min 1
						sec
		64	83.87	80.6	87.1	18 min
70					<b>4</b>	13 sec
70	3	8	88.71	87.1	90.3	24 min
- 4	0.5	4.5				56 sec
	0.3	16	88.71	90.3	87.1	21 min
						10 sec
		32	83.87	77.4	90.3	20 min 2
					1	sec
		64	85.48	80.6	90.3	19 min
						59 sec
		8	88.71	87.1	90.3	24 min 3
	0.6					sec
	0.6	16	87.1	87.1	87.1	21 min
						32 sec
		32	85.48	80.6	90.3	20 min
						23 sec
		64	88.71	90.3	87.1	19 min
						53 sec
		8	91.94	93.5	90.3	25 min
	0.7					30 sec
	0.7	16	87.1	87.1	87.1	21 min
						47 sec
		32	87.1	87.1	87.1	20 min
						48 sec
		64	83.87	80.6	87.1	20 min
						42 sec

Berdasarkan Tabel 4.5 dapat diketahui akurasi terbaik dari pembagian data training 70% yaitu 91.94% dengan inisialisasi nilai probabilitas pada dropout layer sama dengan 0.7 dan nilai batchsize sama dengan 8. Pada klasifikasi citra medis, kinerja sistem klasifikasi juga dievaluasi dengan sensitivitas dan spesifisitas. Sensitivitas dan spesifisitas pada percobaan dengan hasil akurasi terbaik masing-masing sebesar 93.5% dan 90.3%. Nilai sensitifitas yang tinggi menunjukkan bahwa model yang dihasilkan dapat mengenali citra malignant dengan baik. Sedangkan nilai spesifisitas yang tinggi menunjukkan bahwa model yang dihasilkan dapat mengenali citra benign dengan baik. Proses training membutuhkan waktu selama 235 min 24 sec dengan hasil confusion matrix seperti pada Gambar 4.40



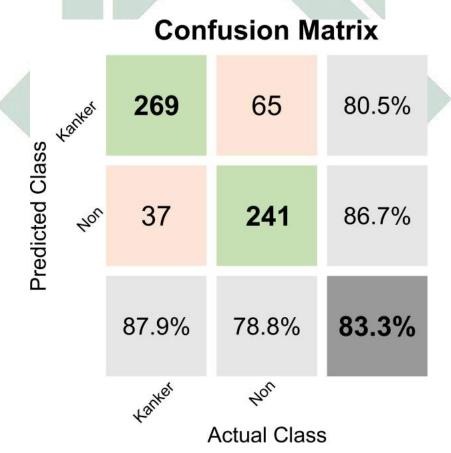
Gambar 4.40  $\it Confusion\ matrix$  hasil terbaik pembagian data  $\it 70\%$  tanpa augmentasi

Hasil pembagian data 70% dengan menggunakan algoritma HOG-SVM ditunjukkan pada Tabel 4.6.

Tabel 4.6 Hasil evaluasi percobaan perbandingan data 70% menggunakan HOG-SVM

Pembagian Data	Akurasi (%)	Spesifisitas (%)	Sensitivitas (%)	Waktu training
70%	84.8	87.9	78.8	5 min 49 sec

Berdasarkan Tabel 4.4 dan Tabel 4.6 menunjukkan bahwa kinerja algoritma CNN GoogleNet lebih baik dibandingkan algoritma HOG-SVM dari segi akurasi. *Confusion matrix* dari hasil percobaan ditunjukkan pada Gambar 4.41.



Gambar 4.41 Confusion matrix hasil terbaik pembagian data 70% menggunakan HOG-SVM

Berdasarkan hasil evaluasi kinerja sistem klasifikasi pada masing-masing percobaan diketahui bahwa klasifikasi dengan menggunakan augmentasi data dan

metode CNN GoogleNet memiliki rata-rata tingkat akurasi yang lebih tinggi. Tingkat akurasi sangat bekorelasi dengan durasi proses training. Pada percobaan dengan augmentasi data menggunakan metode CNN GoogleNet memiliki perbedaan akurasi dan durasi training yang signifikan dibandingkan menggunakan metpde HOG-SVM. Klasifikasi kanker kulit berdasarkan data yang telah di augmentasi menggunakan metode CNN GoogleNet membutuhkan waktu training lebih dari 2 jam, sedangkan pada metode HOG-SVM hanya membutuhkan waktu 5 Hasil akurasi pada sistem klasifikasi menggunakan metode CNN menit. GoogleNet berkisar antara 97 hingga 98%, sedangkan pada metode HOG-SVM hanya memperoleh tingkat akurasi sebesar 84.8%. Perbandingan akurasi klasifikasi data augmentasi dan tanpa augmentasi menggunakan metode CNN GoogleNet dengan metode HOG-SVM menunjukkan metode CNN GoogleNet lebih unggul dari segi akurasi. Percobaan pada Tabel 4.4 dan 4.5 menunjukkan augmentasi data berpengaruh dalam pembangunan sistem kalsifikasi. klasifikasi pada data yang telah di augmentasi memiliki kinerja yang lebih baik dibandingkan data tanpa augmentasi. Hal ini dikarenakan pada percoban dengan augmentasi data sistem akan mempelajari varians data yang lebih banyak sehingga dapat mengenali lesi kanker kulit pada berbagai posisi.

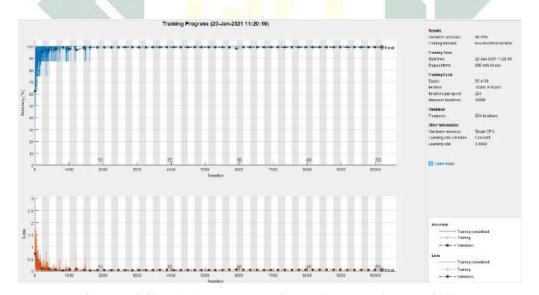
#### 4.5.3. Pembagian Data 80%

Uji coba dengan pembagian data 80% ditunjukkan pada Tabel 4.7.

Tabel 4.7 Hasil evaluasi percobaan perbandingan data 80%

Pembagian	Dropout	Batchsize	Akurasi	Spesifisitas	Sensitivitas	waktu
data			(%)	(%)	(%)	
		8	98.28	97.5	99	298 min
	0.4	16	98.28	98	98.5	273 min
	0.4					33 sec
		32	98.0	98.5	97.5	225 min
						29 sec
		64	97.06	96.1	98	222 min
		100				25 sec
	+	8	99.26	98.5	100	298 min
80	0 = /					40 sec
	0.5	16	98.53	97.1	100	276 min
			7 0.00			13 sec
		32	97.71	98.7	96.7	213 min
	1	1 1				30 sec
	72	64	98.04	98	98	227 min
						57 sec
	Q	8	99.02	99.5	98.5	264 min
			77.02			59 sec
	0.6	16	99.26	99.5	99	238 min
			77.20			40 seca
		32	98.53	99	98	226 min
		0_	70.00			16 sec
		64	98.53	99	98	222 min
			70.00			38 sec
		8	98.28	97.1	99.5	303 min
						53 sec
	0.7	16	98.77	99	98.5	253 min
		10	70			15 sec
		32	98.77	98.5	99	236 min
		52		50.5		8 sec
		64	97.79	99	96.6	229 min
		07	71.17		70.0	34 sec
						37 SCC

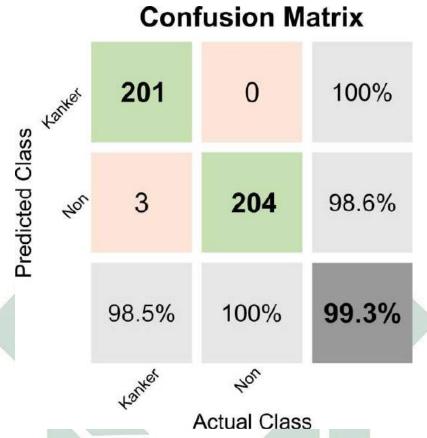
Berdasarkan Tabel 4.7 dapat diketahui akurasi terbaik dari pembagian data training 80% yaitu 99.26% dengan inisialisasi nilai probabilitas pada dropout layer sama dengan 0.5 dan nilai batchsize sama dengan 8. Setiap percobaan batchsize menunjukkan rata-rata nilai akurasi semakin turun ketika nilai batchsize semakin besar. Pada klasifikasi citra medis, kinerja sistem klasifikasi juga dievaluasi dengan sensitivitas dan spesifisitas. Sensitivitas dan spesifisitas pada percobaan dengan hasil akurasi terbaik masing-masing sebesar 100% dan 98.5%. Nilai sensitifitas yang tinggi menunjukkan bahwa model yang dihasilkan dapat mengenali citra malignant dengan baik. Sedangkan nilai spesifisitas yang tinggi menunjukkan bahwa model yang dihasilkan dapat mengenali citra benign dengan baik. Proses training membutuhkan waktu selama 298 min 40 sec dengan tampilan training progress seperti pada Gambar 4.42.



Gambar 4.42 Training progress hasil terbaik pembagian data 80%

Peningkatan nilai akurasi pada Gambar 4.42 ditunjukkan oleh grafik berwarna biru pada bagian atas yang berbanding terbalik dengan nilai eror ditunjukkan oleh grafik merah pada bagian bawah. Gambar 4.42 menunjukkan pada iterasi pertama nilai akurasi kisaran 60% yang terus meningkat hingga pada

iterasi terakhir mencapai nilai akurasi sebesar 99.26%. Dari proses *training* tersebut menghasilkan *confusion matrix* pada Gambar 4.43.



Gambar 4.43 Confusion matrix hasil terbaik pembagian data 80%

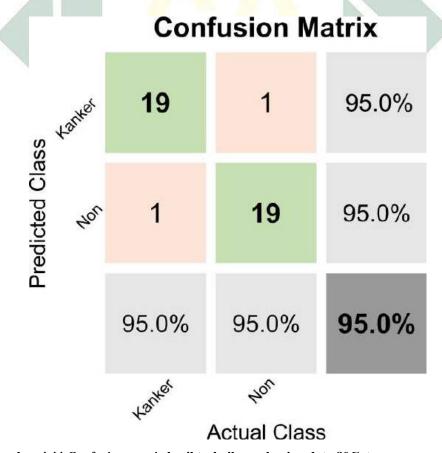
Berdasarkan Gambar 4.43 tiap baris pada tabel merepresentasikan kelas hasil prediksi (Output Class), sedangkan kolom mempresentasikan kelas sebenarnya (Target Class). Kotak pada diagonal matriks menunjukkan data yang terklasifikasi dengan benar, sebaliknya kotak selain pada diagonal menunujukkan data yeng terklasifikasi di kelas yang salah. Pada confusion matrix didapat True Positif (TP), False Positif (FP), True Negatif (TN), dan False Negatif (FN). TP merupakan jumlah citra malignant yang terprediksi benar, FP merupakan jumlah citra benign yang terprediksi benar, dan FN merupakan jumlah citra benign yang

terprediksi sebagai malignant. Sehingga TP, FP, TN, dan FN masing-masing bernilai 201, 3, 204, 0. Perhitungan akurasi, sensitivitas, dan spesifisitas dilakukan dengan menggunakan Persamaan 2.11, 2.12, dan 2.13. Hasil evaluasi sistem klasifikasi menggunakan data tanpa augmentasi ditunjukkan pada Tabel 4.8

Tabel 4.8 Hasil evaluasi percobaan perbandingan data 80% pada data tanpa augmentasi

Dropout	Batchsize		Spesifisitas	Sensitivitas	waktu
	fil.				
	8	87.5	100	75	27 min
0.4					39 sec
0.4	16	85	90	80	23 min
					19 sec
	32	92.5	95	90	23 min
1	5°				13 sec
	64	92.5	100	85	19 min
	47.14				19 sec
	8	90	95	85	27 min
0.5					53 sec
0.5	16	82.5	80	85	24 min
					31 sec
	32	82.5	85	80	23 min 9
					sec
	64	85	85	85	19 min 3
					sec
П	8	82.9	92.7	73.2	29 min
0.6			/ -		21 sec
0.6	16	90	90	90	25 min
					24 sec
-	32	85	85	85	23 min
					11 sec
-	64	90	90	90	19 min 0
					sec
	8	95	95	95	26 min
0.7					10 sec
U./	16	82.5	75	90	23 min
					56 sec
	32	90	90	90	22 min
					33 sec
	64	87.5	90	85	19 min 7
					sec
	0.4	32 64 8 0.5 16 32 64 8 0.6 16 32 64 8 0.7 16 32	0.4     16     85       32     92.5       64     92.5       8     90       16     82.5       32     82.5       64     85       8     82.9       0.6     16     90       32     85       64     90       8     95       0.7     16     82.5       32     90	0.4     (%)     (%)       8     87.5     100       32     92.5     95       64     92.5     100       8     90     95       16     82.5     80       32     82.5     85       64     85     85       8     82.9     92.7       0.6     16     90     90       32     85     85       64     90     90       8     95     95       0.7     16     82.5     75       32     90     90	0.4       (%)       (%)       (%)         16       85       90       80         32       92.5       95       90         64       92.5       100       85         8       90       95       85         16       82.5       80       85         32       82.5       85       80         64       85       85       85         8       82.9       92.7       73.2         0.6       16       90       90       90         32       85       85       85         64       90       90       90         8       95       95       95         0.7       16       82.5       75       90         32       90       90       90

Berdasarkan Tabel 4.8 dapat diketahui akurasi terbaik dari pembagian data training 80% yaitu 95% dengan inisialisasi nilai probabilitas pada dropout layer sama dengan 0.7 dan nilai batchsize sama dengan 8. Pada klasifikasi citra medis, kinerja sistem klasifikasi juga dievaluasi dengan sensitivitas dan spesifisitas. Sensitivitas dan spesifisitas pada percobaan dengan hasil akurasi terbaik masing-masing sebesar 95% dan 95%. Nilai sensitifitas yang tinggi menunjukkan bahwa model yang dihasilkan dapat mengenali citra malignant dengan baik. Sedangkan nilai spesifisitas yang tinggi menunjukkan bahwa model yang dihasilkan dapat mengenali citra benign dengan baik. Proses training membutuhkan waktu selama 26 min 10 sec dengan hasil confusion matrix seperti pada Gambar 4.44



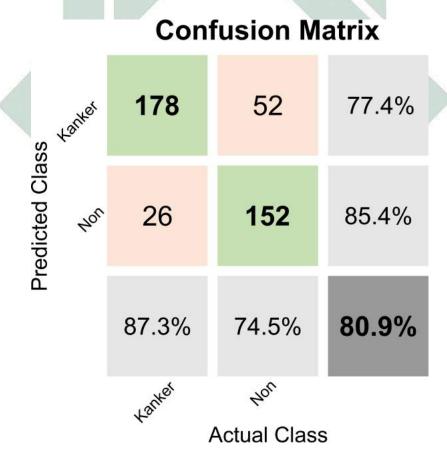
Gambar 4.44  $\it Confusion\ matrix$  hasil terbaik pembagian data 80% tanpa augmentasi

Hasil pembagian data 80% dengan menggunakan algoritma HOG-SVM ditunjukkan pada Tabel 4.9.

Tabel 4.9 Hasil evaluasi percobaan perbandingan data 80% menggunakan HOG-SVM

Pembagian Data	Akurasi (%)	Spesifisitas (%)	Sensitivitas (%)	Waktu training
80%	80.9	87.3	74.5	5 min 58 sec

Berdasarkan Tabel 4.7 dan Tabel 4.6 menunjukkan bahwa kinerja algoritma CNN GoogleNet lebih baik dibandingkan algoritma HOG-SVM dari segi akurasi. *Confusion matrix* dari hasil percobaan ditunjukkan pada Gambar 4.45.



Gambar 4.45 Confusion matrix hasil terbaik pembagian data 80% menggunakan HOG-SVM

Berdasarkan hasil evaluasi kinerja sistem klasifikasi pada masing-masing percobaan diketahui bahwa klasifikasi dengan menggunakan augmentasi data dan

metode CNN GoogleNet memiliki rata-rata tingkat akurasi yang lebih tinggi. Tingkat akurasi sangat bekorelasi dengan durasi proses training. Pada percobaan dengan augmentasi data menggunakan metode CNN GoogleNet memiliki perbedaan akurasi dan durasi training yang signifikan dibandingkan menggunakan metpde HOG-SVM. Klasifikasi kanker kulit berdasarkan data yang telah di augmentasi menggunakan metode CNN GoogleNet membutuhkan waktu training lebih dari 2 jam, sedangkan pada metode HOG-SVM hanya membutuhkan waktu 5 Hasil akurasi pada sistem klasifikasi menggunakan metode CNN menit. GoogleNet berkisar antara 97 hingga 99%, sedangkan pada metode HOG-SVM hanya memperoleh tingkat akurasi sebesar 80.9%. Perbandingan akurasi klasifikasi data augmentasi dan tanpa augmentasi menggunakan metode CNN GoogleNet dengan metode HOG-SVM menunjukkan metode CNN GoogleNet lebih unggul dari segi akurasi. Percobaan pada Tabel 4.7 dan 4.8 menunjukkan augmentasi data berpengaruh dalam pembangunan sistem kalsifikasi. klasifikasi pada data yang telah di augmentasi memiliki kinerja yang lebih baik dibandingkan data tanpa augmentasi. Hal ini dikarenakan pada percoban dengan augmentasi data sistem akan mempelajari varians data yang lebih banyak sehingga dapat mengenali lesi kanker kulit pada berbagai posisi.

#### **4.5.4.** Pembagian Data 90%

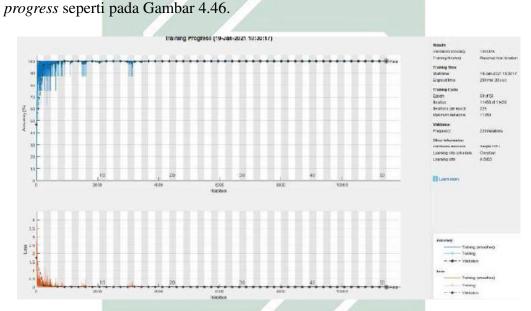
Uji coba dengan pembagian data 90% ditunjukkan pada Tabel 4.10.

Tabel 4.10 Hasil evaluasi percobaan perbandingan data  $90\,\%$ 

Pembagian	Dropout	Batchsize	Akurasi	Sensitivitas	Spesifisitas	Waktu
data						
		8	100	100	100	298 min
	0.4					30 sec
90	0.4	16	99.26	99.5	99	268 min
			0.60			3 sec
		32	99.51	100	99	251 min
						23 sec
		64	99.51	99	100	253 min
	-	- A	//			12 sec
	7	8	99.02	98	100	324 min
						1 sec
	0.5	16	99.02	99	99	263 min
		344				21 sec
	1	32	97.06	98	96.1 a	234 min
						49 sec
		64	98.53	97.1	98	210 min
						7 sec
		8	100	100	100	299 min
	0.6					15 sec
		16	99.51	100	99	263 min
						50 sec
		32	99.51	100	99	233 min
						24 sec
		64	98.53	97.1	100	216 min
						24 sec
		8	99.51	99	100	319 min
						7 sec
	0.7	16	99.02	100	98	287 min
						37 sec
		32	99.02	100	98	265 min
						42 sec
		64	97.06	97.1	97.1	255 min
			2			38 sec

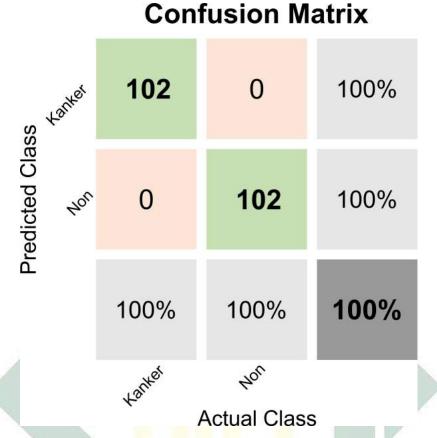
Berdasarkan Tabel 4.10 dapat diketahui akurasi terbaik dari pembagian data training 90% yaitu 100% dengan inisialisasi nilai probabilitas pada dropout layer sama dengan 0.4 dan nilai batchsize sama dengan 8. Setiap percobaan batchsize menunjukkan rata-rata nilai akurasi semakin turun ketika nilai batchsize semakin

besar. Pada klasifikasi citra medis, kinerja sistem klasifikasi juga dievaluasi dengan sensitivitas dan spesifisitas. Sensitivitas dan spesifisitas pada percobaan dengan hasil akurasi terbaik masing-masing sebesar 100% dan 100%. Nilai sensitifitas yang tinggi menunjukkan bahwa model yang dihasilkan dapat mengenali citra *malignant* dengan baik. Sedangkan nilai spesifisitas yang tinggi menunjukkan bahwa model yang dihasilkan dapat mengenali citra *benign* dengan baik. Proses *training* membutuhkan waktu selama 298 min 30 sec dengan tampilan *training* 



Gambar 4.46 Training progress hasil terbaik pembagian data 90%

Peningkatan nilai akurasi pada Gambar 4.46 ditunjukkan oleh grafik berwarna biru pada bagian atas yang berbanding terbalik dengan nilai eror ditunjukkan oleh grafik merah pada bagian bawah. Gambar 4.46 menunjukkan pada iterasi pertama nilai akurasi kisaran 40% yang terus meningkat hingga pada iterasi terakhir mencapai nilai akurasi sebesar 100%. Dari proses *training* tersebut menghasilkan *confusion matrix* pada Gambar 4.47.



Gambar 4.47 *Confusion matrix* hasil terbaik pembagian data 90%

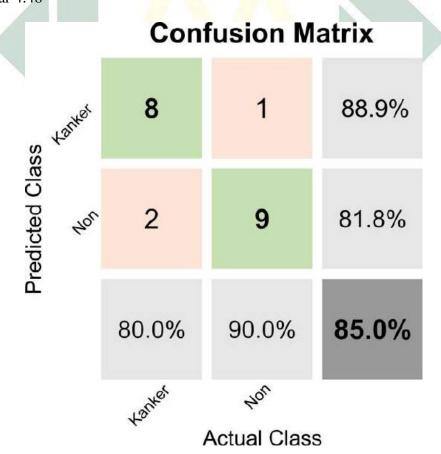
Berdasarkan Gambar 4.47 tiap baris pada tabel merepresentasikan kelas hasil prediksi (Output Class), sedangkan kolom mempresentasikan kelas sebenarnya (Target Class). Kotak pada diagonal matriks menunjukkan data yang terklasifikasi dengan benar, sebaliknya kotak selain pada diagonal menunujukkan data yeng terklasifikasi di kelas yang salah. Pada confusion matrix didapat True Positif (TP), False Positif (FP), True Negatif (TN), dan False Negatif (FN). TP merupakan jumlah citra malignant yang terprediksi benar, FP merupakan jumlah citra benign yang terprediksi sebagai benign, TN merupakan jumlah citra benign yang terprediksi benar, dan FN merupakan jumlah citra benign yang terprediksi sebagai malignant. Sehingga TP, FP, TN, dan FN masing-masing bernilai 102, 0, 102, 0. Perhitungan akurasi, sensitivitas, dan spesifisitas dilakukan

dengan menggunakan Persamaan 2.11, 2.12, dan 2.13. Hasil evaluasi sistem klasifikasi menggunakan data tanpa augmentasi ditunjukkan pada Tabel 4.5

Tabel 4.11 Hasil evaluasi percobaan perbandingan data 90% pada data tanpa augmentasi

Pembagian	Dropout	Batchsize	Akurasi	Spesifisitas	Sensitivitas	waktu
data			(%)	(%)	(%)	
		8	80	80	80	30 min
	0.4					43 sec
	0.4	16	80	80	80	25 min
		1		¢.		30 sec
		32	70	60	80	22 min
						22 sec
		64	75	80	70	18 min 6
00						sec
90	3	8	85	80	90	29 min
4	0.5	16	80	80	80	25 min 6
	0.3					sec
		32	75	80	70	21 min
						43 sec
		64	75	70	80	19 min
						14 sec
		8	80	80	80	28 min
	0.6					47 sec
	0.0	16	75	70	80	24 min
						56 sec
		32	75	70	80	21 min
						30 sec
		64	75	70	80	17 min
						24 sec
		8	75	70	80	29 min
	0.7					13 sec
	0.7	16	75	70	80	25 min
						44 sec
		32	75	80	70	22 min 4
						sec
		64	80	80	80	18 min
						20 sec

Berdasarkan Tabel 4.5 dapat diketahui akurasi terbaik dari pembagian data training 90% yaitu 85% dengan inisialisasi nilai probabilitas pada dropout layer sama dengan 0.5 dan nilai batchsize sama dengan 8. Pada klasifikasi citra medis, kinerja sistem klasifikasi juga dievaluasi dengan sensitivitas dan spesifisitas. Sensitivitas dan spesifisitas pada percobaan dengan hasil akurasi terbaik masing-masing sebesar 80% dan 90%. Nilai sensitifitas yang tinggi menunjukkan bahwa model yang dihasilkan dapat mengenali citra malignant dengan baik. Sedangkan nilai spesifisitas yang tinggi menunjukkan bahwa model yang dihasilkan dapat mengenali citra benign dengan baik. Proses training membutuhkan waktu selama 29 min dengan hasil confusion matrix seperti pada Gambar 4.48



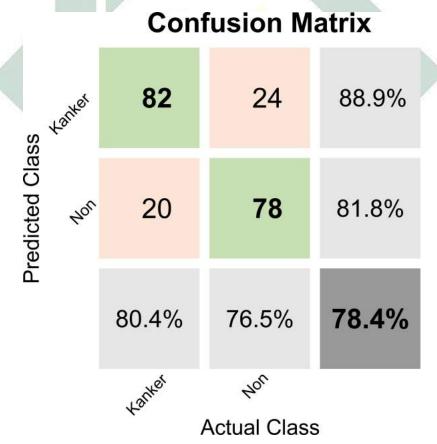
Gambar 4.48 Confusion matrix hasil terbaik pembagian data 90% tanpa augmentasi

Hasil pembagian data 90% dengan menggunakan algoritma HOG-SVM ditunjukkan pada Tabel 4.12.

Tabel 4.12 Hasil evaluasi percobaan perbandingan data 80% menggunakan HOG-SVM

Pembagian Data	Akurasi (%)	Spesifisitas (%)	Sensitivitas (%)	Waktu training
90%	78.4	80.4	76.5	6 min 2 sec

Berdasarkan Tabel 4.10 dan Tabel 4.12 menunjukkan bahwa kinerja algoritma CNN GoogleNet lebih baik dibandingkan algoritma HOG-SVM dari segi akurasi. *Confusion matrix* dari hasil percobaan ditunjukkan pada Gambar 4.49.



Gambar 4.49 Confusion matrix hasil terbaik pembagian data 90% menggunakan HOG-SVM

Berdasarkan hasil evaluasi kinerja sistem klasifikasi pada masing-masing percobaan diketahui bahwa klasifikasi dengan menggunakan augmentasi data dan

metode CNN GoogleNet memiliki rata-rata tingkat akurasi yang lebih tinggi. Tingkat akurasi sangat bekorelasi dengan durasi proses training. Pada percobaan dengan augmentasi data menggunakan metode CNN GoogleNet memiliki perbedaan akurasi dan durasi training yang signifikan dibandingkan menggunakan metpde HOG-SVM. Klasifikasi kanker kulit berdasarkan data yang telah di augmentasi menggunakan metode CNN GoogleNet membutuhkan waktu training lebih dari 2 jam, sedangkan pada metode HOG-SVM hanya membutuhkan waktu 6 Hasil akurasi pada sistem klasifikasi menggunakan metode CNN menit. GoogleNet berkisar antara 97 hingga 100%, sedangkan pada metode HOG-SVM hanya memperoleh tingkat akurasi sebesar 78.4%. Perbandingan akurasi klasifikasi data augmentasi dan tanpa augmentasi menggunakan metode CNN GoogleNet dengan metode HOG-SVM menunjukkan metode CNN GoogleNet lebih unggul dari segi akurasi. Percobaan pada Tabel 4.10 dan 4.11 menunjukkan augmentasi data berpengaruh dalam pembangunan sistem kalsifikasi. klasifikasi pada data yang telah di augmentasi memiliki kinerja yang lebih baik dibandingkan data tanpa augmentasi. Hal ini dikarenakan pada percoban dengan augmentasi data sistem akan mempelajari varians data yang lebih banyak sehingga dapat mengenali lesi kanker kulit pada berbagai posisi.

#### 4.6. Diskusi Hasil Penelitian

Perbandingan hasil evaluasi penelitian klasifikasi kanker kulit ini dengan penelitian terdahulu ditunjukkan pada Tabel 4.13

Tabel 4.13 Perbandingan hasil evaluasi sistem dengan peneliti terdahulu

	Akurasi (%)	Sensitivitas (%)	Spesifisitas (%)
Penelitian ini	100	100	100
(Yunizar et al., 2020)	76.9	76.9	76.9
(Farooq et al., 2016)	95.9	98.7	85.0
(Eltayef et al., 2017)	86.7	73.3	80.0
(Lopez et al., 2017)	95.9	96.2	95.6

Penelitian oleh (Yunizar et al., 2020) dilakukan dengan menggunakan metode *Gray Level Co-occurrence Matrix* (GLCM) dan HSV sebagai ekstraksi fitur. Pada penelitian ini citra lesi kanker kulit di segmentasi terlebih dahulu dengan menggunakan metode *otsu tresholding*. Segmentasi dilakukan dengan operasi morfologi *opening, closing, clear border, region filling,* dan *area filter*. Fitur citra yang digunakan antara lain *energy, homogenity, correlation, contrast, Hue, Saturation, dan Value*. Hasil ekstraksi fitur diklasifikasi dengan menggunakan metode *Support Vector Machine* (SVM). Proses klasifikasi dilakukan dengan uji coba fungsi kernel SVM dan menunjukkan kernel terbaik pada penelitian ini adalah RBF dengan tingkat akurasi, sensitivitas, dan spesifisitas mencapai 76.9%.

Penelitian oleh (Farooq et al., 2016) melalui proses segmentasi dengan beberapa algoritma antara lain watershed algorithm, active contour, dan merged segmentation results. Citra yang telah di pre-processing selanjutnya di ekstrasi fitur menggunakan metode GLCM dengan fitur-fitur mean, correlation, homogeneity, contrast, energy, dissimilarity, kurtois, variance, skewness, dan entropy. Fitur-fitur tersebut di klasifikasi dengan menggunakan metod SVM dan Artificial Neural Network (ANN). Metode ANN di implementasikan sebagai metode klasifikasi tingkat dua untuk menyempurnakan hasil klasifikasi metode SVM dengan memeriksa kegagalan klasifikasi oleh metode SVM. Tingkat akurasi

yang dihasilkan mencapai 95.9%

Deteksi kanker kulit yang dilakukan (Eltayef et al., 2017) diawali dengan menghilangkan noise pada citra lesi kanker kulit dan di segmentasi. Segmentasi dilakukandengan menerapkan metode PSO dan MRF. Selanjutnya fitur-fitur citra diekstraksi pada tingkat sub-wilayah (*cluster*) dengan menggunakan K-Means clustering. Fitur-fitur tersebut diklasifikasikan dengan menggunakan metode ANN dan fungsi aktivasi RBF. Tingkat akurasi yang dihasilkan mencapai 86.7%.

Penelitian oleh (Lopez et al., 2017) mengklasifikasi citra kanker kulit menggunakan metode *deep learning* VGGNet. Parameter-parameter yang digunakan yaitu pada inisialisasi probabilitas *dropout* 0.5 dan jumlah batchsize sama dengan 16. Klasifikasi dilakukan berdasarkan data citra yang telah di augmentasi dengan *rescaling*, rotasi, transformasi, dilasi, dan refleksi. Tingkat akurasi terbaik yang didapatkan yaitu sebesar 95.9% dengan jumlah epoch sebanyak 20.

Berdasarkan perbandingan hasil evaluasi klasifikasi menggunakan beberapa metode, dapat disimpulkan metode *deep learning* memiliki kinerja yang lebih baik dibanding metode *machine learninh* konvensional seperti SVM dan ANN. Proses klasifikasi *machine learning* konvensional bergantung pada hasil ekstraksi fitur citra. Hasil ekstraksi fitur dikatakan baik apabila fitur tersebut merepresentasikan citra pada tiap kelasnya. Sedangkan pada algoritma *deep learning* seperti CNN mempelajari fitur-fitur citra berdasarkan area-area citra dengan menggunakan filter, sehingga dapat mengklasifikasi citra lebih baik. Penelitian yang dilakukan oleh (Li et al., 2020) menunjukkan bahwa metode CNN GoogleNet memiliki kinerja yang lebih baik dibanding arsitektur CNN yang lain seperti VGGNet, sehingga pada penelitian ini dapat memperoleh hasil terbaik sebesar 100%.

## 4.7. Integrasi Keislaman

Berkembangnya zaman mendorong umat manusia untuk mempelajari ilmu sains dan teknologi yang dapat dimanfaatkan dalam berbagai aspek kehidupan. Dalam islam, belajar merupakan suatu kewajiban bagi setiap umat manusia. Anjuran belajar bagi setiap umat manusia telah tertulis dalam ayat Al-Qur'an QS. Al-'Alaq ayat 1-5 yang berbunyi:

Artinya: "Bacalah dengan (menyebut) nama Tuhanmu Yang menciptakan, Dia telah menciptakan manusia dari segumpal darah. Bacalah, dan Tuhanmulah Yang Maha Pemurah, Yang mengajar (manusia) dengan perantaraan kalam. Dia mengajarkan kepada manusia apa yang tidak diketahuinya."

Ayat diatas menganjurkan umat manusia untuk mempelajari banyak hal dengan membaca. Bacaan yang dimaksud dalam ayat tersebut merupakan bacaan dengan berbagai objek, salah satunya sains dan teknologi. Belajar juga menjadi salah satu ikhtiar manusia untuk mencapai tujuan yang diinginkan. Seperti halnya manusia, sebuah sistem klasifikasi juga melakukan pembelajaran pada proses training dan pembelajaran fitur dari sebuah citra, sebagaimana tertulis dalam Al-Qur'an surat Ar-Ra'd ayat 11 yang berbunyi:

Artinya: "Bagi manusia ada malaikat-malaikat yang selalu mengikutinya bergiliran, di muka dan di belakangnya, mereka menjaganya atas perintah Allah.

Sesungguhnya Allah tidak merubah keadaan sesuatu kaum sehingga mereka merubah keadaan yang ada pada diri mereka sendiri. Dan apabila Allah menghendaki keburukan terhadap sesuatu kaum, maka tak ada yang dapat menolaknya; dan sekali-kali tak ada pelindung bagi mereka selain Dia."

Pada ayat tersebut diartikan bahwa hasil yang diperoleh sangat berkorelasi dengan ikhtiar yang dilakukannya. Semakin banyak ikhtiar yang dilakukan maka akan diperoleh hasil yang optimal, sebagaimana sistem yang mempelajari banyak data maka hasil yang didapatkan akan optimal. Sebaik-baiknya proses berikhtiar juga diiringi dengan berdoa kepada Allah SWT agar dimudahkan jalannya dalam mencapai tujuan, sebagaimana tertulis pada surat Al-Mukmin ayat 60 yang berbunyi:

Artinya: Dan Tuhanmu berfirman: "Berdoalah kepada-Ku, niscaya akan Kuperkenankan bagimu. Sesungguhnya orang-orang yang menyombongkan diri dari menyembah-Ku akan masuk neraka Jahannam dalam keadaan hina dina".

Dalam mencapai hasil yang maksimal dari proses pembelajaran sistem klasifikasi, membutuhkan waktu yang cukup lama. Hal ini di merepresentasikan bahwa untuk memperoleh hasil yang maksimal dari segala ikhtiar manusia juga membutuhkan kesabaran seperti yang tertulis pada Al-Qur'an pada ayat 153.

Artinya: "Hai orang-orang yang beriman, jadikanlah sabar dan shalat sebagai penolongmu, sesungguhnya Allah beserta orang-orang yang sabar."

# **BAB V**

## **PENUTUP**

## 5.1. Kesimpulan

Berdasarkan hasil pengelolahan data dengan memperhatikan tujuan penelitian maka didapat kesimpulan penelitian sebagai berikut:

- 1. Deteksi dini kanker kulit secara automatis menggunakan CNN GoogleNet bedasarkan klasifikasi data citra dilakukan dengan beberapa tahap. Tahap pertama yaitu dengan melakukan *pre-processing* data yang terdiri dari *croping, resize,* dan *dull razor filtering*. Hasil yang didapat dari penerapan *dull razor filtering* di augmentasi untuk menambah variansi data citra. Augmentasi data memperbanyak data citra yang semula hanya 204 citra menjadi 2040 citra. Metode yang digunakan untuk membangun sistem klasifikasi merupakan metode *Convolutional Neural Network* (CNN). Algoritma CNN memiliki beberapa lapisan yang digunakan untuk pembelajaran fitur dan klasifikasi sesuai dengan arsitektur GoogleNet. Proses ini dipengaruhi oleh persentase pembagian data *training* dan *batchsize*.
- 2. Model terbaik dari penerapan algoritma CNN GoogleNet untuk mendeteksi dini adanya kanker kulit berdasarkan klasifikasi data citra dengan melakukan uji coba persentase pembagian data training dan data testing sebesar 90% dan 100% dengan tingkat akurasi, sensivitas, dan spesifitas sebesar 100%, 100%, dan 100%.

#### 5.2. Saran

Pada penelitian ini memiliki beberapa kekurangan yang dapat diperbaiki. Hal-hal yang dapat dilakukan untuk penelitian mendatang antara lain:

- Mengumpulkan lebih banyak sumber data sehingga pola kanker kulit yang dipelajari oleh sistem semakin beragam. Selain itu variansi data citra diharapkan juga lebih beragam dengan menerapkan beberapa metode augmentasi data.
- 2. Proses klasifikasi menggunakan algoritma CNN GoogleNet membutuhkan waktu yang cukup lama, diharapkan pada penelitian selanjutnya dapat menggabungkan algoritma lain untuk klasifikasi berdasarkan fitur-fitur yang dipelajari dari arsitektur GoogleNet.

# **DAFTAR PUSTAKA**

- Al-Amin, M., Badrul, M., and Ronju, M. (2015). Detection of Cancerous and Non-cancerous Skin by using GLCM Matrix and Neural Network Classifier. *Int. J. Comput. Appl.*, 132(8):44–49.
- Alqumboz, M. N. A. and Abu-naser, S. S. (2019). Avocado Classification Using Deep Learning. 3(12):30–34.
- Alqumboz, M. N. A. and Abu-Naser, S. S. (2020). Avocado Classification Using Deep Learning.
- Anand, R., Shanthi, T., Nithish, M. S., and Lakshman, S. (2020). Face recognition and classification using GoogleNET architecture. In *Soft Comput. Probl. Solving*, pages 261–269. Springer.
- Ansari, U. B. and Sarode, T. (2017). Skin cancer detection using image processing. Int Res J Eng Technol, 4(4):2875–2881.
- Anwar, A. (2019). Difference between Local Response Normalization and Batch Normalization.
- Anwar, S. M., Majid, M., Qayyum, A., Awais, M., Alnowami, M., and Khan, M. K. (2018). Medical Image Analysis using Convolutional Neural Networks: A Review. *J. Med. Syst.*, 42(11):1–13.
- Asyhar, A. H., Foeady, A. Z., Thohir, M., Arifin, A. Z., Haq, D. Z., and Novitasari,D. C. R. (2020). Implementation LSTM Algorithm for Cervical Cancer using

- Colposcopy Data. In 2020 Int. Conf. Artif. Intell. Inf. Commun., pages 485–489. IEEE.
- Attia, M., Hossny, M., Zhou, H., Nahavandi, S., Asadi, H., and Yazdabadi, A. (2019). Digital hair segmentation using hybrid convolutional and recurrent neural networks architecture. *Comput. Methods Programs Biomed.*, 177:17–30.
- Bora, K., Chowdhury, M., Mahanta, L. B., Kundu, M. K., and Das, A. K. (2016). Pap smear image classification using convolutional neural network. *ACM Int. Conf. Proceeding Ser.*
- Bray, F., Ferlay, J., Soerjomataram, I., Siegel, R. L., Torre, L. A., and Jemal, A. (2018). Global cancer statistics 2018: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries. *CA. Cancer J. Clin.*, 68(6):394–424.
- Chen, J., Luo, J., He, X., and Zhu, C. (2020). Evaluation of contrast-enhanced computed tomography (CT) and magnetic resonance imaging (MRI) in the detection of retropharyngeal lymph node metastases in nasopharyngeal carcinoma patients. *Cancer Manag. Res.*, 12:1733–1739.
- Chicco, D. and Jurman, G. (2020). The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation. *BMC Genomics*, 21(1):1–13.
- Chu, J., Guo, Z., and Leng, L. (2018). Object Detection Based on Multi-Layer Convolution Feature Fusion and Online Hard Example Mining. *IEEE Access*, 6:19959–19967.
- Cokun, M., Uçar, A., Yildirim, Ö., and Demir, Y. (2017). Face recognition based

- on convolutional neural network. In 2017 Int. Conf. Mod. Electr. Energy Syst., pages 376–379. IEEE.
- Deng, X., Liu, Q., Deng, Y., and Mahadevan, S. (2016). An improved method to construct basic probability assignment based on the confusion matrix for classification problem. *Inf. Sci.* (*Ny*)., 340-341:250–261.
- Didona, D., Paolino, G., Bottoni, U., and Cantisani, C. (2018). Non melanoma skin cancer pathogenesis overview. *Biomedicines*, 6(1):1–15.
- D'Orazio, J., Jarrett, S., Amaro-Ortiz, A., and Scott, T. (2013). UV radiation and the skin. *Int. J. Mol. Sci.*, 14(6):12222–12248.
- Dorj, U. O., Lee, K. K., Choi, J. Y., and Lee, M. (2018). The Skin Cancer Classification Using Deep Convolutional Neural Network. *Multimed. Tools*Appl., 77(8):9909–9924.
- Elleuch, M., Tagougui, N., and Kherallah, M. (2017). Optimization of DBN using regularization methods applied for recognizing Arabic handwritten script. *Procedia Comput. Sci.*, 108:2292–2297.
- Elsharif, A. A., Dheir, I. M., Soliman, A., Mettleq, A., and Abu-naser, S. S. (2019).

  Potato Classification Using Deep Learning. 3(12):1–8.
- Eltayef, K., Li, Y., Dodo, B. I., and Liu, X. (2017). Skin Cancer Detection in Dermoscopy Images Using Sub-Region Features. In *Int. Symp. Intell. Data Anal.*, pages 75–86. Springer.
- Esteva, A., Kuprel, B., Novoa, R. A., Ko, J., Swetter, S. M., Blau, H. M., and Thrun, S. (2017). Dermatologist-level Classification of Skin Cancer with Deep Neural Networks. *Nature*, 542(7639):115–118.

- Estria, S. R. and Trihadi, D. (2019). Pengaruh Intervensi Psikoedukasi Berbasis Spiritual terhadap Kecemasan Anak Presirkumsisi. *J. Perawat Indones.*, 3(3):221–228.
- Farooq, M. A., Azhar, M. A. M., and Raza, R. H. (2016). Automatic Lesion Detection System (ALDS) for Skin Cancer Classification Using SVM and Neural Classifiers. *Proc. - 2016 IEEE 16th Int. Conf. Bioinforma. Bioeng. BIBE 2016*, pages 301–308.
- Feng, J., Li, F., Lu, S., Liu, J., and Ma, D. (2017). Injurious or noninjurious defect identification from MFL images in pipeline inspection using convolutional neural network. *IEEE Trans. Instrum. Meas.*, 66(7):1883–1892.
- Foeady, A. Z., Novitasari, D. C. R., Asyhar, A. H., and Firmansjah, M. (2019). Automated Diagnosis System of Diabetic Retinopathy Using GLCM Method and SVM Classifier. 2018 5th Int. Conf. Electr. Eng. Comput. Sci. Informatics, pages 154–160.
- Garg, D. and Verma, G. K. (2020). Emotion Recognition in Valence-Arousal Space from Multi-channel EEG data and Wavelet based Deep Learning Framework. *Procedia Comput. Sci.*, 171(2019):857–867.
- Geetha, M. P. and Selvi, V. (2015). An Impression of Cancers and Survey of Techniques in Image Processing for Detecting Various Cancers: A Review. pages 236–242.
- Gonzales, R. C. and Woods, R. E. (2018). *Digital Image Processing*. Pearson, fourth edition.

- Gordon, R. (2013). Skin cancer: an overview of epidemiology and risk factors. In *Semin. Oncol. Nurs.*, volume 29, pages 160–169. Elsevier.
- Grigoryan, A. M. and Agaian, S. S. (2018). Color image enhancement via combine homomorphic ratio and histogram equalization approaches: Using underwater images as illustrative examples. *Int. J. Futur. Revolut. Comput. Sci. Commun. Eng.*, 4(5):36–47.
- Hamouda, S., Hassan, A., Wahed, M. E., Ail, M., and Farouk, O. (2020). Tuning to Optimize SVM Approach for Breast Cancer Diagnosis with Blood Analysis Data. *SSRN Electron. J.*
- Irigaray, P., Newby, J. A., Clapp, R., Hardell, L., Howard, V., Montagnier, L., Epstein, S., and Belpomme, D. (2007). Lifestyle-related factors and environmental agents causing cancer: An overview. *Biomed. Pharmacother.*, 61(10):640–658.
- Jasitha, P., Dileep, M. R., and Divya, M. (2019). Venation Based Plant Leaves Classification Using GoogLeNet and VGG. In 2019 4th Int. Conf. Recent Trends Electron. Information, Commun. Technol., pages 715–719. IEEE.
- Jensen, A. O., Lamberg, A. L., and Olesen, A. B. (2010). Epidemiology of Non-melanoma Skin Cancer. Non-Surgical Treat. Keratinocyte Ski. Cancer, 146:15–24.
- Kalash, M., Rochan, M., Mohammed, N., Bruce, N. D., Wang, Y., and Iqbal,
  F. (2018). Malware Classification with Deep Convolutional Neural Networks.
  2018 9th IFIP Int. Conf. New Technol. Mobil. Secur. NTMS 2018 Proc., 2018-January:1–5.

- Kaltsum, L. U. (2018). Cobaan Hidup dalam Al-Qur'an (Studi Ayat-Ayat Fitnah dengan Aplikasi Metode Tafsir Tematik). *Ilmu Ushuluddin*, 5(2):107–138.
- Kavitha, K. R., Gopinath, A., and Gopi, M. (2017). Applying improved SVM classifier for leukemia cancer classification using FCBF. 2017 Int. Conf. Adv. Comput. Commun. Informatics, ICACCI 2017, 2017-January:61–66.
- Ker, J., Wang, L., Rao, J., and Lim, T. (2017). Deep Learning Applications in Medical Image Analysis. *IEEE Access*, 6:9375–9379.
- Kiani, K. and Sharafat, A. R. (2011). E-shaver: An improved DullRazor ® for digitally removing dark and light-colored hairs in dermoscopic images. *Comput. Biol. Med.*, 41(3):139–145.
- Kim, J. H., Seo, S. Y., Song, C. G., and Kim, K. S. (2019). Assessment of Electrocardiogram Rhythms by GoogLeNet Deep Neural Network Architecture. J. Healthc. Eng., 2019.
- Kolarsick, P. A. J., Kolarsick, M. A., and Goodwin, C. (2011). Anatomy and physiology of the skin. *J. Dermatol. Nurses. Assoc.*, 3(4):203–213.
- Krizhevsky, A., Sutskever, I., and Hinton, G. E. (2012). Imagenet classification with deep convolutional neural networks. In *Adv. Neural Inf. Process. Syst.*, pages 1097–1105.
- Kudva, V., Prasad, K., and Guruvare, S. (2018). Automation of detection of cervical cancer using convolutional neural networks. *Crit. Rev. Biomed. Eng.*, 46(2):135–145.
- Kumar, R., Deep, G., and Agarwal, R. (2015). An Overview of Ultraviolet B

- Radiation-Induced Skin Cancer Chemoprevention by Silibinin. *Curr. Pharmacol. Reports*, 1(3):206–215.
- Kumar, T. and Verma, K. (2010). A Theory Based on Conversion of RGB image to Gray image. *Int. J. Comput. Appl.*, 7(2):5–12.
- Layode, O., Alam, T., and Rahman, M. M. (2019). Deep Learning Based Integrated Classification and Image Retrieval System for Early Skin Cancer Detection. In 2019 IEEE Appl. Imag. Pattern Recognit. Work., pages 1–7. IEEE.
- Lecun, Y., Bengio, Y., and Hinton, G. (2015). Deep learning. *Nature*, 521(7553):436–444.
- Lee, T., Ng, V., Gallagher, R., Coldman, A., and McLean, D. (1997). Dullrazor®:

  A software approach to hair removal from images. *Comput. Biol. Med.*, 27(6):533–543.
- Li, Y., Wang, H., Dang, L. M., Sadeghi-Niaraki, A., and Moon, H. (2020). Crop pest recognition in natural scenes using convolutional neural networks. *Comput. Electron. Agric.*, 169:105174.
- Liu, K., Kang, G., Zhang, N., and Hou, B. (2018). Breast Cancer Classification Based on Fully-Connected Layer First Convolutional Neural Networks. *IEEE Access*, 6(c):23722–23732.
- Lopez, A. R., Giro-i Nieto, X., Burdick, J., and Marques, O. (2017). Skin lesion classification from dermoscopic images using deep learning techniques. In 2017 13th IASTED Int. Conf. Biomed. Eng., pages 49–54. IEEE.
- Ludwig, J. (2013). Image convolution. Portl. State Univ.

- Ma, M. (2020). Infrared pedestrian detection algorithm based on multimedia image recombination and matrix restoration. *Multimed. Tools Appl.*, 79(13):9267–9282.
- Maglogiannis, I. and Delibasis, K. (2015). Hair removal on dermoscopy images. *Proc. Annu. Int. Conf. IEEE Eng. Med. Biol. Soc. EMBS*, 2015-November:2960–2963.
- Marks, J. (2020). What Are the Different Types of Skin Cancer?
- Meng, Q., Wang, H., Xu, W., and Zhang, Q. (2018). A coupling method incorporating digital image processing and discrete element method for modeling of geomaterials. *Eng. Comput.*
- Mikołajczyk, A. and Grochowski, M. (2018). Data Augmentation for Improving Deep Learning in Image Classification Problem. 2018 Int. Interdiscip. PhD Work. IIPhDW 2018, pages 117–122.
- Mu'allim, A. (2016). Meraih Hikmah dibalik Peristiwa Gempa Bumi (Bagaimana Seorang Mukmin Menyikapi Terpaan Musibah). *UNISIA*, (56):209–213.
- Munir, K., Elahi, H., Ayub, A., Frezza, F., and Rizzi, A. (2019). Cancer diagnosis using deep learning: A bibliographic review. *Cancers (Basel).*, 11(9):1–36.
- Nagpal, C. and Dubey, S. R. (2019). A Performance Evaluation of Convolutional Neural Networks for Face Anti Spoofing. *Proc. Int. Jt. Conf. Neural Networks*, 2019-July(July):1–8.
- Naves, L. B., Dhand, C., Venugopal, J. R., Rajamani, L., Ramakrishna, S., and Almeida, L. (2017). Nanotechnology for the treatment of melanoma skin cancer. *Prog. Biomater.*, 6(1-2):13–26.

- Padmavathi, K. and Thangadurai, K. (2016). Implementation of RGB and grayscale images in plant leaves disease detection Comparative study. *Indian J. Sci. Technol.*, 9(6):4–9.
- Pathology and Laboratory Medical (2016). Neoplasms and Cancer.
- Perez, L. and Wang, J. (2017). The Effectiveness of Data Augmentation in Image Classification using Deep Learning.
- Pham, T.-C., Luong, C.-M., Visani, M., and Hoang, V.-D. (2018). Deep CNN and data augmentation for skin lesion classification. In *Asian Conf. Intell. Inf. Database Syst.*, pages 573–582. Springer.
- Rahman, F., Ihsan, M., Pristianto, A., Khadijah, S., and Budi, I. S. (2019). Terapi Latihan Komprehensif untuk Penderita Penyakit Paru Obstruktif Kronik: Case Report. *9th Univ. Res. Colloqium*, 9(1).
- Rashid, S. (2017). Cancer and chemoprevention: An overview. *Cancer Chemoprevention An Overv.*, (Isaacs 2009):1–173.
- Ruuska, S., Hämäläinen, W., Kajava, S., Mughal, M., Matilainen, P., and Mononen, J. (2018). Evaluation of the confusion matrix method in the validation of an automated system for measuring feeding behaviour of cattle. *Behav. Processes*, 148:56–62.
- Saba, T., Khan, M. A., Rehman, A., and Marie-Sainte, S. L. (2019). Region Extraction and Classification of Skin Cancer: A Heterogeneous framework of Deep CNN Features Fusion and Reduction. *J. Med. Syst.*, 43(9).
- Seo, Y. and Shin, K.-s. (2019). Hierarchical convolutional neural networks for fashion image classification. *Expert Syst. Appl.*, 116:328–339.

- Shafiq, S., Prasad, P. W., Alsadoon, A., Ali, S., and Elchouemi, A. (2018).
  Computer aided early detection and classification of malignant melanoma. *Proc.* 2018 10th Int. Conf. Comput. Intell. Commun. Networks, CICN 2018, pages 92–97.
- Shanthi, T. and Sabeenian, R. S. (2019). Modified Alexnet architecture for classification of diabetic retinopathy images go. 76:56–64.
- Sharma, V., Garg, A., and Thenmalar, S. (2020). A survey on Classification of malignant melanoma and Benign Skin Lesion by Using Machine A survey on Classification of malignant melanoma and Benign Skin Lesion by Using Machine Learning Techniques.
- Shorten, C. and Khoshgoftaar, T. M. (2019). A survey on Image Data Augmentation for Deep Learning. *J. Big Data*, 6(1).
- Siegel, R. L., Miller, K. D., and Jemal, A. (2020). Cancer statistics, 2020. *CA. Cancer J. Clin.*, 70(1):7–30.
- Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., and Salakhutdinov, R. (2014). Dropout: a simple way to prevent neural networks from overfitting. *J. Mach. Learn. Res.*, 15(1):1929–1958.
- Srividya, T. D. and Arulmozhi, V. (2019). A Review of Threshold based Segmentation for Skin Cancer with Image Processing. (5):225–228.
- Susilo, M. M., Wonohadidjojo, D. M., Sugianto, N., and Al., E. (2017). Pengenalan Pola Karakter Bahasa Jepang Hiragana Menggunakan 2D Convolutional Neural Network. J. Inform. dan Sist. Inf. Univ. Ciputra, 03(02):28–36.

- Tabik, S., Peralta, D., Herrera-Poyatos, A., and Herrera, F. (2017). A snapshot of image Pre-Processing for convolutional neural networks: Case study of MNIST.
  Int. J. Comput. Intell. Syst., 10(1):555–568.
- Tarigan, A. K., Nasution, S. D., Suginam, S., and Karim, A. (2016).
  Aplikasi Pembelajaran Citra Dengan Menggunakan Metode Computer Assisted
  Instruction (CAI). JURIKOM (Jurnal Ris. Komputer), 3(4).
- Thohir, M., Foeady, A. Z., Novitasari, D. C. R., Arifin, A. Z., Phiadelvira, B. Y., and Asyhar, A. H. (2020). Classification of Colposcopy Data Using GLCM-SVM on Cervical Cancer. In *2020 Int. Conf. Artif. Intell. Inf. Commun.*, pages 373–378. IEEE.
- Veitch, A. M., Uedo, N., Yao, K., and East, J. E. (2015). Optimizing early upper gastrointestinal cancer detection at endoscopy. *Nat. Rev. Gastroenterol. Hepatol.*, 12(11):660–667.
- Visa, S., Ramsay, B., Ralescu, A. L., and Van Der Knaap, E. (2011). Confusion Matrix-based Feature Selection. *MAICS*, 710:120–127.
- Wang, S. H., Lv, Y. D., Sui, Y., Liu, S., Wang, S. J., and Zhang, Y. D. (2018a).
  Alcoholism Detection by Data Augmentation and Convolutional Neural Network with Stochastic Pooling. *J. Med. Syst.*, 42(1).
- Wang, S. H., Muhammad, K., Hong, J., Sangaiah, A. K., and Zhang, Y. D. (2020).
  Alcoholism identification via convolutional neural network based on parametric
  ReLU, dropout, and batch normalization. *Neural Comput. Appl.*, 32(3):665–680.
- Wang, S. H., Phillips, P., Sui, Y., Liu, B., Yang, M., and Cheng, H. (2018b). Classification of Alzheimer's Disease Based on Eight-Layer Convolutional

- Neural Network with Leaky Rectified Linear Unit and Max Pooling. *J. Med. Syst.*, 42(5):85.
- Xu, J., Zhang, Y., and Miao, D. (2020). Three-way confusion matrix for classification: A measure driven view. *Inf. Sci.* (*Ny*)., 507:772–794.
- Yunizar, I., Widiyanto, D., and Falih, N. (2020). Identifikasi Keganasan Tumor Kulit pada Citra Dermoskopi dengan Metode Support Vector Machine. *Senamika*, 1(2):733–746.
- Zhang, A., Lipton, Z. C., Li, M., and Smola, A. J. (2020a). Dive into Deep Learning. 2020. *URL https//d2l. ai*.
- Zhang, X., Pan, W., Bontozoglou, C., Chirikhina, E., Chen, D., and Xiao, P. (2020b). Skin Capacitive Imaging Analysis Using Deep Learning GoogLeNet, volume 1229 AISC. Springer International Publishing.
- Zmudzinski, L. (2018). Deep learning Guinea pig image classification using NVIDIA DIGITS and GoogLeNet. *CEUR Workshop Proc.*, 2240.