

**SISTEM DIAGNOSIS OSTEOARTHRITIS LUTUT
BERDASARKAN CITRA X-RAY MENGGUNAKAN METODE
CNN JENIS RESNET**

PROPOSAL SKRIPSI



**UIN SUNAN AMPEL
S U R A B A Y A**

Disusun Oleh

NUR HIDAYAH

H92219055

**PROGRAM STUDI MATEMATIKA
FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS ISLAM NEGERI SUNAN AMPEL
SURABAYA**

2022

PERNYATAAN KEASLIAN

LEMBAR PERSETUJUAN PEMBIMBING

PENGESAHAN TIM PENGUJI SKRIPSI

DAFTAR ISI

BAB I

PENDAHULUAN

1.1 Latar Belakang Masalah

Manusia merupakan makhluk Allah yang senantiasa hidup berdampingan dengan beraneka ragam ujian. Allah SWT menurunkan ujiannya kepada manusia tidak serta merta tanpa disertai sebuah alasan. Bukan hanya karena sebuah kesalahan yang dilakukan oleh manusia, namun ujian juga dapat diturunkan untuk menguji keimanan dan kesabaran, sebagaimana termaktub dalam Al-Quran Surah Al-‘Ankabut ayat 2 yang berbunyi:

أَحْسِبِ النَّاسَ أَنْ يُتْرَكُوا أَنْ يَقُولُوا آمَنَّا وَهُمْ لَا يُفْتَنُونَ

Artinya: Apakah manusia mengira bahwa mereka akan dibiarkan hanya dengan mengatakan, “Kami telah beriman” dan mereka tidak diuji?

Ayat tersebut menjelaskan bahwa setiap orang pasti akan diuji, karena keimanan seseorang tidak dapat dibuktikan hanya dengan sebuah pernyataan “kami telah beriman kepada Allah”. Hakikat iman yang sesungguhnya adalah keteguhan dan kesabaran dalam menghadapi segala bentuk ujian yang diberikan. Sabar dalam menghadapi ujian yang menimpa diri memang bukan hal yang mudah, karena terkadang bentuk ujian yang datang dianggap sangat berat. Oleh karena itu, Allah SWT memberikan balasan yang sangat dahsyat untuk orang-orang yang sabar, sebagaimana dijelaskan dalam Al-Quran Surah Hud ayat 11 yang berbunyi:

إِلَّا الَّذِينَ صَبَرُوا وَعَمِلُوا الصَّالِحَاتِ أُولَٰئِكَ لَهُمْ مَغْفِرَةٌ وَأَجْرٌ كَبِيرٌ

Artinya: Kecuali orang-orang yang sabar, dan mengerjakan kebajikan, mereka akan memperoleh ampunan dan pahala yang besar.

Maksud dari ayat tersebut adalah Allah SWT akan memberikan balasan berupa ampunan dan pahala yang besar di akhirat kelak bagi orang-orang yang mampu bersabar terhadap segala ujian yang diberikan dan tetap mengerjakan kebajikan ketika diberi kebahagiaan. Salah satu bentuk ujian dari Allah yang sering diberikan kepada manusia adalah berupa penyakit. Berbagai macam jenis penyakit dapat menyerang tubuh manusia, baik penyakit yang menular maupun tidak menular. Penyakit Tidak Menular (PTM) seringkali tidak terdeteksi sejak dini karena minim atau bahkan tidak menunjukkan gejala. Oleh karena itu, tingkat kematian yang disebabkan oleh PTM ini juga terbilang sangat tinggi. Pada tahun 2021, *World Health Organization* (WHO) menjelaskan bahwa setiap tahunnya PTM membunuh sekitar 41 juta jiwa atau setara dengan 71% dari seluruh kematian global.

Salah satu penyakit tidak menular yang kerap kali diderita oleh masyarakat adalah penyakit arthritis. Arthritis merupakan penyakit yang ditunjukkan dengan adanya pembengkakan dan nyeri pada sendi (Li, 2022). Arthritis ini adalah salah satu penyakit kronis yang biasanya menyerang pria dan wanita pada usia 55 tahun keatas. Berbagai macam tipe dari penyakit arthritis meliputi osteoarthritis, rheumatoid arthritis, psoriatic arthritis, fibromyalgia, dan gout (Khaleghi, 2020). Osteoarthritis (OA) adalah jenis arthritis yang paling umum terjadi (Venkatachalam et al., 2018). OA dapat mempengaruhi kinerja seluruh bagian dari sendi, yang melibatkan tulang rawan, tulang subkondral, sinovium, kapsul, ligamen, dan otot-otot di sekitarnya (Hussain et al., 2020). Secara klinis, OA dapat ditandai dengan nyeri sendi, kekakuan, dan keterbatasan fungsional (Yahaya et al., 2021). OA ini dapat menyerang pada bagian jari, lutut, dan pinggul

(Victoria, 2022). Osteoarthritis lutut merupakan jenis osteoarthritis yang paling umum terjadi (Yoo et al., 2018).

Osteoarthritis lutut adalah salah satu penyakit sendi degeneratif yang paling banyak menyebabkan kecacatan pada usia lanjut (Kan et al., 2019). Prevalensi OA lutut akan terus meningkat seiring dengan bertambahnya usia dan obesitas. OA lutut menyerang sekitar 13% wanita dan 10% pria yang berusia 60 tahun keatas. Dan pada usia 70 tahun keatas, prevalensinya meningkat hingga 40%. Dari data tersebut, menunjukkan bahwa prevalensi OA lutut pada pria wanita lebih tinggi daripada pada pria. Salah satu penelitian menunjukkan bahwa hanya 15% dari total kasus OA lutut menunjukkan adanya gejala (Hsu & Siwiec, 2018). OA lutut tidak dapat disembuhkan kecuali dengan melakukan artroplasti lutut karena dianggap efektif pada stadium lanjut. Namun, tindakan artroplasti ini membutuhkan biaya yang sangat besar (Cui et al., 2020). Oleh karena itu, penting untuk melakukan pencegahan dan pengobatan pada tahap awal penyakit. Hal tersebut dapat dilakukan dengan adanya deteksi dini guna meminimalisir dampak selanjutnya.

Seiring dengan perkembangan teknologi, proses diagnosa dapat dengan mudah dilakukan menggunakan bantuan *Artificial Intelligence* (AI). Salah satu penerapan AI adalah pada metode *deep learning*. Metode ini telah banyak diterapkan untuk klasifikasi, dan telah terbukti menjadi metode terbaik dalam ekstraksi fitur, pencitraan medis, dan klasifikasi objek (Tekade & Rajeswari, 2018). Macam-macam metode *deep learning* yang umum digunakan antara lain *Artificial Neural Network* (ANN), *Deep Neural Network* (DNN), *Recurrent Neural Network* (RNN), dan *Convolutional Neural Network* (CNN) (Koklu et al., 2021).

Metode CNN mampu mempelajari berbagai atribut yang diinputkan dengan baik, sehingga CNN mampu memperoleh karakteristik data lebih detail dan memiliki kemampuan deteksi yang

lebih baik dibandingkan ANN dan DNN (Y. Wang et al., 2020)(Feng et al., 2021). Pada penelitian yang mengenai identifikasi kesalahan yang didasarkan pada sinyal untrasonik, CNN mampu mendapatkan nilai AUC sebesar 99.8%, sedangkan RNN dan DNN hanya menghasilkan nilai AUC 96.1% dan 98.7% (Q. Zhang et al., 2018). Selain itu, pada penelitian mengenai klasifikasi citra medis menggunakan 3 metode yakni CNN, ANN, dan *Support Vector Machine* (SVM), CNN tetap mengungguli 2 metode lainnya. Pada penelitian tersebut, akurasi yang diberikan oleh CNN adalah 100.0%, sedangkan ANN dan SVM secara berturut-turut menghasilkan akurasi sebesar 88.9% dan 94.4% (Maruyama et al., 2018). CNN memiliki beberapa jenis arsitektur, diantaranya meliputi AlexNet, MobileNet, GoogleNet, ResNet, dan lain sebagainya (Naz et al., 2022). ResNet merupakan arsitektur CNN yang terkenal pada tahun 2015 dan menjadi pemenang pada kompetisi *ImageNet Large Scale Visual Challenge 2015* (ILSVRC 2015). Arsitektur ResNet memiliki keunggulan mampu melatih ratusan hingga ribuan lapisan tanpa mengurangi kinerjanya. Arsitektur ini memiliki kemampuan representasi yang kuat meskipun melakukan kinerja yang banyak (Razzak et al., 2020).

Penelitian sebelumnya membahas mengenai klasifikasi COVID-19 dengan membandingkan beberapa metode *deep learning* yang meliputi ResNet, GoogleNet, VGG-16, AlexNet, MobileNet, dan Inception-V3. Hasil dari penelitian tersebut menunjukkan bahwa nilai sensitivitas yang diberikan metode ResNet adalah 100.0% dan melampaui nilai sensitivitas yang dihasilkan oleh arsitektur lainnya. Arsitektur lainnya hanya mampu memberikan nilai sensitivitas yang secara berturut-turut disebutkan sebagai berikut: 96.6%, 96.6%, 98.3%, 93.3%, dan 88.3% (Maheen et al., 2021). Selain itu, ResNet juga telah banyak diaplikasikan pada penelitian-penelitian sebelumnya. Salah satunya diterapkan pada penelitian mengenai klasifikasi kanker melanoma. Pada penelitian tersebut, ResNet mampu memberikan akurasi sebesar 83.0%

(Budhiman et al., 2019). Selain itu, penelitian menggunakan ResNet juga dilakukan pada klasifikasi diabetik retinopati dan mampu memberikan hasil akurasi sebesar 86.67% (Elswah et al., 2020). Pada penelitian lain, ResNet diaplikasikan untuk deteksi karsinoma duktal invasif dan memberikan akurasi sebesar 91.0% (Chapala & Sujatha, 2020).

Berdasarkan penelitian-penelitian sebelumnya, metode CNN dengan arsitektur ResNet memiliki kinerja yang baik dalam proses klasifikasi gambar, sehingga penelitian ini memanfaatkan arsitektur CNN ResNet untuk mendiagnosis osteoarthritis lutut berdasarkan data citra x-ray. Penelitian ini diharapkan dapat membangun sistem diagnosis citra osteoarthritis lutut menggunakan metode CNN jenis ResNet. Dengan itu, sistem yang telah dibuat diharapkan kedepannya dapat menjadi alternatif sebagai pendeteksi dini osteoarthritis lutut.

1.2 Rumusan Masalah

Berdasarkan permasalahan yang telah dijelaskan pada latar belakang, rumusan masalah pada penelitian ini adalah sebagai berikut:

1. Bagaimana proses diagnosis osteoarthritis lutut berdasarkan data citra X-ray menggunakan *Convolutional Neural Network* (CNN) jenis ResNet?
2. Bagaimana model optimal diagnosis osteoarthritis lutut menggunakan *Convolutional Neural Network* (CNN) jenis ResNet berdasarkan uji coba pembagian data, *dropout*, dan *minibatchsize*?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah diatas, penelitian ini dibuat dengan tujuan sebagai berikut:

1. Dapat mendiagnosis osteoarthritis lutut berdasarkan data citra X-ray menggunakan *Convolutional Neural Network* (CNN) jenis ResNet dengan akurasi yang tinggi.
2. Dapat mengetahui model optimal diagnosis osteoarthritis lutut menggunakan *Convolutional Neural Network* (CNN) jenis ResNet berdasarkan uji coba pembagian data, *dropout*, dan *minibatchsize*.

1.4 Manfaat Penelitian

Penelitian ini diharapkan dapat bermanfaat untuk berbagai lapisan masyarakat, seperti yang tertulis sebagai berikut:

1. Manfaat Teoritis

Penelitian ini diharapkan dapat menjadi referensi bagi penulis-penulis selanjutnya yang mengangkat topik mengenai diagnosis osteoarthritis lutut atau dalam proses diagnosis menggunakan arsitektur CNN jenis ResNet.

2. Manfaat Praktis

- a. Bagi Penulis

Menambah pengetahuan baru bagi penulis dalam memahami penyakit osteoarthritis lutut dan proses diagnosisnya menggunakan arsitektur CNN jenis ResNet.

- b. Bagi Ahli Medis

Membantu ahli medis dalam mendiagnosis osteoarthritis lutut dengan lebih efisien yang mampu mendapatkan akurasi yang maksimal

c. Bagi Masyarakat Umum

Memberi edukasi kepada masyarakat umum tentang osteoarthritis lutut dan menambah keilmuan dalam bidang sains, teknologi maupun kedokteran.

1.5 Batasan Masalah

Ruang lingkup penelitian ini akan sangat luas jika tidak ada batasan permasalahan. Batasan permasalahan yang digunakan dalam penelitian ini yaitu:

1. Data citra yang digunakan pada penelitian ini merupakan data citra x-ray osteoarthritis lutut pada 5 kelas (grade 0, grade 1, grade 2, grade 3, dan grade 4).
2. Tahap *preprocessing* yang digunakan pada penelitian ini yaitu *cropping* dan *resizing* citra.
3. Metode pendekatan yang digunakan untuk diagnosis osteoarthritis lutut adalah CNN dengan arsitektur ResNet.
4. Perangkat komputer penunjang penelitian ini yakni *Personal Computer* (PC) dengan spesifikasi ...

1.6 Sistematika Penulisan

Sistematika pada penelitian ini secara umum terdiri dari tiga bagian utama, yaitu bagian awal, bagian isi, dan bagian akhir.

1. Bagian Awal

Bagian ini berisi halaman judul, lembar persetujuan, pernyataan keaslian, motto, kata pengantar, abstrak, daftar isi, dan daftar gambar.

2. Bagian Isi

Bagian ini merupakan pokok pembahasan yang terdiri dari beberapa bab terkait penelitian ini, meliputi:

a. BAB I Pendahuluan

Berisi latar belakang masalah, perumusan masalah, tujuan penelitian, manfaat penelitian, metodologi penelitian, dan sistematika penulisan.

b. BAB II Tinjauan Pustaka

Berisi tentang *literature review* yang menjelaskan definisi, teori, dan persamaan yang digunakan dalam penelitian. Diantaranya meliputi osteoarthritis, osteoarthritis lutut, Citra, *Convolutional Neural Network* (CNN), ResNet, *confusion matrix*, dan integrasi osteoarthritis lutut dalam Islam.

c. BAB III Metodologi Penelitian

Berisi jenis penelitian, pengumpulan data, dan kerangka penelitian.

d. BAB IV Hasil dan Pembahasan

Berisi tentang pemaparan hasil yang didapat pada penelitian ini, dan analisis hasil untuk penarikan kesimpulan sesuai dengan tujuan penelitian.

e. BAB V Penutup

Berisi tentang kesimpulan dan saran dari hasil penelitian.

3. Bagian Akhir

Bagian ini berisi daftar pustaka dan lampiran-lampiran.

BAB II

TINJAUAN PUSTAKA

2.1. Osteoarthritis (OA)

OA merupakan peradangan pada sendi yang disebabkan karena penipisan dan kerusakan tulang rawan (Pavone et al., 2021). OA akan mempengaruhi struktur sendi penderitanya, termasuk pada tulang rawan artikular, tulang subkondral, meniskus, membran sinovial, dan bantalan lemak infrapatellar. Perubahan yang terjadi karena OA ini dapat berupa degradasi tulang rawan, tulang subkondral, pembentukan osteofit, serta perubahan sinovium dan kapsul sendi (Chow & Chin, 2020).

Fungsi sendi pada penderita OA dapat berubah dari tugas awalnya. Hal tersebut dikarenakan komponen inflamasi (sitokin dan kemokin) diproduksi oleh kondrosit dan sinoviosit. Selain itu, bantalan lemak infrapatellar mengandung sel kekebalan berupa makrofag dan sel T dalam jumlah yang besar. Sehingga, bantalan lemak infrapatellar mampu bertindak sebagai mediator inflamasi. Mediator ini merubah pemberian sinyal sel, ekspresi gen dan perilaku jaringan sendi. Perubahan transduksi sinyal dapat meningkatkan aktivasi jalur inflamasi yang menyebabkan lebih banyaknya senyawa inflamasi dan enzim dilepaskan. Dengan demikian, fungsi anatomi dan fisiologis dari sendi tersebut akan berubah.

2.2. Osteoarthritis Lutut

Osteoarthritis lutut atau yang dikenal dengan radang sendi lutut merupakan masalah kesehatan yang mengenai tulang dan sendi di sekitar lutut (Jones et al., 2019). OA lutut ini mempengaruhi 3 kompartemen yang ada pada sendi lutut yaitu medial, lateral, dan sendi patellofemoral (Lespasio et al., 2017). Pada sendi lutut yang merupakan sendi sinovial terbesar

mausia, terdapat pertemuan antara tulang femur bagian bawah dan tulang tibia bagian atas yang pada masing-masing ujungnya terdapat tulang rawan (Jang et al., 2021). Pada penderita OA lutut, tulang rawan yang ada pada dua sendi tersebut mengalami kerusakan yang menyebabkan tulang femur dan tibia bergesekan secara langsung dan menimbulkan rasa nyeri (Thienkarochanakul et al., 2020).

OA lutut dapat terjadi karena adanya beberapa penyebab, diantaranya adalah karena penuaan, inflamasi lokal, faktor genetik, tekanan mekanik dan proses sel, serta biokimia. Gejala yang ditimbulkan karena penyakit OA lutut ini meliputi nyeri pada sendi, pembengkakan sendi, perubahan bentuk sendi, sendi terasa kaku dan tidak dapat digerakkan dengan sempurna (Peterson, 2020). Terdapat dua alternatif pengobatan pada OA lutut yaitu metode konservatif dan operatif. Pengobatan konservatif akan dipilih ketika awal pasien menderita osteoarthritis, pengobatan konservatif meliputi modifikasi aktifitas fisik, menurunkan berat badan, latihan memperkuat otot dan pemberian obat pereda nyeri. Apabila pengobatan konservatif dianggap gagal, maka dilakukan terapi operatif yang meliputi perbaikan tulang rawan, osteotomi dan penggantian sendi lutut (Philips et al., 2022).

2.3. Citra Digital

Citra digital merupakan representasi dari suatu objek secara visual (Haq, 2020). Citra digital juga dapat dikatakan sebagai representasi dari fungsi intensitas cahaya dalam bentuk diskrit pada bidang dua dimensi (Damanik, 2022). Secara matematis, citra digital adalah fungsi dua dimensi $f(x,y)$ yang merupakan proyeksi objek 3 dimensi ke dalam bidang 2 dimensi, dimana x,y menyatakan koordinat spasial pada citra, sedangkan amplitudo dari fungsi f pada titik x,y menyatakan derajat keabuan (Sihotang, 2019). Selain itu, citra digital juga merupakan representasi matriks dari citra dua dimensi yang berisi informasi mengenai nilai piksel pada


gambar (Dougherty, 2020). Citra digital dengan $I \times J$ piksel dapat direpresentasikan dengan matriks baris I dan kolom J seperti yang ditunjukkan pada Persamaan 2.1.

$$f(x,y) = \begin{bmatrix} f(1,1) & f(1,2) & f(1,3) & \cdots & f(1,J) \\ f(2,1) & f(2,2) & f(2,3) & \cdots & f(2,J) \\ f(3,1) & f(3,2) & f(3,3) & \cdots & f(3,J) \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ f(I,1) & f(I,2) & f(I,3) & \cdots & f(I,J) \end{bmatrix} \quad (2.1)$$

Citra digital dapat dikategorikan berdasarkan tingkat warnanya, diantaranya adalah sebagai berikut:

2.3.1 Citra RGB


Citra RGB merupakan citra yang tersusun dari tiga kombina warna primer yaitu *Red* (R), *Green* (G), dan *Blue* (B) (Rizani, 2021). Model dari citra RGB dapat diwakilli oleh sistem koordinat kartesian, seperti yang ditampilkan pada Gambar 2.2.



Gambar 2.3. Koordinat Kartesius Citra RGB

Berdasarkan Gambar 2.3, koordinat sumbu x,y,z mewakili R,G,B dimana setiap titik dalam ruangan tiga dimensi tersebut merepresentasikan kecerahan yang berada pada rentang 0 hingga 1. Pada koordinat awal (0,0,0) gambar akan memiliki warna hitam, sedangkan pada simpul terjauh dengan koordinat (1,1,1) berwarna putih. Garis lurus antara hitam dan putih disebut sebagai garis abu-abu yang berubah dari hitam menuju putih. Selain garis dan titik-titik tersebut, tiga titik sudut lainnya merupakan warna pelengkap dari tiga warna primer yaitu kuning, cyan, dan magenta (Xiong et al., 2018).

Setiap piksel pada citra RGB memiliki rentang antara 0 sampai dengan 255 dan mempunyai 8 bit pada tiap lapisannya (Singh, 2021). Sehingga secara keseluruhan citra RGB mempunyai 24 bit (Szyc, 2019). Contoh citra RGB dan informasi mengenai nilai-nilai pikselnya ditunjukkan pada Gambar 2.4.




Gambar 2.4. Contoh Citra RGB dan Nilai Pikselnya

Sumber: (Kurnianto, 2013)

2.3.2 Citra *Grayscale*

Citra *grayscale* adalah gambar monokrom yang hanya memiliki satu warna. Citra *grayscale* tidak memiliki informasi warna seperti citra RGB, namun hanya menunjukkan informasi kecerahan citra yang bervariasi mulai dari intensitas terendah yang berwarna hitam hingga berwarna putih yang merupakan intensitas tertinggi (Agrawal et al., 2021). Derajat keabuan citra *grayscale* berada pada rentang 0 hingga 255 (Allaam & Wibowo, 2021). Contoh citra *grayscale* ditunjukkan pada Gambar 2.5.




Gambar 2.5. Contoh Citra *Grayscale* dan Nilai Pikselnya

Sumber: (Kurnianto, 2013)

2.3.3 Citra Biner

Citra Biner merupakan jenis citra yang hanya memiliki dua nilai saja, yaitu 0 dan 1. Nilai 0 merepresentasikan warna hitam, sedangkan nilai 1 merepresentasikan warna putih (Sathesh & Adam, 2021). Citra biner ini merupakan citra yang paling sederhana dan paling ringan dalam penyimpanannya. Contoh citra biner ditunjukkan pada Gambar 2.6.



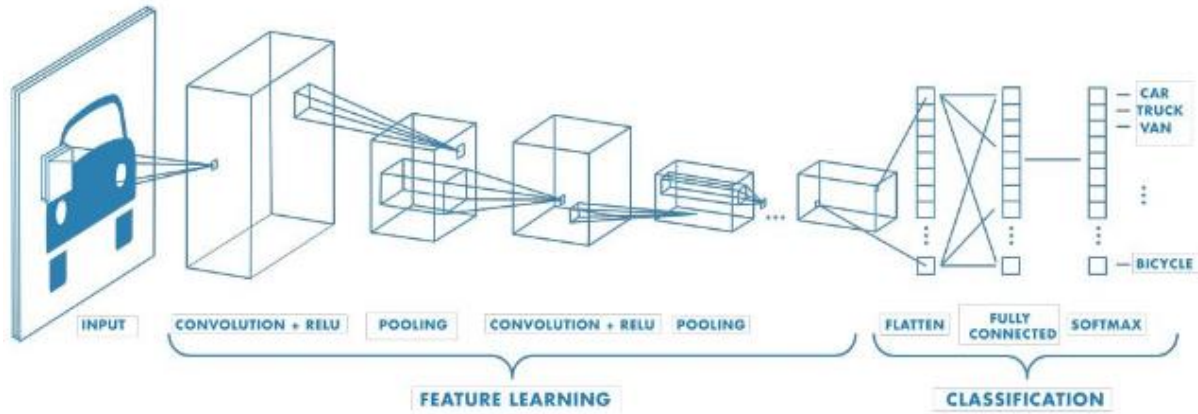
Gambar 2.6. Contoh Citra Biner dan Nilai Pikselnya

Sumber: (Kurnianto, 2013)

2.4. *Convolutional Neural Network (CNN)*

CNN atau yang juga sering dikenal dengan ConvNet merupakan bagian dari *Deep Neural Networks* yang biasanya digunakan untuk menganalisis data citra (El-Kahlout & Abu-Naser, 2020). CNN adalah pengembangan dari algoritma *Multi Layer Perceptron (MLP)* yang mampu mengolah data dua dimensi. Selain itu, CNN ini juga merupakan salah satu algoritma *deep learning* yang menerima *input* berupa gambar yang mampu melakukan pembelajaran pada gambar untuk memperoleh *feature learning*, dan juga dapat membedakan antara gambar yang satu dengan yang lainnya (Chauhan et al., 2018) (Jogin et al., 2018).

Arsitektur CNN dirancang menyerupai cara kerja sel saraf pada otak manusia. CNN ini terinspirasi oleh salah satu bagian otak yaitu *Visual Cortex* yang bertanggung jawab dalam pemrosesan informasi dalam bentuk visual (Bhatt et al., 2021). Dengan arsitektur yang dirancang seperti cara kerja *Visual Cortex*, CNN dapat dilatih untuk memahami detail gambar dengan baik. Arsitektur CNN ditampilkan pada Gambar 2.7.



Gambar 2.7. Arsitektur *Convolutional Neural Network* (CNN)

Sumber: (MathWorks, 2021)

Berdasarkan Gambar 2.7 ditunjukkan bahwa arsitektur CNN memiliki beberapa lapisan untuk menjalankan algoritmanya. Lapisan-lapisan tersebut terdiri dari *convolution layer*, fungsi aktivasi *ReLU*, *normalization layer*, *pooling layer*, *dropout layer*, dan *fully connected layer*. Masing-masing lapisan tersebut akan dijelaskan sebagai berikut:

2.4.1. *Convolution layer*

Convolution layer merupakan *layer* pertama pada *feature learning* dan merupakan *layer* yang paling penting pada CNN (S.-H. Wang et al., 2018). Pada *convolution layer* ini diterapkan beberapa operasi konvolusi untuk mempelajari fitur-fitur dari data citra yang diinputkan (Mostafa et al., 2021). Operasi konvolusi ini diterapkan pada matriks yang berisi nilai piksel citra dan matriks kernel atau yang juga disebut dengan filter (Haq, 2020). Kernel berisi nilai *random* antara -1 hingga 1 yang memiliki ukuran berbeda-beda sesuai dengan jenis arsitekturnya. Rumus *convolutional layer* ditunjukkan pada Persamaan 2.2.

$$Q_j = \left(\sum_{i=1}^N I_{i,j} \otimes F_{i,j} \right) + B_j \quad (2.2)$$


Dengan Q_j merupakan nilai dari proses *convolution*, sedangkan N menunjukkan banyaknya *channel*. Pada citra RGB, biasanya terdapat 3 *channel* yaitu *red*, *green*, dan *blue*. $I_{i,j}$ merupakan matriks yang berisi nilai piksel citra, $F_{i,j}$ merupakan matriks kernel, dan B_j sebagai bias. Sehingga, berdasarkan Persamaan 2.2 tersebut, nilai *convolution* didapatkan dari perkalian matriks yang berisi nilai piksel citra dengan matriks kernel yang kemudian ditambah dengan bias.

Pada algoritma CNN, kernel akan bergeser sejumlah dengan *stride* pada nilai piksel citra. *Stride* merupakan parameter yang menentukan langkah pergeseran matriks kernel baik searah sumbu x maupun sumbu y . Selain itu, terdapat pula *padding* yang merupakan parameter untuk menambah jumlah piksel dari setiap sisi. Pada setiap sisinya, ditambahkan dengan nilai 0 yang bertujuan agar tidak terjadi pengurangan fitur citra dan menyamakan ukuran matriks piksel dan kernel saat memiliki sisa (Rakamawati, 2021).

Proses *convolutional layer* menghasilkan *output* yang disebut dengan *feature map*. Ukuran dari output tersebut dapat dicari menggunakan persamaan 2.3.

$$h = \frac{i - k + 2p}{s} + 1 \quad (2.3)$$

Dimana h merupakan ukuran *feature map*, i adalah ukuran matriks *input*, k merupakan ukuran matriks kernel, p adalah *padding*, dan s adalah *stride*. Contoh proses *convolution* ditunjukkan pada Gambar 2.8.



Gambar 2.8. Proses *Convolution Layer*

Sumber: (Shi et al., 2021)

2.4.2. *Rectified Linear Unit (ReLU)*

ReLU merupakan fungsi aktivasi yang paling sering digunakan pada metode CNN. Fungsi aktivasi bertujuan untuk mengubah sinyal input dari sebuah node menjadi sinyal output. Fungsi aktivasi ReLU memiliki kinerja yang efisien karena waktu komputasi yang dibutuhkan jauh lebih cepat dibandingkan fungsi aktivasi lainnya. Secara lebih jelas, fungsi aktivasi ReLU digunakan untuk mengubah nilai x menjadi 0 jika nilai x tersebut negatif. Apabila nilai x tersebut tidak kurang dari 0, maka nilai x akan tetap dipertahankan. Dengan x adalah *feature map*. Secara matematis, fungsi tersebut dituliskan pada Persamaan 2.4.

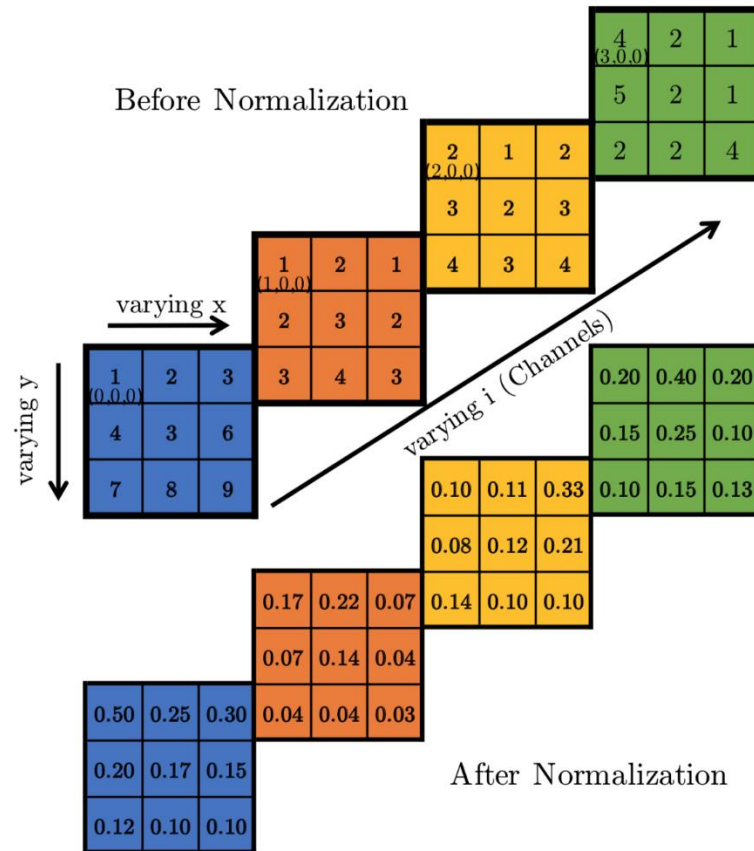
$$f(x) = \max(0, x) \quad (2.4)$$

2.4.3. Local Response Normalization Layer

Local response normalization layer merupakan *layer* yang digunakan untuk normalisasi data pada *feature map* yang berdekatan. *Local response normalization layer* juga dikenal dengan *cross channel normalization*. Rumus yang digunakan pada *local response normalization layer* ditunjukkan pada Persamaan 2.5.

$$x_{i,j}^p = \frac{\alpha_{i,j}^p}{\left(k + \frac{\left(\alpha \sum_{\max(1, p-\frac{n}{2})}^{\min(N-1, p+\frac{n}{2})} (a_{i,j}^q)^2 \right)}{n} \right)^\beta} \quad (2.5)$$

Dimana $x_{i,j}^p$ adalah merupakan *output feature map* yang dihasilkan oleh kernel ke- p . Sedangkan $a_{i,j}^p$ adalah *feature map* sebelum dilakukannya perhitungan pada baris ke- i dan kolom ke- j , dan N merupakan jumlah total *layer*. Selain itu, k (konstanta untuk menghindari 0), α (konstanta normalisasi), β (konstanta kontras), dan n yang digunakan untuk menentukan panjang piksel. Variabel k, α, β , dan n merupakan *hyperparameters* yang digunakan. Ilustrasi gambar *local response normalization layer* ditampilkan pada Gambar 2.9.

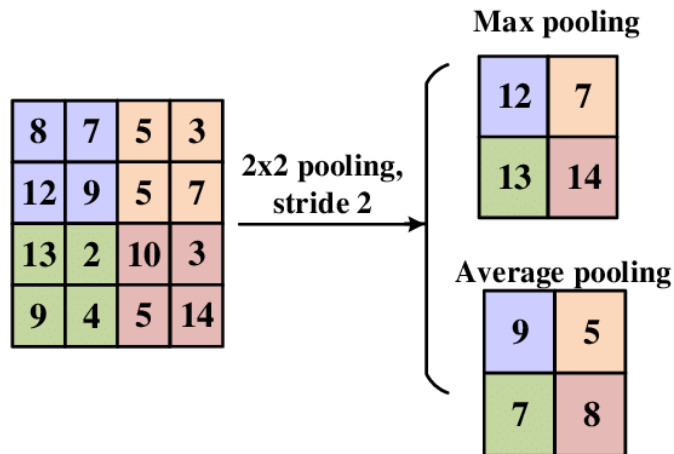


Gambar 2.9. Proses *Local Response Normalization Layer*

Sumber: (Anwar, 2019)

2.4.4. *Pooling Layer*

Pooling layer merupakan *layer* yang biasanya berada setelah *convolution layer* dan berfungsi untuk mengurangi jumlah parameter dengan operasi *down-sampling* (Xiao et al., 2020). Umumnya, metode *pooling* yang digunakan adalah *max pooling* dan *average pooling*. *Max pooling* merupakan jenis *pooling* yang mengambil nilai terbesar pada *feature map* (Yani, 2019). Sedangkan *average pooling* adalah pengambilan nilai rata-rata pada *feature map* (W. Wang & Neumann, 2018). Contoh operasi *pooling layer* ditunjukkan pada Gambar 2.10.




Gambar 2.10. Contoh *Pooling Layer*

Sumber: (Yingge et al., 2020)

2.4.5. *Dropout layer*

Dropout layer merupakan bagian dari *layer* CNN yang berfungsi untuk mencegah adanya *overfitting* (Z. Zhang et al., 2021). Selain itu, *dropout* juga dapat mempercepat terjadinya proses *learning*. Kedua hal tersebut dapat terjadi karena ide utama dari *dropout* adalah dengan menghilangkan beberapa *neuron* secara *random*. Setelah diterapkan *dropout* maka jaringan akan lebih tipis dari sebelumnya dan dapat membantu mencegah terjadinya *overfitting* dan mempercepat proses *training* (S.-H. Wang et al., 2020). Contoh proses *dropout layer* ditunjukkan pada Gambar 2.11.



Gambar 2.11. Proses *Dropout Layer*


Sumber: (Florkowski, 2020)

2.4.6. *Fully Connected Layer*

Fully Connected Layer merupakan *layer* yang menghubungkan *neuron* aktivasi pada *layer* sebelumnya menuju *layer* selanjutnya (Alqumboz & Abu-Naser, 2020). Pada *fully connected layer* ini matriks dengan dimensi x akan diubah menjadi matriks berdimensi satu yang kemudian dapat diklasifikasikan (Lorentius et al., 2019). *Fully connected layer* dapat dicari menggunakan Persamaan 2.6.

$$y_j = b_j + \sum w_{i,j}x_i \quad (2.6)$$

Dimana y_j merupakan hasil *output* dari *fully connected layer* ke- j , b_j merupakan bias, $w_{i,j}$ sebagai bobot jaringan dan x_i adalah input yang diperoleh dari proses *learning feature*. Gambar ilustrasi *fully connected layer* ditunjukkan pada Gambar 2.12.



Gambar 2.12. Proses *Fully Connected Layer*

Sumber: (Kost et al., 2019)

2.4.7. *Softmax Layer*

Softmax layer merupakan fungsi aktivasi yang digunakan pada *output layer* untuk menormalkan jaringan (Alhassan & Zainon, 2021). Hal tersebut dilakukan dengan tujuan mendapatkan nilai probabilitas pada setiap data yang berada diantara interval 0 hingga 1. *Softmax* dapat dicari menggunakan Persamaan 2.7.

$$p_j(x) = \frac{e^{x_j}}{\sum_{i=1}^k e^{x_j}} \quad (2.7)$$

Dimana $p_j(x)$ menyatakan nilai probabilitas dari x_j yang didapatkan dengan melakukan pembagian antara eksponensial x_j dengan total dari penjumlahan eksponensial x_i pada k (banyak kelas).


2.5. *Deep Residual Network (ResNet)*

ResNet merupakan arsitektur CNN yang sangat terkenal pada tahun 2015. Pada tahun tersebut, ResNet menjadi pemenang dalam ILSVRC 2015 dan beberapa kompetisi lain. Dalam tahun 2010 hingga 2015 model ResNet memiliki tingkat *error* terendah jika dibandingkan dengan arsitektur lainnya.

Arsitektur ResNet dibangun untuk mengatasi masalah *deep learning* yang memakan banyak waktu dan terbatas pada lapisan tertentu. Solusi tersebut diusulkan oleh ResNet dengan adanya *skip connection* atau *shortcut* (Raman et al., 2021). ResNet memiliki keunggulan yang tidak dimiliki oleh arsitektur CNN yang lain, yaitu kinerja yang tidak menurun walaupun arsitekturnya semakin dalam. Selain itu, perhitungan komputasi yang dilakukan lebih ringan dan kemampuan untuk melatih jaringan lebih baik. Selain itu, ResNet juga mengatasi masalah mengenai *vanishing gradient problem*, dimana gradien yang terdapat pada *layer* akhir mulai menghilang dan menyebabkan *layer* selanjutnya tidak ada perubahan. Melihat masalah tersebut, ResNet membuat *residual block* seperti yang ditunjukkan pada Gambar 2.12 (Basodi et al., 2020). *Residual block* dapat dicari menggunakan persamaan 2.8.

$$y = F(x, W_i + x) \quad (2.8)$$

Dimana y merupakan *output layer*, dan x adalah *input layer*. Selain itu, F merupakan fungsi sisa (*residual*), dan W_i adalah *weight layer*.



Gambar 2.12. *Residual Block*

Sumber: (Sahoo, 2018)

Residual Block pada ResNet dapat dilakukan jika dimensi data *input* sama dengan dimensi *output* (Sarwinda et al., 2021). Setiap blok pada ResNet terdiri dari 2 layer (untuk jaringan ResNet 18 dan ResNet 34) atau 3 layer (untuk jaringan ResNet 50, 101, dan 152). Jenis-jenis arsitektur ResNet dapat dibedakan berdasarkan jumlah layer yang digunakan, mulai dari 18, 34, 50, 101, hingga 152 layer seperti yang ditampilkan pada Gambar 2.13.

layer name	output size	18-layer	34-layer	50-layer	101-layer	152-layer
conv1	112×112	7×7, 64, stride 2				
conv2_x	56×56	3×3 max pool, stride 2				
		$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$
conv3_x	28×28	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 8$
conv4_x	14×14	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 23$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 36$
conv5_x	7×7	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$
	1×1	average pool, 1000-d fc, softmax				
FLOPs		1.8×10^9	3.6×10^9	3.8×10^9	7.6×10^9	11.3×10^9

Gambar 2.13. Perbandingan Arsitektur pada Model ResNet

Sumber: (Hassan, 2019)

2.6. Confusion Matrix

Confusion matrix adalah metode evaluasi yang digunakan pada sistem klasifikasi yang dapat mengukur tingkat keberhasilan model klasifikasi yang telah dibuat (Koklu & Ozkan, 2020) (Elhoseny et al., 2019). *Confusion matrix* ini digunakan untuk mengetahui akurasi model dengan membandingkan nilai aktual dan nilai prediksi (Zeng, 2020). *Confusion matrix* memiliki ukuran $n \times n$, dimana n menunjukkan jumlah kelas. Gambar *confusion matrix multi class*

ditampilkan pada Gambar 2.14 dengan asumsi bahwa C1 = grade 0, C2 = grade 1, C3 = grade 2, C4 = grade 3, dan C5 = grade 4.

		Predicted Class				
		C1	C2	C3	C4	C5
Actual Class	C1	TN	TN	FP	TN	TN
	C2	TN	TN	FP	TN	TN
	C3	FN	FN	TP	FN	FN
	C4	TN	TN	FP	TN	TN
	C5	TN	TN	FP	TN	TN

Gambar 2.14. *Confusion Matrix* sebanyak 5 kelas

Terdapat beberapa istilah yang digunakan pada *confusion matrix*, yaitu (Chicco et al., 2021):

1. *True Positive* (TP) adalah data C3 yang diprediksi benar pada C3.
2. *True Negative* (TN) adalah data selain C3 yang diprediksi benar pada kelas selain C3.
3. *False Positive* (FP) adalah data selain C3 yang diprediksi salah pada kelas C3.
4. *False Negative* (FN) adalah data C3 yang diprediksi salah pada kelas selain C3.

Berdasarkan nilai yang diberikan oleh TP, TN, FP, dan FN, evaluasi dilakukan menggunakan tiga parameter. Parameter yang digunakan untuk melakukan uji evaluasi menggunakan *confusion matrix* yaitu akurasi, sensitivitas dan spesifisitas. Nilai parameter tersebut dapat dicari menggunakan Persamaan (2.9) sampai Persamaan (2.11) (Muhammad et al., 2020).

$$Akurasi = \frac{TP + TN}{TP + TN + FP + FN} \times 100 \quad (2.9)$$

$$Sensitivitas = \frac{TP}{TP + FP} \times 100 \quad (2.10)$$

$$Spesifisitas = \frac{TN}{TN + FP} \times 100 \quad (2.11)$$

2.7. Penyakit dalam Perspektif Islam

Ditinjau dari segi kedokteran, sakit merupakan keadaan dimana sistem metabolisme tubuh tidak berjalan sebagaimana fungsi awalnya. Berdasarkan perspektif Islam, sakit merupakan pemberian dari Allah untuk menguji tingkat keimanan seorang hambanya. Segala sesuatu yang diberikan Allah SWT kepada hambanya tentu tidak datang begitu saja tanpa dibarengi adanya maksud dan tujuan. Sejalan dengan hal itu, maka sakit diturunkan oleh Allah juga memiliki makna lain didalamnya, diantaranya adalah:

a. Ujian

Datangnya penyakit pada diri seorang hamba dapat dimaknai sebagai ujian dari Allah. Ujian tersebut tentu tidak semata-mata untuk menyengsarakan hambanya, melainkan untuk menguji kesabaran. Setiap manusia yang bernyawa tidak dapat lepas dari ujian yang Allah berikan, sebagaimana sudah dijelaskan dalam Al-Quran surah Al-Baqarah ayat 155 yang berbunyi:

وَلَنَبْلُوَنَّكُمْ بِشَيْءٍ مِّنَ الْخَوْفِ وَالْجُوعِ وَنَقْصٍ مِّنَ الْأَمْوَالِ وَالْأَنْفُسِ
وَالثَّمَرَاتِ وَبَشِّرِ الصَّابِرِينَ

Artinya: Dan Kami pasti akan menguji kamu dengan sedikit ketakutan, kelaparan, kekurangan harta, jiwa, dan buah-buahan. Dan sampaikanlah kabar gembira kepada orang-orang yang sabar.

Pada ayat tersebut menjelaskan bahwa setiap hamba-Nya pasti akan diuji dengan berbagai bentuk ujian yang salah satunya dapat berupa penyakit. Dalam ayat tersebut juga dijelaskan bahwa akan ada ‘kabar gembira’ bagi orang-orang yang melewati ujiannya dengan sabar. Sehingga, adanya sakit yang menimpa diri seorang hamba dapat diyakini sebagai bentuk ujian dari Allah yang harus disikapi dengan sabar. Selain itu, datangnya ujian sakit dari Allah juga dapat mendatangkan kebaikan, seperti sabda Rasulullah SAW pada Hadits yang diriwayatkan oleh Imam Bukhari nomor 5213 yang berbunyi:

حَدَّثَنَا عَبْدُ اللَّهِ بْنُ يُوسُفَ أَخْبَرَنَا مَالِكٌ عَنْ مُحَمَّدِ بْنِ عَبْدِ اللَّهِ بْنِ عَبْدِ
الرَّحْمَنِ بْنِ أَبِي صَعْصَعَةَ أَنَّهُ قَالَ سَمِعْتُ سَعِيدَ بْنَ يَسَارٍ أَبَا الْحُبَابِ يَقُولُ
سَمِعْتُ أَبَا هُرَيْرَةَ يَقُولُ قَالَ رَسُولُ اللَّهِ صَلَّى اللَّهُ عَلَيْهِ وَسَلَّمَ مَنْ يُرِدْ اللَّهُ بِهِ
خَيْرًا يُصِيبْ مِنْهُ

Artinya: Telah menceritakan kepada kami [Abdullah bin Yusuf] telah mengabarkan kepada kami [Malik] dari [Muhammad bin Abdullah bin Abdurrahman bin Abu Sha'sha'ah] bahwa dia berkata, saya mendengar [Sa'id bin Yasar Abu Al Hubbab] berkata; saya mendengar [Abu Hurairah] berkata; Rasulullah shallallahu 'alaihi wasallam bersabda: "Barangsiapa di kehendaki Allah kebaikan, maka Dia akan mengujinya."

Hadits tersebut menjelaskan bahwasanya kebaikan bisa Allah datangkan kepada seorang hamba yang sedang ditimpa ujian. Oleh karena itu, berbaik sangka pada Allah saat ditimpa sakit merupakan hal yang sangat dianjurkan.

b. Teguran

Sakit juga dapat dimaknai dengan teguran yang Allah berikan. Teguran ini diberikan oleh Allah SWT karena kelalaian manusia akan dosa-dosa yang telah dilakukan. Hal tersebut dijelaskan oleh Allah pada surah Al-An'am ayat 65 yang berbunyi:

قُلْ هُوَ الْقَادِرُ عَلَىٰ أَنْ يَبْعَثَ عَلَيْكُمْ عَذَابًا مِّنْ فَوْقِكُمْ أَوْ مِنْ تَحْتِ
أَرْجُلِكُمْ أَوْ يَلْبِسَكُمْ شِيْعًا وَيُذِيقَ بَعْضَكُمْ بَأْسَ بَعْضٍ ۚ أُنْظُرْ كَيْفَ
نُصْرِفُ الْآيَاتِ لَعَلَّهُمْ يَفْقَهُونَ

Artinya: Katakanlah (Muhammad), “Dialah yang berkuasa mengirimkan azab kepadamu, dari atas atau dari bawah kakimu atau Dia mencampurkan kamu dalam golongan-golongan (yang saling bertentangan) dan merasakan kepada sebagian kamu keganasan sebagian yang lain.” Perhatikanlah, bagaimana Kami menjelaskan berulang-ulang tanda-tanda (kekuasaan Kami) agar mereka memahami (Nya).

Ayat diatas menerangkan bahwa Allah SWT dapat mendatangkan adzab kepada manusia dengan berbagai cara. Mulai dari adzab yang datang dari sisi atas seperti halilintar, hujan bebatuan, angin yang kencang, dan lain sebagainya yang dapat menimbulkan rasa sakit. Selain itu, Allah juga dapat memberikan adzab kepada manusia dari sisi bawah seperti longsor, gempa bumi, dan lainnya. Bahkan Allah berkuasa untuk memnunculkan adanya permusuhan yang mengakibatkan peperangan. Berbagai bentuk adzab dari Allah tersebut merupakan bentuk teguran yang Allah berikan kepada hambanya karena sudah lalai terhadap yang larangan yang Allah berikan.

c. Penggugur Dosa

Makna sakit yang ketiga yaitu sebagai penggugur dosa seorang hamba. Ditimpakannya sakit pada diri seorang hamba jika diiringi dengan sikap sabar dan tawakkal dapat menjadi alternatif penggugur dosa. Hal tersebut telah dijelaskan pada Hadits yang diriwayatkan oleh Imam Bukhari dan Muslim:

مَا مِنْ مُسْلِمٍ يُصِيبُهُ أَدَى مِنْ مَرَضٍ فَمَا سِوَاهُ إِلَّا حَطَّ اللَّهُ بِهِ
سَيِّئَاتِهِ كَمَا تَحُطُّ الشَّجَرَةُ وَرَقَهَا

Artinya: Tidaklah seorang muslim tertimpa suatu penyakit dan sejenisnya, melainkan Allah akan mengugurkan bersamanya dosa-dosanya seperti pohon yang mengugurkan daun-daunnya.”

Hadits tersebut menunjukkan bahwa musibah sakit dapat meringankan dosa-dosa hambanya. Karena dengan diturunkannya sakit oleh Allah dapat menjadi penggugur dosa-dosa yang telah berlalu. Oleh karena itu, sakit yang Allah berikan dapat memberikan kebaikan pada diri seorang hamba.

BAB III

METODE PENELITIAN

3.1 Jenis Penelitian


Penelitian ini dapat dikategorikan dalam jenis penelitian kuantitatif karena didasarkan pada data yang digunakan. Pada penelitian ini, data yang digunakan adalah data numerik yang berisi nilai-nilai piksel dari data citra OA lutut. Citra tersebut akan dibaca oleh komputer sehingga akan berubah menjadi sebuah matriks yang berukuran $M \times N$. Matriks tersebut kemudian dilakukan proses perhitungan menggunakan arsitektur CNN jenis ResNet hingga mendapatkan hasil diagnosa pada masing-masing data citra.

3.2 Sumber Data


Data citra x-ray osteoarthritis lutut diambil melalui *website* Mendeley Dataset (Chen, 2018). Data tersebut terbagi menjadi 5 kelas yang terdiri dari grade 0, grade 1, grade 2, grade 3, dan grade 4. Total data citra yang diperoleh adalah sebanyak 9458 dengan pembagian 3529 data grade 0, 1770 data grade 1, 2578 data grade 2, 1286 data grade 3, dan 295 data grade 4. Sampel citra dari masing-masing kelas ditunjukkan pada Gambar 3.1.




(a)



(b)



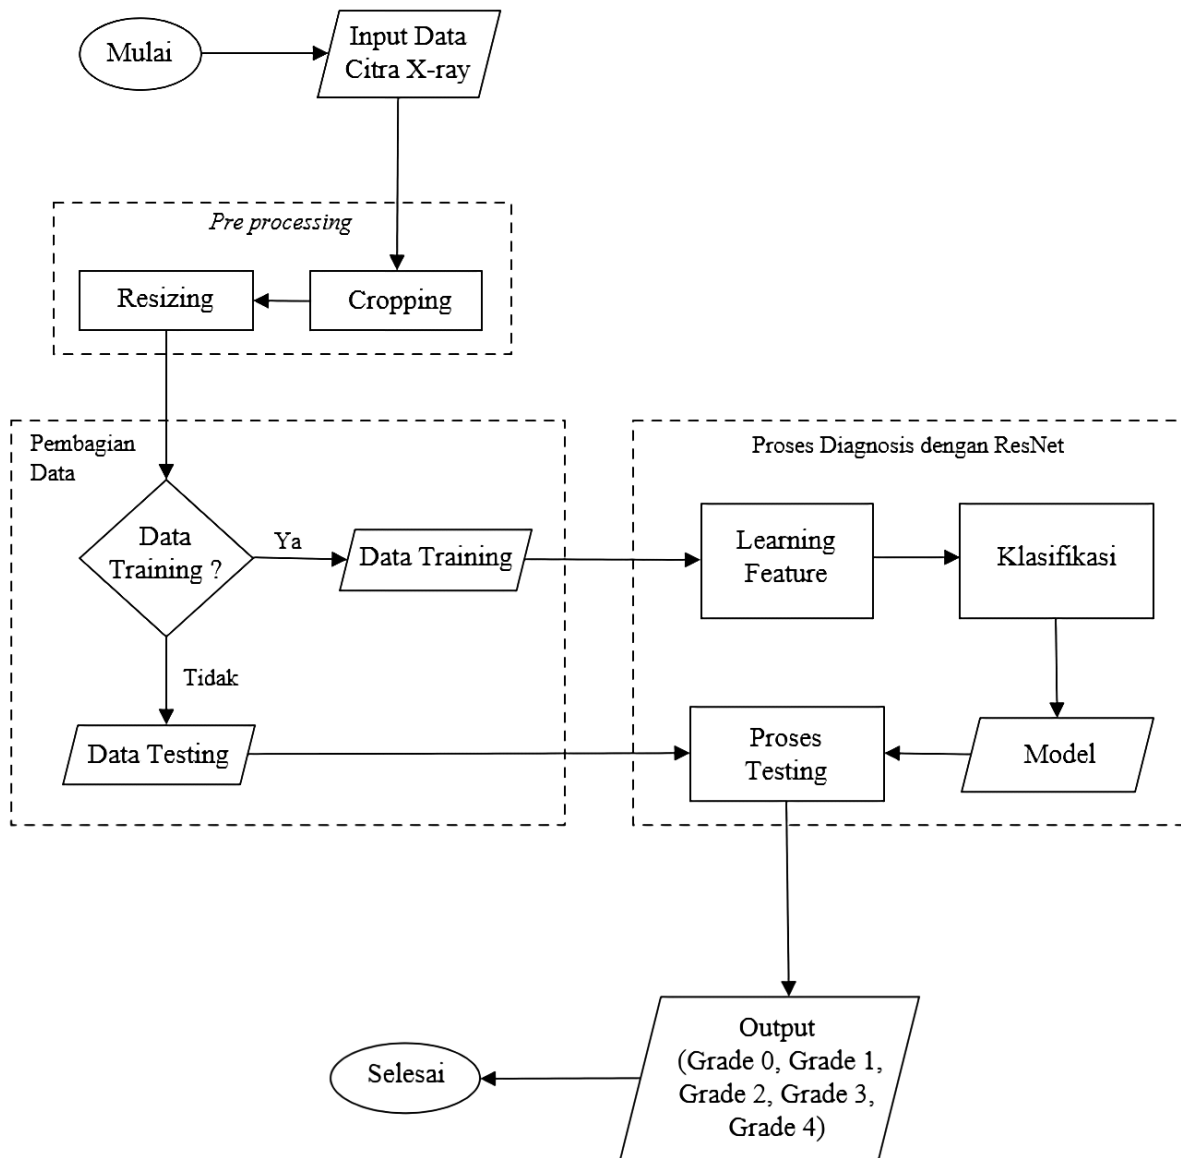
(c)



Gambar 3.1. Citra X-ray Osteoarthritis Lutut **(a)** Grade 0; **(b)** Grade 1; **(c)** Grade 2; **(d)** Grade 3; **(e)** Grade 4

3.3 Kerangka Penelitian


Proses yang dilakukan untuk diagnosis osteoarthritis lutut menggunakan metode *Convolutional Neural Network* (CNN) jenis ResNet terdiri dari beberapa tahapan seperti yang ditunjukkan pada Gambar 3.2.



Gambar 3.2. Diagram Alir Penelitian

Penelitian ini terdiri dari beberapa tahapan seperti yang dijelaskan berikut:

1. Tahap *preprocessing*, semua data citra yang awalnya berukuran 224×224 dilakukan *cropping* pada bagian pertemuan tulang femur dan tibia. Selanjutnya, dilakukan *resizing* untuk mengembalikan citra pada ukuran 224×224 seperti yang ditunjukkan pada Gambar 3.3.



Gambar 3.3. *Preprocessing*

2. Tahap pembagian data dilakukan menggunakan *SplitEachLabel*. Pembagian data dilakukan dengan beberapa uji coba yaitu dengan prosentase data *training* 60%, 70%, 80%, dan 90%.
3. Proses *feature learning* dilakukan menggunakan algoritma CNN dengan arsitektur jaringan ResNet. Arsitektur tersebut dapat dibangun berdasarkan *layer-layer* CNN yang ditunjukkan pada Persmaan 2.2 hingga 2.6. Uji coba parameter juga dilakukan dengan nilai *dropout* sebesar 0.6, 0.7, 0.8, dan 0.9. Selain itu, uji coba *minibatchsize* juga dilakukan dengan nilai 8, 16, 32, dan 64.
4. Tahap klasifikasi pada *fully connected layer* dengan menggunakan *softmax layer* dapat dilakukan dengan menggunakan persamaan 2.7.
5. Tahap terakhir yaitu evaluasi menggunakan *confusion matrix multi-class* untuk mendapatkan nilai akurasi, sensitivitas, dan spesifisitas yang masing-masing dapat dicari menggunakan Persamaan 2.9, 2.10, dan 2.11.

BAB IV

HASIL DAN PEMBAHASAN

BAB V

PENUTUP

DAFTAR PUSTAKA

- Agrawal, S., Patel, M., & Sinhal, A. (2021). An Enhance Security of the Color Image Using Asymmetric RSA Algorithm. *Proceedings of International Conference on Communication and Computational Technologies*, 279–286.
- Alhassan, A. M., & Zainon, W. M. N. W. (2021). Brain tumor classification in magnetic resonance image using hard swish-based RELU activation function-convolutional neural network. *Neural Computing and Applications*, 33(15), 9075–9087.
- Allaam, M. R. R., & Wibowo, A. T. (2021). Klasifikasi Genus Tanaman Anggrek Menggunakan Metode Convolutional Neural Network (cnn). *EProceedings of Engineering*, 8(2).
- Alqumboz, M. N. A., & Abu-Naser, S. S. (2020). Avocado Classification Using Deep Learning. *International Journal of Academic Engineering Research (IJAER)*, 3(12).
- Anwar, A. (2019). *Difference between Local Response Normalization and Batch Normalization. Towards Data Science*.
- Basodi, S., Ji, C., Zhang, H., & Pan, Y. (2020). Gradient amplification: An efficient way to train deep neural networks. *Big Data Mining and Analytics*, 3(3), 196–207.
- Bhatt, D., Patel, C., Talsania, H., Patel, J., Vaghela, R., Pandya, S., Modi, K., & Ghayvat, H. (2021). CNN variants for computer vision: History, architecture, application, challenges and future scope. *Electronics*, 10(20), 2470.
- Budhiman, A., Suyanto, S., & Arifianto, A. (2019). Melanoma cancer classification using resnet with data augmentation. *2019 International Seminar on Research of Information Technology and Intelligent Systems (ISRITI)*, 17–20.
- Chapala, H., & Sujatha, B. (2020). ResNet: detection of invasive ductal carcinoma in breast histopathology images using deep learning. *2020 International Conference on Electronics and Sustainable Communication Systems (ICESC)*, 60–67.
- Chauhan, R., Ghanshala, K. K., & Joshi, R. C. (2018). Convolutional neural network (CNN) for image detection and recognition. *2018 First International Conference on Secure Cyber Computing and Communication (ICSCCC)*, 278–282.
- Chen, P. (2018). *Knee Osteoarthritis Severity Grading Dataset*. Mendeley Dataset.
- Chicco, D., Tötsch, N., & Jurman, G. (2021). The Matthews correlation coefficient (MCC) is more reliable than balanced accuracy, bookmaker informedness, and markedness in two-class confusion matrix evaluation. *BioData Mining*, 14(1), 1–22.
- Chow, Y. Y., & Chin, K.-Y. (2020). The role of inflammation in the pathogenesis of osteoarthritis. *Mediators of Inflammation*, 2020.

- Cui, A., Li, H., Wang, D., Zhong, J., Chen, Y., & Lu, H. (2020). Global, regional prevalence, incidence and risk factors of knee osteoarthritis in population-based studies. *EClinicalMedicine*, 29, 100587.
- Damanik, R. (2022). IMAGE DETECTION EDGE IMAGE USING CANNY EDGE ALGORITHM. *Journal of Artificial Intelligence and Engineering Applications (JAIEA)*, 1(3), 248–255.
- Dougherty, E. R. (2020). *Digital image processing methods*. CRC Press.
- Elhoseny, M., Shankar, K., & Uthayakumar, J. (2019). Intelligent diagnostic prediction and classification system for chronic kidney disease. *Scientific Reports*, 9(1), 1–14.
- El-Kahlout, M. I., & Abu-Naser, S. S. (2020). Peach type classification using deep learning. *International Journal of Academic Engineering Research (IJAER)*, 3(12).
- Elswah, D. K., Elnakib, A. A., & Moustafa, H. E. (2020). Automated Diabetic Retinopathy Grading using Resnet. *2020 37th National Radio Science Conference (NRSC)*, 248–254. <https://doi.org/10.1109/NRSC49500.2020.9235098>
- Feng, B., Zhou, H., Li, G., Zhang, Y., Sood, K., & Yu, S. (2021). Enabling Machine Learning with Service Function Chaining for Security Enhancement at 5G Edges. *IEEE Network*, 35(5), 196–201.
- Florkowski, M. (2020). Classification of partial discharge images using deep convolutional neural networks. *Energies*, 13(20), 5496.
- Haq, D. Z. (2020). *KLASIFIKASI CITRA KANKER KULIT MENGGUNAKAN CONVOLUTIONAL NEURAL NETWORK MODEL GOOGLINET*. UIN Sunan Ampel Surabaya.
- Hassan, M. ul. (2019). *ResNet (34, 50, 101): Residual CNNs for Image Classification Tasks*. Neurohive.
- Hsu, H., & Siwiec, R. M. (2018). *Knee osteoarthritis*.
- Hussain, S. M., Dawson, C., Wang, Y., Tonkin, A. M., Chou, L., Wluka, A. E., & Cicuttini, F. M. (2020). Vascular pathology and osteoarthritis: a systematic review. *The Journal of Rheumatology*, 47(5), 748–760.
- Jang, S., Lee, K., & Ju, J. H. (2021). Recent Updates of Diagnosis, Pathophysiology, and Treatment on Osteoarthritis of the Knee. *International Journal of Molecular Sciences*, 22(5), 2619.
- Jogin, M., Madhulika, M. S., Divya, G. D., Meghana, R. K., & Apoorva, S. (2018). Feature extraction using convolution neural networks (CNN) and deep learning. *2018 3rd IEEE International Conference on Recent Trends in Electronics, Information & Communication Technology (RTEICT)*, 2319–2323.

- Jones, I. A., Togashi, R., Wilson, M. L., Heckmann, N., & Vangsness, C. T. (2019). Intra-articular treatment options for knee osteoarthritis. *Nature Reviews Rheumatology*, 15(2), 77–90.
- Kan, H. S., Chan, P. K., Chiu, K. Y., Yan, C. H., Yeung, S. S., Ng, Y. L., Shiu, K. W., & Ho, T. (2019). Non-surgical treatment of knee osteoarthritis. *Hong Kong Medical Journal*, 25(2), 127.
- Khaleghi, M. (2020). New arthritis foundation guidelines on CBD use could be first of many more to come. *Alternative Therapies in Health and Medicine*, 26, 8–11.
- Koklu, M., Cinar, I., & Taspinar, Y. S. (2021). Classification of rice varieties with deep learning methods. *Computers and Electronics in Agriculture*, 187, 106285.
- Koklu, M., & Ozkan, I. A. (2020). Multiclass classification of dry beans using computer vision and machine learning techniques. *Computers and Electronics in Agriculture*, 174, 105507.
- Kost, A., Altabey, W., Noori, M., & Awad, T. (2019). Applying Neural Networks for Tire Pressure Monitoring Systems. *Structural Durability & Health Monitoring*, 13, 247–266. <https://doi.org/10.32604/sdhm.2019.07025>
- Kurnianto, D. (2013). *Empat Tipe Dasar Citra Digital*. Catatan Peneliti.
- Lespasio, M. J., Piuizzi, N. S., Husni, M. E., Muschler, G. F., Guarino, A. J., & Mont, M. A. (2017). Knee osteoarthritis: a primer. *The Permanente Journal*, 21.
- Li, J. (2022). Application of Nanotubes Combined with Ethnic Sports Rehabilitation Therapy in the Treatment of Patients with Knee Arthritis. *Journal of Nanomaterials*, 2022.
- Lorentius, C. A., Gunadi, K., & Tjondrowiguno, A. N. (2019). Pengenalan Aksara Jawa dengan Menggunakan Metode Convolutional Neural Network. *Jurnal Infra*, 7(1), 221–227.
- Maheen, U., Malik, K. I., & Ali, G. (2021). Comparative Analysis of Deep Learning Algorithms for Classification of COVID-19 X-Ray Images. *ArXiv Preprint ArXiv:2110.09294*.
- Maruyama, T., Hayashi, N., Sato, Y., Hyuga, S., Wakayama, Y., Watanabe, H., Ogura, A., & Ogura, T. (2018). Comparison of medical image classification accuracy among three machine learning methods. *Journal of X-Ray Science and Technology*, 26(6), 885–893.
- MathWorks. (2021). *What is a Convolutional Neural Network?* MATLAB & Simulink.
- Mostafa, A. M., Kumar, S. A., Meraj, T., Rauf, H. T., Alnuaim, A. A., & Alkhayyal, M. A. (2021). Guava Disease Detection Using Deep Convolutional Neural Networks: A Case Study of Guava Plants. *Applied Sciences*, 12(1), 239.
- Muhammad, Y., Tahir, M., Hayat, M., & Chong, K. T. (2020). Early and accurate detection and diagnosis of heart disease using intelligent computational model. *Scientific Reports*, 10(1), 1–17.

- Naz, S., Bibi, K., & Ahmad, R. (2022). DeepSignature: fine-tuned transfer learning based signature verification system. *Multimedia Tools and Applications*, 1–10.
- Pavone, V., Vescio, A., Turchetta, M., Giardina, S. M. C., Culmone, A., & Testa, G. (2021). Injection-based management of osteoarthritis of the knee: A systematic review of guidelines. *Frontiers in Pharmacology*, 12, 661805.
- Peterson, L. S. (2020). *Mayo Clinic Guide to Arthritis: Managing Joint Pain for an Active Life*. Rosetta Books.
- Philips, T., Vanmierlo, B., & Goubau, J. F. (2022). Arthroplasty of the Proximal Interphalangeal Joint With the TACTYS Prosthesis: Clinical and Radiographic Results With a Mean Follow-up of 5 Years. *HAND*, 15589447211030962.
- Rakamawati, J. V. N. (2021). *Klasifikasi diabetic retinopathy berdasarkan foto fundus menggunakan Convolutional Neural Network (CNN) jenis densenet*. UIN Sunan Ampel Surabaya.
- Raman, S., Maskeliūnas, R., & Damaševičius, R. (2021). Markerless dog pose recognition in the wild using ResNet deep learning model. *Computers*, 11(1), 2.
- Razzak, I., Shoukat, G., Naz, S., & Khan, T. M. (2020). Skin lesion analysis toward accurate detection of melanoma using multistage fully connected residual network. *2020 International Joint Conference on Neural Networks (IJCNN)*, 1–8.
- Rizani, F. (2021). Image quality improvement using image processing method image brightness contrast and image sharpening. *MULTICA SCIENCE AND TECHNOLOGY (MST) JOURNAL*, 1(1), 6–12.
- Sahoo, S. (2018). *Residual Blocks — Building Blocks of ResNet*. Towards Data Science.
- Sarwinda, D., Paradisa, R. H., Bustamam, A., & Anggia, P. (2021). Deep learning in image classification using residual network (ResNet) variants for detection of colorectal cancer. *Procedia Computer Science*, 179, 423–431.
- Sathesh, A., & Adam, E. E. B. (2021). Hybrid Parallel Image Processing Algorithm for Binary Images with Image Thinning Technique. *Journal of Artificial Intelligence*, 3(03), 243–258.
- Shi, J., Dang, J., Cui, M., Zuo, R., Shimizu, K., Tsunoda, A., & Suzuki, Y. (2021). Improvement of damage segmentation based on pixel-level data balance using vgg-unet. *Applied Sciences*, 11(2), 518.
- Sihotang, J. (2019). Implementation of Gray Level Transformation Method for Sharping 2D Images. *INFOKUM*, 8(1, Desembe), 16–19.
- Singh, Y. K. (2021). Detection of Fire Regions Using RGB Color Variance. *Int. J. Res. Eng. Sci*, 9, 10–14.

- Szyc, K. (2019). An impact of different images color spaces on the efficiency of convolutional neural networks. *International Conference on Dependability and Complex Systems*, 506–514.
- Tekade, R., & Rajeswari, K. (2018). Lung Cancer Detection and Classification Using Deep Learning. *2018 Fourth International Conference on Computing Communication Control and Automation (ICCUBE)*, 1–5. <https://doi.org/10.1109/ICCUBE.2018.8697352>
- Thienkarochanakul, K., Javadi, A. A., Akrami, M., Charnley, J. R., & Benattayallah, A. (2020). Stress distribution of the tibiofemoral joint in a healthy versus osteoarthritis knee model using image-based three-dimensional finite element analysis. *Journal of Medical and Biological Engineering*, 40(3), 409–418.
- Venkatachalam, J., Natesan, M., Eswaran, M., Johnson, A. K. S., Bharath, V., & Singh, Z. (2018). Prevalence of osteoarthritis of knee joint among adult population in a rural area of Kanchipuram District, Tamil Nadu. *Indian Journal of Public Health*, 62(2), 117.
- Victoria, L. W. (2022). Rheumatoid Arthritis: An Autoimmune Disorder. *Acta Rheuma*, 9(6), 10.
- Wang, S.-H., Muhammad, K., Hong, J., Sangaiah, A. K., & Zhang, Y.-D. (2020). Alcoholism identification via convolutional neural network based on parametric ReLU, dropout, and batch normalization. *Neural Computing and Applications*, 32(3), 665–680.
- Wang, S.-H., Phillips, P., Sui, Y., Liu, B., Yang, M., & Cheng, H. (2018). Classification of Alzheimer's disease based on eight-layer convolutional neural network with leaky rectified linear unit and max pooling. *Journal of Medical Systems*, 42(5), 1–11.
- Wang, W., & Neumann, U. (2018). Depth-aware cnn for rgb-d segmentation. *Proceedings of the European Conference on Computer Vision (ECCV)*, 135–150.
- Wang, Y., Ge, Q., Lu, W., & Yan, X. (2020). Well-logging constrained seismic inversion based on closed-loop convolutional neural network. *IEEE Transactions on Geoscience and Remote Sensing*, 58(8), 5564–5574.
- Xiao, B., Li, X., Li, C., & Xu, Q. (2020). A novel pooling block for improving lightweight deep neural networks. *Pattern Recognition Letters*, 135, 307–312.
- Xiong, N. N., Shen, Y., Yang, K., Lee, C., & Wu, C. (2018). Color sensors and their applications based on real-time color image segmentation for cyber physical systems. *EURASIP Journal on Image and Video Processing*, 2018(1), 1–16.
- Yahaya, I., Wright, T., Babatunde, O. O., Helliwell, T., Dikomititis, L., & Mallen, C. D. (2021). Prevalence of osteoarthritis in lower middle-and low-income countries: a systematic review and meta-analysis. *Rheumatology International*, 41(7), 1221–1231.
- Yani, M. (2019). Application of transfer learning using convolutional neural network method for early detection of terry's nail. *Journal of Physics: Conference Series*, 1201(1), 012052.

- Yingge, H., Ali, I., & Lee, K.-Y. (2020). Deep neural networks on chip-A survey. *2020 IEEE International Conference on Big Data and Smart Computing (BigComp)*, 589–592.
- Yoo, J. J., Kim, D. H., & Kim, H. A. (2018). Risk factors for progression of radiographic knee osteoarthritis in elderly community residents in Korea. *BMC Musculoskeletal Disorders*, 19(1), 1–7.
- Zeng, G. (2020). On the confusion matrix in credit scoring and its analytical properties. *Communications in Statistics-Theory and Methods*, 49(9), 2080–2093.
- Zhang, Q., Lin, J., Song, H., & Sheng, G. (2018). Fault identification based on PD ultrasonic signal using RNN, DNN and CNN. *2018 Condition Monitoring and Diagnosis (CMD)*, 1–6.
- Zhang, Z., Xu, X., Gong, W., Chen, Y., & Gao, H. (2021). Efficient federated convolutional neural network with information fusion for rolling bearing fault diagnosis. *Control Engineering Practice*, 116, 104913.